

Laporan Teknis Paket **fastsae**:

Estimasi Area Kecil Frekuentis dan Bayes Berperforma Tinggi di R

Laporan otomatis dari pembacaan kode sumber **fastsae**
<https://github.com/ridsonap/fastvae>

Oktober 2026

Ringkasan

Laporan ini mendokumentasikan paket R **fastvae** (v1.0.0) langsung dari kodenya: setiap persamaan, algoritma, dan klaim implementasi dibaca dari `R/`, `src/*.cpp`, `man/`, `vignettes/`, `tests/`, `DESCRIPTION` dan `README.Rmd`. Bagian pendahuluan menjelaskan masalah estimasi area kecil (SAE) dan arsitektur paket; bagian 2 mendeskripsikan inti C++ (Fisher scoring, identitas Woodbury, bootstrap OpenMP); bagian 3 melaporkan benchmark yang seluruh angkanya dihitung ulang dari `inst/extdata/*.rds`; bagian 4 menyajikan latar statistik; bagian 5 membedah sembilan fungsi model (`eblup_fh()`, `eblup_sfh()`, `eblup_stfh()`, `eblup_bhf()`, `eblup_twofold()`, `hb_area()`, `hb_unit()`, `hb_twofold()` beserta utilitasnya) lengkap dengan pseudo-code yang dicocokkan baris demi baris terhadap sumber; bagian 6 menjelaskan kerangka Bayes-INLA (GMRF, CAR/ICAR, BYM/BYM2, prior PC); bagian 7 membahas utilitas diagnostik dan pemetaan; bagian 8 berisi derivasi dan reproduktibilitas. Seluruh perbedaan antara implementasi dan rumus yang lazim dikutip didaftarkan dalam `DISCREPANCIES.md`, dan referensi yang tidak dapat diverifikasi didaftarkan dalam `TODO_REFERENCES.md`.

Daftar Isi

1	Pendahuluan	8
1.1	Masalah estimasi area kecil	8
1.2	Estimasi langsung, sintetis, dan EBLUP	8
1.3	Apa yang ditawarkan fastvae	8
1.4	Arsitektur paket	9
1.5	Instalasi, termasuk INLA	10
1.6	Struktur repositori dan cara membaca laporan ini	10
2	Desain perangkat lunak	11
2.1	Pembagian kerja R dan C++	11
2.2	Struktur iterasi: Fisher scoring	11
2.3	Identitas matriks: di mana Woodbury dipakai	12
2.4	Strategi memori	13
2.5	Bootstrap paralel	13
2.6	Objek keluaran dan kelas S3	14
2.7	Ringkasan desain	14

3	Benchmark	15
3.1	Metodologi	15
3.2	Waktu komputasi	16
3.3	Penggunaan memori	19
3.4	Skala terhadap jumlah area	19
3.5	Ekuivalensi numerik terhadap pembandingan	23
3.6	Kaveat dan keadilan	24
3.7	Kontradiksi klaim dokumentasi terhadap data	24
4	Latar statistik	25
4.1	Tabel notasi	25
4.2	Model campuran linear, GLS, dan BLUP	25
4.3	EBLUP	26
4.4	ML, REML, dan skor	26
4.5	Fisher scoring	27
4.6	Dekomposisi MSE	27
4.7	MSE bootstrap	28
4.8	Domain tanpa sampel dan prediksi sintetis	28
4.9	Benchmarking: pengertian internal dan eksternal	29
5	Model Fay–Herriot area-level: eblup_fh	29
5.1	Setting data dan kapan dipakai	29
5.2	Persamaan model	29
5.3	Prediktor titik	29
5.4	Estimasi komponen varians	30
5.5	Estimasi MSE	30
5.6	Pseudo-code	30
5.7	Signature, argumen, objek keluaran, dan contoh	30
5.8	Referensi kunci	32
6	Model Fay–Herriot spasial: eblup_sfh	32
6.1	Setting data dan kapan dipakai	32
6.2	Persamaan model	33
6.3	Prediktor titik	33
6.4	Estimasi komponen varians	33
6.5	Estimasi MSE	34
6.6	Pseudo-code	36
6.7	Signature, argumen, objek keluaran, dan contoh	36
6.8	Referensi kunci	36

7	Model Fay–Herriot spasio-temporal: eblup_stfh	36
7.1	Setting data dan kapan dipakai	36
7.2	Persamaan model	37
7.3	Prediktor titik	37
7.4	Estimasi komponen varians	37
7.5	Estimasi MSE	38
7.6	Pseudo-code	38
7.7	Signature, argumen, objek keluaran, dan contoh	38
7.8	Referensi kunci	40
8	Model unit-level Battese–Harter–Fuller: eblup_bhf	40
8.1	Setting data dan kapan dipakai	40
8.2	Persamaan model	41
8.3	Prediktor titik	41
8.4	Estimasi komponen varians	41
8.5	Estimasi MSE	41
8.6	Pseudo-code	42
8.7	Signature, argumen, objek keluaran, dan contoh	42
8.8	Referensi kunci	44
9	Model sub-area dua-lipat: eblup_twofold	44
9.1	Setting data dan kapan dipakai	44
9.2	Persamaan model	44
9.3	Prediktor titik	44
9.4	Estimasi komponen varians	45
9.5	Estimasi MSE	45
9.6	Pseudo-code	46
9.7	Signature, argumen, objek keluaran, dan contoh	46
9.8	Referensi kunci	46
10	Model hierarki Bayes area-level: hb_area	48
10.1	Setting data dan kapan dipakai	48
10.2	Persamaan model	48
10.3	Prediktor titik	49
10.4	Estimasi komponen varians	49
10.5	Estimasi MSE	49
10.6	Pseudo-code	50
10.7	Signature, argumen, objek keluaran, dan contoh	50
10.8	Referensi kunci	51

11 Model hierarki Bayes unit-level: <code>hb_unit</code>	51
11.1 Setting data dan kapan dipakai	51
11.2 Persamaan model	52
11.3 Prediktor titik	52
11.4 Estimasi komponen varians	52
11.5 Estimasi MSE	53
11.6 Pseudo-code	53
11.7 Signature, argumen, objek keluaran, dan contoh	53
11.8 Referensi kunci	54
12 Model hierarki Bayes sub-area dua-lipat: <code>hb_twofold</code>	54
12.1 Setting data dan kapan dipakai	54
12.2 Persamaan model	54
12.3 Prediktor titik	55
12.4 Estimasi komponen varians	55
12.5 Estimasi MSE	55
12.6 Pseudo-code	55
12.7 Signature, argumen, objek keluaran, dan contoh	55
12.8 Referensi kunci	57
13 Kerangka Bayes: INLA, GMRF, struktur spasial, dan prior	57
13.1 Model latent Gaussian dan aproksimasi INLA	57
13.2 Gaussian Markov Random Field	58
13.3 Struktur presisi: CAR, ICAR, BYM, dan varian lain	58
13.4 Prior PC dan log-gamma	59
13.5 Likelihood, link, dan parameterisasi <code>scale</code>	60
14 Lapisan utilitas: benchmarking, diagnostik, perbandingan, ekspor, peta	60
14.1 Benchmarking: <code>benchmark_sae</code>	62
14.2 Diagnostik: <code>diagnose</code>	63
14.3 Perbandingan dua model: <code>compare_sae</code>	64
14.4 Flag reliabilitas dan ekspor: <code>export_sae</code>	65
14.5 Peta choropleth: <code>map_sae</code>	65
14.6 Metode S3 dan grafik	65
14.7 Data simulasi	66
14.8 Rujukan lapisan utilitas	67
A Derivasi identitas Woodbury dan penerapannya	67
B Derivasi skor dan informasi Fisher (ML dan REML)	68

C Derivasi suku-suku MSE (g_1, g_2, g_3, g_4)	68
D Glosarium	69
E Reproduksi angka dan gambar dalam laporan ini	69

Daftar Gambar

1 Waktu median per iterasi terhadap jumlah area n (skala log pada kedua sumbu). Sumber: <code>inst/extdata/eblup_benchmark.rds</code> , <code>seblup_benchmark.rds</code> , <code>steblup_benchmark.rds</code> , <code>hb_benchmark.rds</code> ; digambar oleh <code>scripts/02_figures.R</code>	21
2 Waktu median untuk tiga varian model beta (skala log-log). Sumber: <code>inst/extdata/beta_benchmark.rds</code> , <code>spatial_beta_benchmark.rds</code> , <code>spatio_temporal_beta_benchmark.rds</code> ; <code>scripts/02_figures.R</code> . Panel (c) hanya memiliki $n = 30$ dan $n = 50$	21
3 Alokasi memori total per iterasi terhadap n (skala log-log). Sumber: file <code>inst/extdata/*_benchmark.rds</code> sebagaimana tercantum pada tiap panel; <code>scripts/02_figures.R</code>	22
4 Rasio waktu (pembanding/tes) terhadap n ; garis putus-putus menandai rasio = 1. Sumber: file <code>inst/extdata/*_benchmark.rds</code> ; <code>scripts/02_figures.R</code>	22
5 Ekuivalensi numerik <code>fastsae</code> vs <code>tipsae</code> untuk $n = 1000$ area: (a) prediktor area terhadap garis identitas; (b) MSE pada skala log. Sumber: <code>inst/extdata/beta_estimates_n1000.rds</code> ; <code>scripts/02_figures.R</code>	24
6 Graf tetangga enam domain beserta matriks yang diturunkannya. Derajat dibaca dari graf: d_1 dan d_3 bertiga, sisanya bertua. Matriks bobot apa pun (<code>matrix</code> , <code>nb</code> , <code>listw</code>) dikonversi ke graf biner simetris oleh <code>.convert_spatial_weights</code> sebelum masuk <code>inla.graph</code> . Sumber: <code>R/inla_utils.R:27-88</code> dan pemakaian Q di <code>R/hb_area.R:411-488</code>	61
7 Struktur ketergantungan pada field laten GMRF: hanya pasangan dengan $Q_{ij} \neq 0$ yang bersambung (markov blanket), sementara y_i bergantung pada x_i lewat link. Struktur Q inilah yang diisi oleh CAR/ICAR/BYM/BYM2 pada Tabel 25. Sumber: (65) dan <code>R/hb_area.R:411-488</code>	61

Daftar Tabel

1 Fungsi yang diekspor <code>fastsae</code> dan perannya. Sumber: <code>NAMESPACE</code> dan kode masing-masing fungsi di R/.	9
2 Fungsi <code>Rcpp</code> dan <code>OpenMP</code> . Sumber: <code>src/RcppExports.cpp</code> , <code>src/Makevars</code> , dan <code>grep #pragma omp</code> pada <code>src/*.cpp</code>	10
3 Pembagian kerja lapis R dan lapis C++ per fungsi model. Sumber: pemanggilan <code>.eblup_core/.seblup_core/.eblup_stfh_core/.eblup_tfh_core/.eblup_bhf_cpp</code> beserta berkas pemanggilnya.	11
4 Pengaturan iterasi pada empat inti Fisher scoring. Sumber: baris kode pada kolom terakhir.	12

5	Kelas dan elemen khusus objek keluaran. Sumber: kode perakitan output masing-masing fungsi.	14
6	Skrip benchmark: pembandingan, ukuran masalah, iterasi, dan seed. Sumber: pembacaan <code>benchmarks/*.R</code> (lihat <code>_notes/bench_methodology.md</code>).	16
7	Waktu median per iterasi (detik) menurut jumlah area n . Sumber: file <code>eblup_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	17
8	Waktu median per iterasi (detik) menurut jumlah area n . Sumber: file <code>seblup_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	17
9	Waktu median per iterasi (detik) menurut jumlah area n . Model spasio-temporal dengan T periode waktu; waktu termasuk estimasi komponen varian. Sumber: file <code>steblop_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	17
10	Waktu median per iterasi (detik) menurut jumlah area n . Model area-level beta (<code>fastsae::hb_area</code> vs <code>tipsae::fit_sae</code>). Sumber: file <code>beta_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	17
11	Waktu median per iterasi (detik) menurut jumlah area n . Model area-level beta dengan efek spasial. Sumber: file <code>spatial_beta_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	18
12	Waktu median per iterasi (detik) menurut jumlah area n . Model beta spasio-temporal ($T = 5$); data tersedia hanya untuk $n = 30$ dan $n = 50$. Sumber: file <code>spatio_temporal_beta_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	18
13	Waktu median per iterasi (detik) menurut jumlah area n . Model hierarki Bayes area-level Gaussian (<code>hb_area</code>) vs <code>hbsae::fSAE.Area</code> . Sumber: file <code>hb_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	18
14	Alokasi memori total per iterasi (MB) menurut jumlah area n . Sumber: file <code>eblup_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	19
15	Alokasi memori total per iterasi (MB) menurut jumlah area n . Sumber: file <code>seblup_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	19
16	Alokasi memori total per iterasi (MB) menurut jumlah area n . Sumber: file <code>steblop_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	19
17	Alokasi memori total per iterasi (MB) menurut jumlah area n . Model hierarki Bayes area-level Gaussian. Sumber: file <code>hb_benchmark.rds</code> di <code>inst/extdata</code> (repo <code>fastsae</code>); angka dihitung ulang oleh <code>scripts/01_tables.R</code> , ditampilkan hingga 6 digit signifikan.	20

18	Ringkasan alokasi memori total per iterasi (MB): rerata, minimum dan maksimum lintas seluruh n pada tiap file sumber. Kolom “maks” adalah nilai pada n terbesar pada file tersebut.	20
19	Rasio kecepatan = median waktu pembandingan / median waktu fastsae (semakin besar semakin cepat fastsae ; nilai < 1 berarti pembandingan lebih cepat). Rasio dihitung per n lalu diringkas.	23
20	Ekuivalensi numerik antara fastsae dan tipsae pada $n = 1000$ area (indikator beta). Semua metrik dihitung dari pasangan kolom pada file sumber.	23
21	Klaim dokumentasi yang bertolak belakang dengan file data. Sumber: README.Rmd , vignettes/benchmarks.Rmd , paper/article.tex vs inst/extdata/*.rds (butir DOC-1–DOC-11 di DISCREPANCIES.md).	25
22	Notasi utama dan padanannya dalam kode. Sumber: simbol pada R/*.R dan src/*.cpp	26
23	Penanganan domain tanpa sampel. Sumber: cabang kode pada kolom terakhir.	28
24	Pemetaan st_interaction ke bentuk interaksi Knorr–Held. Sumber: penyusunan string f(...) di R/hb_area.R:491–566	48
25	Struktur presisi spasial dan pemakainya di fastsae . Sumber: penyusunan f(...) di R/hb_area.R:411–488 dan R/hb_unit.R:253–263 , R/hb_twofold.R:242–258	58
26	Prior default di tiga fungsi Bayes (baca: “argumen bawaan yang didefinisikan dalam signature”). Sumber: signature fungsi dan pemakaian hyper di R/hb_area.R:399–488 , R/hb_unit.R:136 , R/hb_twofold.R:153–154	59
27	Family likelihood dan parameterisasi yang dikirim fastsae ke INLA. Sumber: R/hb_area.R:612–667 , R/hb_unit.R:274–282 , R/hb_twofold.R:278–287	60
28	Metode S3 utama beserta file sumbernya.	66
29	Pemakaian identitas Woodbury di dalam paket. Sumber: baris kode yang dikutip pada kolom terakhir.	67
30	Glosarium tiga arah: istilah — simbol — nama di kode.	70

1 Pendahuluan

1.1 Masalah estimasi area kecil

Banyak keputusan publik membutuhkan indikator pada unit geografis yang kecil: kabupaten, kecamatan, desa, sekolah, atau rumah sakit. Survei nasional yang dirancang untuk tingkat nasional atau provinsi biasanya menghasilkan sampel yang terlalu kecil pada unit-unit tersebut, sehingga *estimasi langsung* (*direct estimator*) menjadi tidak stabil atau bahkan tidak terdefinisi. Estimasi langsung

$$\hat{y}_d^{\text{dir}} = \frac{1}{n_d} \sum_{i \in s_d} y_{id}, \quad \text{Var}(\hat{y}_d^{\text{dir}}) = \psi_d = \frac{S_d^2}{n_d}, \quad (1)$$

hanya memakai informasi dari domain d itu sendiri; ketika n_d kecil, galat baku $\sqrt{\psi_d}$ melebihi toleransi keandalan yang lazim (misalnya kamufase RSE di atas 25%; lihat bagian 14.2). Beberapa domain bahkan tidak tersampel sama sekali ($n_d = 0$), dan (1) tidak terdefinisi di sana.

Estimasi berbasis model (*model-based estimation*) menyiasati hal tersebut dengan memodelkan domain kecil sebagai bagian dari satu himpunan data bersama. Informasi dari domain lain “dipinjamkan” melalui model, sehingga estimasi menjadi lebih halus (*shrinkage*) dan domain tanpa sampel tetap dapat diprediksi. Biayanya adalah asumsi model. Pendahuluan metode ini dalam literatur SAE dibahas oleh Pfeffermann [2013] dan Rao and Molina [2015].

1.2 Estimasi langsung, sintetis, dan EBLUP

Tiga kelas prediktor membedah literatur SAE [Rao and Molina, 2015]:

- (a) **Prediktor sintetis** memakai hanya kovariat domain: $\hat{\theta}_d^{\text{syn}} = \bar{x}_d' \hat{\beta}$. Kuat pada domain tanpa sampel, tetapi mengabaikan data domain itu sendiri bila ada.
- (b) **EBLUP** (*empirical best linear unbiased predictor*) menggabungkan kovariat dan data domain melalui model campuran linear: $\hat{\theta}_d = x_d' \hat{\beta} + \hat{u}_d$. Perkiraan komponen varians σ^2 dari data membuatnya “empiris”. Model Fay–Herriot [Fay and Herriot, 1979] adalah contoh kanoniknya.
- (c) **EBP** (*empirical best predictor*) dan pendekatan Bayes memperluas gagasan yang sama ke indikator non-Gaussian (rasio, proporsi, jumlah) dan ke pemodelan penuh atas komponen varians [Molina and Rao, 2010, Molina and Marhuenda, 2015].

1.3 Apa yang ditawarkan fastsae

`fastsae` v1.0.0 (deskripsi diambil dari DESCRIPTION) adalah paket R untuk estimasi area kecil yang membagi dua jalur: model frekuentis EBLUP yang dikompilasi ke C++ lewat Rcpp/RcppArmadillo, dan model Bayes hierarki yang diserahkan ke INLA. Tabel 1 meringkas fungsi yang diekspor (daftar lengkap menurut NAMESPACE; peta file, metode estimasi, dan metode MSE ada di CODE_MAP.md).

Empat pilar yang membedakan paket ini, semuanya terverifikasi dari kode:

1. **Inti numerik di C++/Armadillo.** Fisher scoring untuk model area-level, sub-area, spasial, dan spatio-temporal ditulis dalam `src/*.cpp` (bagian 2).

Tabel 1: Fungsi yang diekspor `fastsae` dan perannya. Sumber: `NAMESPACE` dan kode masing-masing fungsi di R/.

Fungsi	Jenis	Peran
<code>eblup_fh</code>	frekuentis	Fay–Herriot area-level
<code>eblup_sfh</code>	frekuentis	Fay–Herriot spasial (SAR/error-components)
<code>eblup_stfh</code>	frekuentis	Fay–Herriot spasio-temporal
<code>eblup_bhf</code>	frekuentis	Battese–Harter–Fuller unit-level
<code>eblup_twofold</code> (alias <code>eblup_tfh</code>)	frekuentis	model sub-area <i>two-fold</i>
<code>hb_area</code>	Bayes	hierarki Bayes area-level, 6 family likelihood
<code>hb_unit</code>	Bayes	hierarki Bayes unit-level
<code>hb_twofold</code> (alias <code>hb_tfh</code>)	Bayes	hierarki Bayes sub-area
<code>benchmark</code> , <code>benchmark_sae</code>	utilitas	kalibrasi ke agregat target
<code>diagnose</code>	utilitas	uji kecocokan, uji bias, Moran’s I, flag keandalan
<code>compare_sae</code>	utilitas	perbandingan dua model
<code>export_sae</code> , <code>map_sae</code>	utilitas	ekspor tabel dan peta choropleth
<code>sim_spatial_weights</code> , <code>sim_area_data</code> , <code>sim_series_data</code>	utilitas	pembangkit data dan matriks tetangga
<code>add_reliability_flags</code>	utilitas	flag RSE
<code>autoplot</code> (S3)	utilitas	grafik model, benchmark, diagnosis

2. **Bootstrap paralel OpenMP.** Empat berkas sumber memakai `#pragma omp parallel for` (`eblup_tfh.cpp`:481, `eblup_sfh_pbmse.cpp`:108, `eblup_sfh_npbmse.cpp`:159, `eblup_stfh_pbmse.cpp`:352).
3. **Lapisan INLA untuk model Bayes.** Enam family likelihood (Gaussian, Beta, Binomial, Poisson, Negative Binomial, Gamma), enam struktur spasial, lima struktur temporal, dan interaksi spatio-temporal (bagian 13).
4. **Domain tanpa sampel ditangani eksplisit** di setiap fungsi model: FH memprediksi $x'_{ns}\hat{\beta}$, BHF menghasilkan prediktor sintesis, dan `hb_unit()` menambahkan baris `y = NA` per domain (lihat tiap bagian model).

1.4 Arsitektur paket

Secara arsitektur `fastsae` terdiri atas lima lapis:

1. **Lapis pemanggilan R** — parsing formula, validasi argumen, pembangunan `model.frame`/`model.matrix`, pelabelan domain, dan perakitan objek keluaran berkelas S3. Semua file berada di R/ mengikuti urutan *Collate* pada `DESCRIPTION`.
2. **Lapis C++** — delapan berkas `src/*.cpp` yang mengekspor delapan fungsi Rcpp (Tabel 2); semua dikompilasi dengan `CXX17` dan tautan LAPACK/BLAS serta OpenMP melalui `src/Makevars`.
3. **Lapis INLA** — `R/inla_utils.R` merangkai formula `f(...)` dan mengekstrak hasil; tidak diekspor (semua `@noRd`).
4. **Lapis lme4** — hanya untuk BHF dan jalur `glmm hb_area()`.

5. **Metode S3** — kelas `fastsae` beserta turunannya (`fastsae_unit`, `fastsae_hb*`, `fastsae_diagnose`, `fastsae_benchmark`, `fastsae_comparison`) memiliki method `print`, `summary`, `plot`, `autoplot`, `coef`, `fitted`, `residuals`.

Tabel 2: Fungsi Rcpp dan OpenMP. Sumber: `src/RcppExports.cpp`, `src/Makevars`, dan `grep #pragma omp` pada `src/*.cpp`.

Berkas sumber	Fungsi Rcpp	OpenMP
<code>eblup_fh.cpp</code>	<code>.eblup_core</code>	—
<code>eblup_unit.cpp</code>	<code>.eblup_bhf_cpp</code>	—
<code>eblup_tfh.cpp</code>	<code>.eblup_tfh_core</code>	baris 481
<code>eblup_sfh_core.cpp</code>	<code>.seblup_core</code>	—
<code>eblup_sfh_pbmse.cpp</code>	<code>.seblup_pbmse</code>	baris 108
<code>eblup_sfh_npbmse.cpp</code>	<code>.seblup_npbmse</code>	baris 159
<code>eblup_stfh_core.cpp</code>	<code>.eblup_stfh_core</code>	—
<code>eblup_stfh_pbmse.cpp</code>	<code>.pbmse_stfh</code>	baris 352

1.5 Instalasi, termasuk INLA

Paket berada di CRAN dan dapat dipasang bersama versi pengembangannya (petunjuk di `README.Rmd:131–154`):

Listing 1: Perintah instalasi sebagaimana terdokumentasi di `README.Rmd`.

```
install.packages("fastsae")           # rilis stabil
# install.packages("remotes")
remotes::install_github("ridsonap/fastvae") # versi pengembang

# model Bayes memerlukan INLA (tidak ada di CRAN)
install.packages("INLA",
  repos = c(getOption("repos"),
    INLA = "https://inla.r-inla-download.org/R/stable"),
  dep = TRUE)
```

Repo INLA pada baris terakhir identik dengan `Additional_repositories` di `DESCRIPTION`. INLA berada pada `Suggests`, sehingga fungsi frekuentis tetap dapat dipakai tanpanya; `hb_area()` memeriksanya lebih dulu melalui `.check_inla_installed()` (`R/inla_utils.R:8–15`) dan melempar `cli_abort` dengan instruksi repo bila tidak ada.

1.6 Struktur repositori dan cara membaca laporan ini

Listing 2: Struktur repositori (pilihan relevan).

```
R/          22 berkas R      : lapis pemanggilan, utilitas, data
src/        9 berkas C++    : inti numerik + RcppExports
man/        38 berkas Rd     : dokumentasi (sumber sitasi roxygen)
vignettes/  7 Rmd          : pengantar, benchmark, diagnosis, model Bayes
tests/      testthat       : 1.063 tes lulus (lihat bagian 8.3)
inst/extdata/ 9 file .rds    : hasil benchmark (satu-satunya sumber angka)
benchmarks/ 11 skrip       : pembangkit hasil benchmark
```

Laporan ini disusun agar setiap klaim dapat ditelusuri: nomor baris dalam teks mengacu ke berkas sumber, seluruh angka berasal dari `inst/extdata/*.rds` lewat skrip di `scripts/`, dan seluruh perbedaan antara kode dan rumus publik dikumpulkan di `DISCREPANCIES.md`. Referensi

dikutip dengan penulis-tahun (natbib) dan hanya entri yang lolos verifikasi DOI yang masuk ke `references.bib` (lihat `TODO_REFERENCES.md` untuk yang tidak lolos).

Referensi utama pendahuluan: [Fay and Herriot \[1979\]](#) untuk model area-level, [Rao and Molina \[2015\]](#) untuk kerangka umum, [Pfeffermann \[2013\]](#) untuk perkembangan mutakhir, [Rue et al. \[2009\]](#) untuk INLA, serta tiga paket pembandingan pada benchmark: `sae` [[Molina and Marhuenda, 2015](#)], `emdi` [[Kreutzmann et al., 2019](#)], dan `tipsae` [[De Nicolò and Gardini, 2024](#)].

2 Desain perangkat lunak

Bagian ini menjelaskan apa yang sebenarnya dilakukan inti kode: bagian mana yang berjalan di C++, identitas matriks mana yang dipakai, bagaimana memori diatur, dan bagaimana bootstrap diparalelkan. Rumus statistik yang muncul di sini dibahas lebih rinci pada bagian 4 dan tiap bagian model.

2.1 Pembagian kerja R dan C++

Prinsipnya: R menangani *parsing* dan *perakitan*, C++ menangani *iterasi numerik*. Tabel 3 memberi pembagian persisnya.

Tabel 3: Pembagian kerja lapis R dan lapis C++ per fungsi model. Sumber: pemanggilan `.eblup_core/.seblup_core/.eblup_stfh_core/.eblup_tfh_core/.eblup_bhf_cpp` beserta berkas pemanggilnya.

Fungsi	Di R	Di C++
<code>eblup_fh</code>	<code>model.frame(na.pass)</code> , validasi <code>vardir</code> , pelabelan <code>domain</code> , kelas	pemisahan sampel/tak-sampel, Fisher scoring, EBLUP, MSE $g_1 g_2 g_3$, loglik
<code>eblup_sfh</code>	identik + subset area tersampel untuk bootstrap	Fisher scoring 2-parameter, MSE $g_1 \dots g_4$, kriging, bootstrap
<code>eblup_stfh</code>	validasi panel lengkap ($n = D \times T$), W , nilai awal	Fisher scoring 4-parameter, inversi Woodbury, EBLUP, bootstrap
<code>eblup_twofold</code>	pembuatan area 0-based, <code>set.seed</code>	Fisher scoring 2-parameter per blok, MSE analitik, bootstrap
<code>eblup_bhf</code>	<code>lme4::lmer</code> ($\hat{\beta}, \hat{\sigma}_u^2, \hat{\sigma}_e^2, \hat{u}$), bootstrap	penyusunan prediktor per domain (f_d , rata-rata sampel/populasi)
<code>hb_*</code>	seluruhnya: merangkai formula INLA, prior, kontrol, ekstraksi hasil	— (INLA sendiri adalah biner eksternal)

Konsekuensinya, model Bayes tidak memakai C++ buatan paket sama sekali: seluruh pekerjaan numerik berada di dalam INLA, sedangkan paket hanya merangkai formula dan membaca `summary.*` (bagian 13).

2.2 Struktur iterasi: Fisher scoring

Semua model frekuentis non-linear dalam komponen varians memakai algoritme yang sama: *Fisher scoring* atas vektor parameter komponen varians θ . Pola yang sama berulang di empat inti C++ (lihat bagian 4 untuk turunannya):

1. hitung $\mathbf{V}(\theta)$, $\mathbf{V}^{-1}$, dan $\mathbf{Q} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}$;
2. hitung skor $s(\theta)$ dan informasi Fisher $\mathcal{I}(\theta)$;

3. update Newton–Fisher $\theta^{(k+1)} = \theta^{(k)} + \mathcal{I}^{-1}s$ — dua parameter memakai inversi matriks 2×2 penuh, satu parameter memakai pembagian skalar;
4. uji batas (*boundary*) dan kriteria konvergensi;
5. pass akhir: hitung ulang $\mathbf{Q}, \hat{\beta}$, galat baku, prediktor, dan MSE pada $\hat{\theta}$ setelah update terakhir.

Tabel 4 merangkum pengaturan iterasi tiap inti. Semua nilai baca dari kode, bukan dari dokumentasi.

Tabel 4: Pengaturan iterasi pada empat inti Fisher scoring. Sumber: baris kode pada kolom terakhir.

Inti	Parameter	Nilai awal	Toleransi	Penanganan batas
<code>.eblup_core</code>	σ^2	$\max(\text{median}(\psi), 0)$	relatif $ \Delta\sigma^2 / \max(\sigma^2, 10^{-12}) \leq 10^{-4}$, <code>maxiter</code> = 100	update non-finite/negatif dipaksa 0
<code>.eblup_tfh_core</code>	(σ_v^2, σ_u^2)	0.5 median(ψ) keduanya	maksimum selisih relatif per parameter $\leq 10^{-4}$, <code>maxiter</code> = 100	negatif $\rightarrow 0$; informasi singular $\rightarrow$ fallback skor diagonal
<code>.seblup_core</code>	(σ_u^2, ρ)	median(ψ), 0.5	$\max \Delta\theta / (\theta + 10^{-12}) \leq 10^{-4}$	ρ di-clamp ± 0.999 ; $\sigma^2 \geq 0$ hanya pada hasil akhir
<code>.eblup_stfh_core</code>	$(\sigma_1^2, \rho_1, \sigma_2^2, \rho_2)$	0.5 median(ψ) dan 0.5	relatif $\leq 10^{-4}$	$\rho_{1,2}$ di-clamp ± 0.999 ; $\sigma^2 \geq 0$ pada hasil akhir

Dua hal patut dicatat. *Pertama*, pada `.seblup_core` hasil akhir memetakan $\rho = \pm 0.999$ menjadi ± 1.0 persis (`eblup_sfh_core.cpp:389–391`) tempat $\mathbf{V}$ menjadi singular, sehingga inversi jatuh ke `pinv` — perilaku yang berbeda dengan jalur bootstrap yang mempertahankan ± 0.999 (lihat SFH-4 di `DISCREPANCIES.md`). *Kedua*, `eblup_stfh` selalu memakai REML: `method` di-hardcode "REML" di `R/eblup_stfh.R:225`.

2.3 Identitas matriks: di mana Woodbury dipakai

Dua dari empat inti memakai identitas Woodbury/Sherman–Morrison untuk menurunkan biaya inversi; dua inti tidak.

Two-fold (per blok, Sherman–Morrison). Untuk tiap area d dengan n_d sub-area, kovarians $\mathbf{V}_d = \sigma_v^2 \mathbf{1}\mathbf{1}' + \text{diag}(\sigma_u^2 + \psi_d)$. Karena suku rangsang ber-rangka-1, inversi dilakukan lewat

$$\mathbf{V}_d^{-1}a = \text{dd} \odot a - c \text{dd} (\text{dd}'a), \quad \text{dd} = \frac{1}{\sigma_u^2 + \psi_d}, \quad c = \frac{\sigma_v^2}{1 + \sigma_v^2 \sum_j \text{dd}_j}, \quad (2)$$

persis kode `eblup_tfh.cpp:98–108` dan `:345–350`. Biaya per blok $O(n_d)$, bukan $O(n_d^3)$.

Spasio-temporal (Woodbury penuh). Pada `eblup_stfh_core.cpp:139–153` terdapat pola

$$\mathbf{C} = \Omega_1^{-1}/\sigma_1^2 + \text{diag}(Z_1' \mathbf{V}_A^{-1} Z_1), \quad (3)$$

$$\mathbf{V}^{-1} = \mathbf{V}_A^{-1} - \mathbf{V}_A^{-1} Z_1 \mathbf{C}^{-1} Z_1' \mathbf{V}_A^{-1}, \quad (4)$$

dengan $\mathbf{V}_A$ blok-diagonal per domain. Inversi $\mathbf{V}_A$ hanya $T \times T$ per domain ($O(DT^3)$) dan inversi $\mathbf{C}$ hanya $D \times D$ ($O(D^3)$), alih-alih $O((DT)^3)$. Log-determinan juga memakai rantai yang setara (eblup_stfh_core.cpp:456-471): $\log |\mathbf{V}| = \log |\mathbf{V}_A| + \log |\sigma_1^2 \Omega_1| + \log |\mathbf{C}|$. Catatan: memori tetap $O(M^2)$ karena $\mathbf{V}_A^{-1}$, $\mathbf{V}^{-1}$, dan matriks turunan disimpan penuh — yang diturunkan adalah *biaya inversi*, bukan ordo memori.

Yang tidak memakai Woodbury. .seblup_core melakukan `inv_sympd(Vi, V)` dan `inv_sympd(derSigma, A)` per iterasi: $O(m^3)$ per iterasi dengan sekitar sembilan matriks $m \times m$ yang dialokasikan di luar loop (eblup_sfth_core.cpp:294-298). .eblup_core (FH) bekerja pada skalar per-observasi: $w_d = 1/(\psi_d + \sigma^2)$ dan matriks $\mathbf{Q}$ hanya $p \times p$, sehingga tidak membutuhkan identitas apa pun. Implikasi terhadap skala dibahas pada bagian 3.

2.4 Strategi memori

Tiga kebiasaan kode menjelaskan mengapa jejak memori `fastsae` kecil:

1. **Alokasi di luar loop.** eblup_sfth_core.cpp:279-284 menghitung W' , $\mathbf{I}$, $W'W$, $W + W'$ sekali sebelum iterasi; eblup_stfh_core.cpp:90-123 membangun $\mathbf{V}_A^{-1}$ per blok sekali per iterasi, bukan per parameter.
2. **Hanya matriks yang dibutuhkan.** FH tidak pernah membuat matriks $m \times m$ sama sekali (hanya w , Py , dan $\mathbf{Q}$ $p \times p$).
3. **Bootstrap menulis per-kolom.** Replikat disimpan pada matriks $N \times B$ (dua-fold) atau lewat akumulator kuadrat (SFH/STFH), bukan menyimpan seluruh hasil per replikat (eblup_tfh.cpp:479, eblup_sfth_pbmse.cpp).

Bandingkan `sae`, yang pada benchmark membangun matriks penuh per iterasi untuk masalah $n = 1000$ (Tabel 14 dan Tabel 18).

2.5 Bootstrap paralel

Empat berkas memuat `Rcpp::plugins(openmp)` dan memanggil `omp_set_num_threads` bila argumen `n_threads` diberikan (eblup_sfth_pbmse.cpp:73-75, eblup_sfth_npbmse.cpp:125-127, eblup_stfh_pbmse.cpp:345-347); `n_threads <= 0` berarti memakai semua core. Skema umumnya sama di keempatnya:

Dua detail penting:

- **RNG dibangkitkan sebelum pragma** (eblup_sfth_pbmse.cpp:90-98, eblup_tfh.cpp:475-478) karena generator R tidak aman thread. Konsekuensinya hasil bootstrap *reproducible terlepas dari jumlah thread*, selama `seed` diberikan.
- **Jumlah thread** diatur lewat argumen `n_threads` (SFH/STFH) atau `OMP_NUM_THREADS` (dua-fold, yang tidak punya argumen itu). Tidak ada `omp_set_num_threads` pada eblup_tfh.cpp.

Perbedaan skema antar model nyata dan berpengaruh terhadap interpretasi: SFH memaksa tepat B replikat *valid* lewat skema batch (eblup_sfth_pbmse.cpp:77-88), STFH membagi dengan jumlah replikat valid sehingga efektifnya bisa $< B$ (eblup_stfh_pbmse.cpp:410-412), sedangkan BHF menghitung bootstrap di R secara serial dengan `n_threads` yang didokumentasikan tetapi tidak pernah dipakai (BHF-1 di DISCREPANCIES.md).

Algorithm 1: Akumulasi: $\widehat{\text{MSE}} = B^{-1} \sum_b (\hat{\theta}_b^* - \theta_b^*)^2$ versi bias-koreksi pada teks SFH.

```

1 Masukan data ( $\mathbf{X}, y, \psi, W$ ),  $B$ ,  $n\_threads$ , seed Keluaran vektor MSE per area
   Data distribusi RNG dibangkitkan sekuensial sebelum region paralel if  $seed \geq 0$  then
2    $\text{set.seed}(seed)$  ; // baris 29
3    $\hat{\theta} \leftarrow \text{seblup\_core}(\text{only\_core} = \text{TRUE})$ ;
4   for  $b = 1, \dots, B$  sekuensial do
5     bangkitkan  $u_b^* \sim N(0, \hat{\sigma}^2)$  dan  $e_b^* \sim N(0, \psi)$ ;
6      $v_b^* \leftarrow (\mathbf{I} - \hat{\rho}W)^{-1}u_b^*$ ;
7    $\# \text{pragma omp parallel for schedule(dynamic)}$ ;
8   for  $b = 1, \dots, B$  paralel do
9      $\theta_b^* = \mathbf{X}\hat{\beta} + v_b^*$ ;  $y_b^* = \theta_b^* + e_b^*$ ;
10    refit Fisher scoring penuh pada  $y_b^*$ ;
11    if tidak konvergen atau  $\hat{\sigma}^{2*} < 0$  atau tidak finite then
12       $\text{lewati replikat (masuk hitungan anggaran percobaan)}$ 
13    kembalikan  $(\hat{\theta}_b^* - \theta_b^*)^2$ 

```

2.6 Objek keluaran dan kelas S3

Semua fungsi model mengembalikan `list` berkelas `fastsae` (atau turunannya) dengan elemen inti yang seragam: `estcoef`, `df_eblup`, `random_effect_var`, `goodness`, `n_iter`, `convergence`, `formula`, `model`, `call`, `data`. Tabel 5 mencatat variasinya.

Tabel 5: Kelas dan elemen khusus objek keluaran. Sumber: kode perakitan output masing-masing fungsi.

Fungsi	class()	Elemen khusus
<code>eblup_fh</code>	<code>fastsae</code>	<code>goodness</code> (loglik ML, AIC, BIC)
<code>eblup_sfh</code>	<code>fastsae</code>	<code>rho</code> , <code>estvarcomp</code> , <code>W</code>
<code>eblup_stfh</code>	<code>fastsae</code>	<code>estvarcomp</code> 4 baris; <code>mse/rse</code> = NA bila <code>compute_mse</code> = FALSE
<code>eblup_bhf</code>	<code>fastsae</code> , <code>fastsae_unit</code>	<code>fit</code> (objek <code>lmer</code>), <code>samp_size</code> ; tanpa <code>goodness</code>
<code>eblup_twofold</code>	<code>fastsae</code>	<code>level</code> = "subarea", <code>sigma2_v/sigma2_u</code>
<code>hb_area</code>	<code>fastsae_hb_area</code> , <code>fastsae</code>	<code>fit</code> (objek <code>inla</code>), <code>hyperpar</code> , <code>phi/rho</code>
<code>hb_unit</code> , <code>hb_twofold</code>	<code>fastsae_hb*</code> , <code>fastsae_hb</code> , <code>fastsae</code>	<code>goodness</code> berupa <code>list</code> (DIC, WAIC, marginal likelihood)

Metode `print/summary` (bagian 14) memakai elemen ini; karena itu perbedaan kecil di atas (misalnya `hb_area` tanpa kelas `fastsae_hb`, HB-16) berdampak pada perilaku turunan.

2.7 Ringkasan desain

- Inti numerik ada di delapan fungsi C++; model Bayes diserahkan ke INLA tanpa kode C++ tambahan.
- Woodbury dipakai dua kali (dua-fold per blok, spasio-temporal penuh); spatial FH justru memilih inversi simetris-positif-definitleh penuh per iterasi — konsekuensi pemilihan model SAR (butir 3).

- Bootstrap diparalelkan dengan OpenMP pada empat titik; RNG dibangkitkan sekuensial agar hasil tidak bergantung thread.
- Kriteria konvergensi seragam (10^{-4} , 100 iterasi) tetapi penanganan batas berbeda antar model dan dicatat sebagai temuan.

3 Benchmark

Seluruh angka pada bagian ini dihitung ulang oleh `scripts/01_tables.R` dan `scripts/02_figures.R` langsung dari sembilan berkas `inst/extdata/*.rds`. Tidak ada angka yang diketik tangan, dan setiap tabel/figur mencantumkan file sumbernya pada caption. Bila klaim di `README.Rmd` atau vignette bertolak belakang dengan file data, laporan ini memakai data dan mencatat kontradiksinya pada bagian 3.7 (daftar lengkap: `DISCREPANCIES.md` bagian H).

3.1 Metodologi

Apa yang diukur. Semua file benchmark berformat sama: kolom `Method`, `Min (s)`, `Median (s)`, `Iterations/sec`, `Memory (MB)`, `n_iter`, `n`. Dua kolom waktu berasal dari `bench::mark()$min` dan `$median`; `Memory (MB) = as.numeric(res$mem_alloc)/1024^2`, yaitu *total alokasi memori selama run*, bukan puncak RSS (lihat `benchmarks/bench_beta_tipsae.R:92-98`). `n_iter` mencatat jumlah iterasi aktual yang benar-benar dijalankan.

Skrip, pembandingan, ukuran, iterasi, seed. Tabel 6 disusun dari pembacaan langsung 11 skrip di `benchmarks/`.

Apa yang tidak tercatat. Model CPU, jumlah inti, RAM, sistem operasi, tanggal run, versi R pada saat run, dan versi paket pembandingan *tidak ada* di dalam file `.rds`. Satu-satunya pernyataan hardware di repo adalah `paper/article.tex:277` (“Apple Silicon processor under R 4.4.2”). Tidak ada skrip yang mengatur `OMP_NUM_THREADS`; `README.Rmd:126` hanya menulis bahwa “timings depend on hardware and the number of threads”. Empat file (`eblup_benchmark.rds`, `seblup_benchmark.rds`, `stebup_benchmark.rds`, `beta_estimates_n1000.rds`) *tidak punya skrip pembuat* di repo mana pun (terverifikasi dengan `git log -S`); karenanya hasilnya tidak dapat direproduksi dari repo.

Keadilan perbandingan. Pada skrip yang ada, kedua metode menerima *data simulasi yang sama* (`sim_area_data(D = n_val, seed = 42 + n_val)`), formula yang sama, dan kolom `vardir` yang sama; `bench::mark(..., check = FALSE, filter_gc = FALSE, memory = TRUE, time_unit = "s")`. Perbedaan yang tetap ada dan harus dibaca sebagai *caveat*:

- `tipsae` dijalankan sebagai pemanggilan MCMC/Stan dengan `seed = 42` dan `refresh = 0`, sedangkan `fastsae` memakai aproksimasi Laplace INLA — dua algoritme yang berbeda secara mendasar, bukan dua implementasi algoritme yang sama.
- `hbsae::fSAE.Area` adalah pemanggilan langsung tanpa penyetelan iterasi; `fastsae::hb_area` memakai default `strategy = "laplace"`.

Tabel 6: Skrip benchmark: pembandingan, ukuran masalah, iterasi, dan seed. Sumber: pembacaan `benchmarks/*.R` (lihat `_notes/bench_methodology.md`).

Skrip	Pembandingan (dari kode)	n	Iterasi / seed
<code>bench_beta_tipsae.R</code>	<code>fastsae::hb_area</code> vs <code>tipsae::fit_sae</code>	250, 500	20; data <code>seed = 42+n</code> ; <code>tipsae seed = 42</code>
<code>bench_spatial_beta.R</code>	<code>fastsae</code> vs <code>tipsae</code> (+ <code>sf</code> , <code>spdep</code>)	30, 50, 100	20; data <code>42+n</code>
<code>bench_spatio_temporal_beta.R</code>	<code>fastsae</code> vs <code>tipsae</code> ($T = 5$)	30–1000	5; data <code>42+n</code>
<code>bench_hb_normal.R</code>	<code>fastsae::hb_area</code> vs <code>hbsae::fSAE.Area</code>	30, 50, 100, 250	10; data <code>42+n</code>
<code>update_hb_benchmark.R</code>	<code>fastsae</code> vs <code>hbsae</code>	500, 1000	10; data <code>42+n</code>
<code>run_hb_area_full_benchmark.R</code>	<code>fastsae</code> vs <code>fastsaehb</code> vs <code>tipsae</code> (Stan HMC)	skenario tunggal	<code>set.seed(123/42)</code> ; tidak menulis file
<code>run_multipackage_hb_benchmark.R</code>	<code>fastsae</code> vs <code>hbsae</code> , CARBayes, <code>fastsaehb</code> , <code>tipsae</code>	—	5 iterasi; tidak menulis file
<code>compare_ebp_tipsae_truth.R</code> , <code>sim_finite_population_beta.R</code> , <code>sim_mc_finite_population.R</code> , <code>sim_mc_finite_pop_d500.R</code>	<code>fastsae</code> vs <code>tipsae</code> vs estimasi langsung (akurasi terhadap kebenaran model)	$D = 60/500$	$R = 100$ (seed 2024) dan $R = 25$ (seed 999); <code>mclapply</code> 5–6 core

- Untuk tiga file pertama (`eblup`, `seblup`, `stebup`) skrip pembuatnya tidak ada, sehingga kesetaraan pengaturan awal, kriteria konvergensi, dan jumlah thread tidak dapat diverifikasi dari repo.
- Beberapa `n_iter` aktual berbeda dari nilai yang diminta (lihat kolom `n_iter` di file), tanda run besar memakai argumen `-iter` yang tidak tercatat di file mana pun.

3.2 Waktu komputasi

Tabel 7–9 memuat waktu median per iterasi untuk tiga keluarga Fay–Herriot frekuentis; Tabel 10 sampai Tabel 13 untuk model beta dan model hierarki Bayes. Pembandingnya: `sae` dan `emdi` untuk FH, `tipsae` untuk beta, `hbsae` untuk Bayes Gaussian.

Perlu ditegaskan apa yang dimaksud “keluarga beta” di sini: `fastsae` tidak mengekspor fungsi khusus beta — yang dijalankan adalah `fastsae::hb_area` dengan `family = "beta"`, sedangkan pembandingnya `tipsae::fit_sae` (`benchmarks/bench_beta_tipsae.R`:9–10). Rumus regresi beta yang mendasari pembandingan itu dibahas Ferrari and Cribari-Neto [2004] dan Janicki [2020], perluasannya ke SAE area-level oleh Esteban et al. [2019] dan ke campuran beta oleh De Nicolò et al. [2024]; rujukan paketnya De Nicolò and Gardini [2024].

Tiga pengamatan yang terbaca langsung dari tabel:

1. Pada masalah kecil ($n = 30$) selisih antar paket kecil bahkan untuk FH, sebab biaya tetap (parsing, pembangunan matriks desain) masih dominan.
2. Pada FH area-level, waktu pembandingan tumbuh jauh lebih cepat daripada `fastsae` seiring n ; pada n terbesar pada file, `emdi` membutuhkan waktu dua orde magnitudo lebih besar.

Tabel 7: Waktu median per iterasi (detik) menurut jumlah area n . Sumber: file `eblup_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	fastsae	emdi	sae
30	0.000588063	0.0108802	0.00155167
50	0.000510983	0.0180643	0.0019507
100	0.00055022	0.0505076	0.00344267
250	0.000899663	0.857347	0.037575
500	0.00140398	5.86366	0.196726
1000	0.00413358	51.0224	1.50363

Tabel 8: Waktu median per iterasi (detik) menurut jumlah area n . Sumber: file `seblup_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	fastsae	emdi	sae
30	0.000734618	0.0107105	0.00410111
50	0.00114812	0.0180005	0.00967977
100	0.00472576	0.05299	0.0705356
250	0.0238317	0.843782	1.07476
500	0.142051	3.13662	7.11793
1000	0.832158	51.0593	67.1518

Tabel 9: Waktu median per iterasi (detik) menurut jumlah area n . Model spasio-temporal dengan T periode waktu; waktu termasuk estimasi komponen varian. Sumber: file `steblup_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	fastsae	sae
30	0.0367356	0.118558
50	0.0898305	0.420018
100	2.29928	17.9425
250	3.81651	58.4315
500	10.3596	253.343
1000	58.1005	1786.49

Tabel 10: Waktu median per iterasi (detik) menurut jumlah area n . Model area-level beta (`fastsae::hb_area` vs `tipsae::fit_sae`). Sumber: file `beta_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	fastsae	tipsae
30	1.24489	2.34867
50	1.33152	3.77451
100	1.27232	8.23587
250	1.31454	26.2762
500	1.41239	64.2141
1000	1.63967	187.162

Tabel 11: Waktu median per iterasi (detik) menurut jumlah area n . Model area-level beta dengan efek spasial. Sumber: file `spatial_beta_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	fastsae	tipsae
30	0.613834	25.7233
50	0.620765	65.7235
100	1.37316	100.02
250	1.31548	155.898
500	1.43413	248.821
1000	1.72812	404.342

Tabel 12: Waktu median per iterasi (detik) menurut jumlah area n . Model beta spasio-temporal ($T = 5$); data tersedia hanya untuk $n = 30$ dan $n = 50$. Sumber: file `spatio_temporal_beta_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	fastsae	tipsae
30	1.44206	540.573
50	1.66767	908.173

Tabel 13: Waktu median per iterasi (detik) menurut jumlah area n . Model hierarki Bayes area-level Gaussian (`hb_area`) vs `hbsae::fSAE.Area`. Sumber: file `hb_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	fastsae	hbsae
30	1.29238	0.0209383
50	1.28063	0.0255576
100	1.2507	0.0373128
250	1.22658	0.0744251
500	1.25466	0.143842
1000	1.27669	0.271585

3. Pada model Bayes Gaussian justru `hbsae` yang lebih cepat di seluruh n pada file — tidak ada pembandingan lain pada skenario ini, dan temuan ini dibahas pada bagian 3.6.

3.3 Penggunaan memori

Tabel 14: Alokasi memori total per iterasi (MB) menurut jumlah area n . Sumber: file `eblup_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	<code>fastsae</code>	<code>emdi</code>	<code>sae</code>
30	0.00506592	4.18307	0.153381
50	0.00884247	10.4676	0.373138
100	0.0162811	37.3394	0.917542
250	0.0385971	240.893	6.34988
500	0.0757904	880.314	18.2391
1000	0.185699	3773.6	71.9765

Tabel 15: Alokasi memori total per iterasi (MB) menurut jumlah area n . Sumber: file `seblup_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	<code>fastsae</code>	<code>emdi</code>	<code>sae</code>
30	0.029808	4.18307	1.37314
50	0.0737839	10.4676	3.31219
100	0.258606	37.3394	17.9755
250	1.49972	240.893	110.388
500	5.85706	949.864	776.407
1000	23.1548	3772.57	1920.01

Tabel 16: Alokasi memori total per iterasi (MB) menurut jumlah area n . Sumber: file `steb lup_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.

n	<code>fastsae</code>	<code>sae</code>
30	0.0274048	43.8007
50	0.0466537	107.829
100	0.0901871	2551.1
250	0.225403	3624.71
500	0.448158	8124.37
1000	0.893669	32478.3

Kolom Memory (MB) adalah total alokasi selama run (bagian 3.1), sehingga angkanya lebih besar daripada puncak RSS yang dilaporkan `bench::mark()` sebagai `mem_usage`. Klaim `README.Rmd:124` (“< 10 MB” untuk `fastsae`) dan label “Peak Memory” terbantahkan oleh file data pada beberapa baris; rinciannya di bagian 3.7.

3.4 Skala terhadap jumlah area


Gambar 1 dan Gambar 2 menampilkan waktu median terhadap n pada skala log–log untuk seluruh keluarga model; Gambar 3 menampilkan memori; Gambar 4 merangkum rasio waktu pembandingan/tes terhadap n .

Tabel 17: Alokasi memori total per iterasi (MB) menurut jumlah area n . Model hierarki Bayes area-level Gaussian. Sumber: file `hb_benchmark.rds` di `inst/extdata` (repo `fastsae`); angka dihitung ulang oleh `scripts/01_tables.R`, ditampilkan hingga 6 digit signifikan.


n	fastsae	hbsae
30	46.7163	5.93539
50	2.40248	5.8022
100	3.59152	12.3786
250	7.15878	45.3857
500	57.7934	112.206
1000	25.0034	220.352

Tabel 18: Ringkasan alokasi memori total per iterasi (MB): rerata, minimum dan maksimum lintas seluruh n pada tiap file sumber. Kolom “maks” adalah nilai pada n terbesar pada file tersebut.


File	Metode	Rerata	Min	Maks
eblup	fastsae	0.0550461	0.00506592	0.185699
eblup	emdi	824.466	4.18307	3773.6
eblup	sae	16.3349	0.153381	71.9765
seblup	fastsae	5.14563	0.029808	23.1548
seblup	emdi	835.886	4.18307	3772.57
seblup	sae	471.577	1.37314	1920.01
steblop	fastsae	0.288579	0.0274048	0.893669
steblop	sae	7821.69	43.8007	32478.3
beta	fastsae	81.0359	2.59546	133.585
beta	tipsae	5860.87	499.97	18335.2
spatial_beta	fastsae	70.6704	3.36058	161.025
spatial_beta	tipsae	7366.18	642.835	23038.7
spatio_temporal_beta	fastsae	105.869	102.73	109.008
spatio_temporal_beta	tipsae	3913.6	2947.08	4880.13
hb	fastsae	23.7777	2.40248	57.7934
hb	hbsae	67.01	5.8022	220.352




Gambar 1: Waktu median per iterasi terhadap jumlah area n (skala log pada kedua sumbu). Sumber: `inst/extdata/eb lup_benchmark.rds`, `seblup_benchmark.rds`, `steb lup_benchmark.rds`, `hb_benchmark.rds`; digambar oleh `scripts/02_figures.R`.



Gambar 2: Waktu median untuk tiga varian model beta (skala log-log). Sumber: `inst/extdata/beta_benchmark.rds`, `spatial_beta_benchmark.rds`, `spatio_temporal_beta_benchmark.rds`; `scripts/02_figures.R`. Panel (c) hanya memiliki $n = 30$ dan $n = 50$.



Gambar 3: Alokasi memori total per iterasi terhadap n (skala log-log). Sumber: file `inst/extdata/*_benchmark.rds` sebagaimana tercantum pada tiap panel; `scripts/02_figures.R`.



Gambar 4: Rasio waktu (pembanding/tes) terhadap n ; garis putus-putus menandai rasio = 1. Sumber: file `inst/extdata/*_benchmark.rds`; `scripts/02_figures.R`.

Tabel 19 merangkum seluruh rasio per n . Rentangnya jauh lebih lebar daripada klaim di README.Rmd: pada ujung bawah ada skenario tempat pembanding lebih cepat dari **fastsae**, dan pada ujung atas rasio mencapai empat orde magnitudo — karenanya laporan memilih menampilkan rentang, bukan satu angka tunggal.

Tabel 19: Rasio kecepatan = median waktu pembanding / median waktu **fastsae** (semakin besar semakin cepat **fastsae**; nilai < 1 berarti pembanding lebih cepat). Rasio dihitung per n lalu diringkas.

Model	Pembanding	n pertama	n terbesar	min	max
FH area-level (eblup_fh)	emdi	18.5018	12343.4	18.5018	12343.4
FH area-level (eblup_fh)	sae	2.6386	363.76	2.6386	363.76
FH spasial (eblup_sfh)	emdi	14.5797	61.3577	11.213	61.3577
FH spasial (eblup_sfh)	sae	5.58264	80.696	5.58264	80.696
FH spasio-temporal (eblup_stfh)	sae	3.22733	30.7484	3.22733	30.7484
Beta area-level (hb_area)	tipsae	1.88664	114.146	1.88664	114.146
Beta spasial	tipsae	41.906	233.978	41.906	233.978
Beta spasio-temporal	tipsae	374.863	544.576	374.863	544.576
Hierarki Bayes Gaussian	hbsae	0.0162013	0.212725	0.0162013	0.212725


3.5 Ekuivalensi numerik terhadap pembanding

File `beta_estimates_n1000.rds` memuat pasangan estimasi dan MSE untuk 1000 area antara **fastsae** dan **tipsae** pada model beta yang sama. Tabel 20 menghitung metrik kesesuaian dari pasangan kolom itu; Gambar 5 menampilkannya secara grafis.

Tabel 20: Ekuivalensi numerik antara **fastsae** dan **tipsae** pada $n = 1000$ area (indikator beta). Semua metrik dihitung dari pasangan kolom pada file sumber.

Metrik	Nilai
Pearson r (estimasi)	0.999343
Spearman ρ (estimasi)	0.999208
MAE (estimasi)	0.0196916
RMSD (estimasi)	0.0236901
Galat absolut maksimum	0.0558335
Pearson r (MSE)	0.963148
Median selisih mutlak MSE	0.000171686
Median rasio MSE fastsae / tipsae	2.21687

Kedua paket memprediksi indikator yang sama dengan selisih kecil pada prediktor (korelasi sangat tinggi; Tabel 20), sedangkan MSE berbeda lebih nyata karena kedua paket memakai pendekatan ketidakpastian yang berbeda (INLA Laplace vs posterior MCMC). Angka MSE tidak boleh dibaca sebagai “satu paket lebih benar” tanpa rujukan kebenaran; pembanding terhadap kebenaran model tersedia pada skrip `benchmarks/compare_ebp_tipsae_truth.R` dan `sim_mc_finite_population.R` (hasil tersimpan di `benchmarks/output/`, di luar cakupan `inst/extdata`).



Gambar 5: Ekuivalensi numerik `fastsae` vs `tipsae` untuk $n = 1000$ area: (a) prediktor area terhadap garis identitas; (b) MSE pada skala log. Sumber: `inst/extdata/beta_estimates_n1000.rds`; `scripts/02_figures.R`.

3.6 Kaveat dan keadilan

1. **Beda algoritme, bukan beda implementasi.** `tipsae` adalah Bayes MCMC/Stan [De Nicolò and Gardini, 2024], `hbsae` memakai pendekatan Bayesnya sendiri, `emdi` dan `sae` memakai `lme4`/aljabar Matrix di R, sedangkan `fastsae` memakai C++ + INLA. Selisih waktu mencerminkan perbedaan ini sekaligus.
2. **Tanpa penetapan thread.** Tidak ada skrip yang mengunci `OMP_NUM_THREADS`; bootstrap paralel (bagian 2.5) dapat memakai seluruh core mesin, sedangkan pembanding berjalan serial. Ini membuat perbandingan *memihak* ke `fastsae` pada skala besar, dan dilaporkan apa adanya.
3. **Kriteria konvergensi tidak disamakan.** `fastsae` memakai toleransi 10^{-4} dan 100 iterasi (Tabel 4); pengaturan pembanding tidak tercatat di file.
4. **Memori bukan puncak.** Kolom memori adalah akumulasi alokasi, sehingga tidak setara dengan *peak RSS* yang lazim dilaporkan.
5. **Empat file tanpa skrip.** Hasil FH (tiga file) dan `beta_estimates_n1000` tidak dapat direproduksi dari repo; laporan memakainya apa adanya dan menandainya.
6. **Run inkremental.** Skrip 1–5 menulis file secara inkremental (baris lama per n diganti), sehingga file bisa berisi campuran run dari waktu yang berbeda.

3.7 Kontradiksi klaim dokumentasi terhadap data

Aturan laporan: data menang. Temuan berikut berasal dari perbandingan langsung klaim `README.Rmd/vignettes/benchmarks.Rmd/paper/article.tex` dengan isi `inst/extdata` (perhitungan lengkap: `_notes/bench_methodology.md` bagian 6 dan 8).

Implikasinya langsung: laporan ini tidak mengutip satu pun angka kecepatan dari README. Angka yang dipakai seluruhnya berasal dari tabel dan gambar di atas, yang kesemuanya dihasilkan ulang dari file data.

Tabel 21: Klaim dokumentasi yang bertolak belakang dengan file data. Sumber: README.Rmd, vignettes/benchmarks.Rmd, paper/article.tex vs inst/extdata/*.rds (butir DOC-1 – DOC-11 di DISCREPANCIES.md).

Butir	Klaim dokumentasi	Fakta dari data
DOC-1	README.Rmd:118 menandai tabel “Benchmark across $n = 1000$ areas”	angka tabel adalah rata-rata lintas $n = 30 \dots 1000$
DOC-2	README.Rmd:122 “ $\sim 190\times$ ” dan “ $\sim 6400\times$ ”	rasio yang benar tidak cocok dengan salah satunya (lihat Tabel 19)
DOC-3	README.Rmd:124 fastsae “ < 10 MB”	beberapa baris fastsae melebihi 10 MB (Tabel 18)
DOC-4	README.Rmd:124 pembandingan “ ~ 400 MB”/“ ~ 800 MB”	campuran dua file; untuk FH angkanya jauh di bawah itu
DOC-5/6	README.Rmd:34–35 “50 to 6,000 $\times$ ” dan :87 “10–100 $\times$ ”	rentang teramati lebih lebar di kedua ujung (Tabel 19)
DOC-7	vignettes/benchmarks.Rmd:39 emdi spasial “8,69 s”	nilai pada file berbeda (Tabel 8)
DOC-8	label “Peak Memory” di README, vignette, dan artikel	nilai adalah rerata mem_alloc, bukan puncak
DOC-10	vignettes/benchmarks.Rmd:407–414, 634–639 kolom Spatial/ST $n \geq 100$	tidak ada data pendukung di inst/extdata
DOC-11	reproduksi hasil	empat file tidak punya skrip pembuat di repo

4 Latar statistik

Bagian ini menyajikan perkakas yang dipakai berulang di seluruh model, dengan notasi yang sama dengan yang dipakai kode (mis. nama variabel `varidir`, `sigma2`, `rho`). Derivasi panjang dipindahkan ke lampiran B.

4.1 Tabel notasi

4.2 Model campuran linear, GLS, dan BLUP

Model campuran linear umum

$$y = \mathbf{X}\beta + \mathbf{Z}u + \varepsilon, \quad \begin{pmatrix} u \\ \varepsilon \end{pmatrix} \sim N\left(0, \begin{pmatrix} \mathbf{G} & 0 \\ 0 & \mathbf{R} \end{pmatrix}\right), \quad (5)$$

memberi kovarians total $\mathbf{V} = \mathbf{ZGZ}' + \mathbf{R}$. Dengan β diketahui, prediktor linier tak bias terbaik (BLUP) dari u adalah

$$\tilde{u} = \mathbf{GZ}'\mathbf{V}^{-1}(y - \mathbf{X}\beta), \quad \tilde{\theta} = \mathbf{X}\beta + \mathbf{GZ}'\mathbf{V}^{-1}(y - \mathbf{X}\beta). \quad (6)$$

Apabila β dinilai dengan GLS, $\hat{\beta} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-1}y$, maka prediktor (6) tetap linier tak bias pada β dan dikenal sebagai *best linear unbiased predictor* [Kackar and Harville, 1984]. Pada fastsae, (6) muncul sebagai `eblup = Xbeta + GVi %*% (y - Xbeta)` pada SFH (`eblup_sfh_core.cpp:462`) dan sebagai kasus khusus pada FH.

Untuk model area-level FH, $\mathbf{Z} = \mathbf{I}$, $\mathbf{G} = \sigma^2\mathbf{I}$, $\mathbf{R} = \text{diag}(\psi_d)$ sehingga $\mathbf{V}$ diagonal dan semua operasi turun ke skalar per area:

$$\hat{u}_d = \frac{\sigma^2}{\sigma^2 + \psi_d} (y_d - x_d'\hat{\beta}), \quad \hat{\theta}_d = x_d'\hat{\beta} + \hat{u}_d. \quad (7)$$

Tabel 22: Notasi utama dan padanannya dalam kode. Sumber: simbol pada `R/*`.R dan `src/*`.cpp.

Simbol	Nama kode	Arti
y_d atau y_{id}	<code>y</code>	pengamatan langsung / respons (baris NA menandai domain tak-sampel pada model area-level)
ψ_d	<code>vardir, psi</code>	varian pengukuran langsung $\psi_d = S_d^2/n_d$; wajib > 0 pada area tersampel
$\mathbf{X}$	<code>X, Xall</code>	matriks desain ($m \times p$ atau $N \times p$)
$\hat{\beta}$	<code>beta</code>	estimasi koefisien fit tetap (GLS)
u_d, θ_d	<code>random_effect, theta</code>	efek acak domain dan prediktor area $\theta_d = x_d'\beta + u_d$
σ^2	<code>sigma2, sigma2_u</code>	varians efek acak
$\mathbf{V}$	<code>V, Vi</code>	kovarians respons dan inversinya
$\mathbf{Q} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}$	<code>Q</code>	matriks informasi GLS
$w_d = 1/(\psi_d + \sigma^2)$	<code>w</code>	bobot FH per area
B_d	<code>Bd</code>	faktor pemulusan gaya FH (lihat (13))
$h_d = x_d'\mathbf{Q}x_d$	<code>h</code>	leverage prediktor
$\mathbf{W}$	<code>W, proxmat</code>	matriks tetangga (bobot)
ρ	<code>rho</code>	autoregresi spasial pada SFH/STFH
$f_d = n_d/N_d$	<code>f</code>	fraksi sampel populasi (BHF, <code>hb_unit</code>)
B	<code>B</code>	jumlah replikat bootstrap
m, M, D, T	<code>m, D, Tt</code>	jumlah area ter-sampel, total baris, jumlah domain, jumlah periode waktu

4.3 EBLUP

Empirical BLUP menggantikan komponen varians σ^2 dengan estimanya $\hat{\sigma}^2$:

$$\hat{\theta}_d(\hat{\sigma}^2) = x_d'\hat{\beta}(\hat{\sigma}^2) + \hat{u}_d(\hat{\sigma}^2). \quad (8)$$

Kackar and Harville [1984] menunjukkan bahwa pendekatan orde-kedua menyediakan pendekatan varian prediktor yang lazim dipakai; Prasad and Rao [1990] dan Datta and Lahiri [2000] mengembangkan dekomposisinya menjadi suku-suku g yang dibahas pada bagian 4.6. Konsekuensi praktis pendekatan ini diabaikan oleh Kackar–Harville: penggantian $\sigma^2 \rightarrow \hat{\sigma}^2$ menggeser prediktor sedikit ke atas (*bias*); pada FH, `fastsae` mengoreksi orde-kedua itu *hanya* bila `method = "ML"` (`eb_lup_fh.cpp:196–199`).

4.4 ML, REML, dan skor

Likelihood biasa untuk FH (satu parametrik) dengan $v_d = \sigma^2 + \psi_d$:

$$\ell(\sigma^2) = -\frac{1}{2} \sum_{d=1}^m \left[\log(2\pi v_d) + \frac{r_d^2}{v_d} \right], \quad r_d = y_d - x_d'\hat{\beta}, \quad (9)$$

dengan $\hat{\beta}$ fungsi GLS dari σ^2 . Persamaan skor ML yang dikodekan (`eb_lup_fh.cpp:103`) adalah

$$s(\sigma^2) = -\frac{1}{2} \sum_d w_d + \frac{1}{2} (Py)'(Py), \quad P = W - WX\mathbf{Q}X'W, \quad (10)$$

dan informasi Fisher $I(\sigma^2) = \frac{1}{2} \sum_d w_d^2$ (`eb_lup_fh.cpp:112`). REML memakai kasus spesial

$$s_R(\sigma^2) = -\frac{1}{2} \text{tr } P + \frac{1}{2} (Py)'(Py), \quad I_R(\sigma^2) = \frac{1}{2} \text{tr}(P^2), \quad (11)$$

dengan turunan ringkas yang dikodekan: $\text{tr } P = \sum_d w_d - \text{tr}(\mathbf{Q}X'W^2\mathbf{X})$ dan $\text{tr}(P^2) = \sum w^2 - 2 \sum_d w_d^2 (x_d'\mathbf{Q}x_d)w_d + \text{tr}(K^2)$, $K = \mathbf{Q}X'W^2\mathbf{X}$ (`eb_lup_fh.cpp:105–117`). Tidak ada inversi matriks $m \times m$ sama sekali pada FH: kedua turunan dihitung dari akumulasi skalar.

Implementation note. Untuk model dengan dua atau lebih parameter (dua-fold, SFH, STFH), persamaan skor ditulis per elemen θ_a dengan pola $s_a = -\frac{1}{2} \text{tr}(M_a) + \frac{1}{2} y' M_a y$ (REML) dan $\mathcal{I}_{ab} = \frac{1}{2} \text{tr}(M_a M_b)$, dengan $M_a = P \partial V / \partial \theta_a$ dan $P = V^{-1} - V^{-1} X \mathbf{Q} X' V^{-1}$. Untuk SFH dengan `method="ML"`, kode memakai kuadratik $y' P D P y$ tetapi informasi $\frac{1}{2} \text{tr}(V^{-1} D_a V^{-1} D_b)$ — campuran ML/REML yang didokumentasikan sebagai SFH-1 di `DISCREPANCIES.md`.

4.5 Fisher scoring

Fisher scoring menggantikan Hessian oleh informasi Fisher:

$$\theta^{(k+1)} = \theta^{(k)} + \mathcal{I}(\theta^{(k)})^{-1} s(\theta^{(k)}). \quad (12)$$

Algoritme umum yang diikuti empat inti C++ (lihat Tabel 4 untuk nilai konkretnya):

1. hitung $\mathbf{V}, \mathbf{V}^{-1}, \mathbf{Q}$ pada $\theta^{(k)}$;
2. hitung skor s dan informasi $\mathcal{I}$;
3. langkah $\Delta = \mathcal{I}^{-1} s$ (pada dua-parameter: inversi 2×2 ; bila gagal, fallback $\Delta_a = s_a / \mathcal{I}_{aa}$);
4. perbarui $\theta \leftarrow \theta + \Delta$; terapkan batas;
5. uji `diff` = $\max_a |\Delta_a / \max(\theta_a, 10^{-12})| \leq \text{precision}$;
6. ulangi maksimum `maxiter` kali, lalu lakukan pass akhir pada $\hat{\theta}$ (menghitung ulang $\mathbf{Q}, \hat{\beta}$, galat baku, prediktor, dan MSE).

Langkah 6 penting: MSE dan galat baku dievaluasi pada $\hat{\theta}$ final, bukan pada iterate terakhir sebelum update (pada STFH, galat baku parameter komponen varians justru dihitung dari $\mathcal{I}^{-1}$ pada θ_k sebelum update terakhir — STFH-7 di `DISCREPANCIES.md`).

4.6 Dekomposisi MSE

Untuk prediktor EBLUP, Prasad and Rao [1990] dan Kackar and Harville [1984] menguraikan galat kuadrat rata-rata ke dalam tiga suku. Untuk FH, `fastsae` menghitung (`eblup_fh.cpp:183-202`) dengan parametrisasi

$$B_d = \frac{\psi_d}{\psi_d + \hat{\sigma}^2}, \quad g_1 = \psi_d(1 - B_d), \quad g_2 = B_d^2 h_d, \quad g_3 = B_d^2 \frac{\text{Var}(\hat{\sigma}^2)}{\hat{\sigma}^2 + \psi_d}, \quad (13)$$

dengan $\text{Var}(\hat{\sigma}^2) = 2 / \sum_d w_d^2$ (varian asimptotik $\hat{\sigma}^2$), $h_d = x_d' \mathbf{Q} x_d$. Lalu

$$\widehat{\text{MSE}}(\hat{\theta}_d) = \begin{cases} g_1 + g_2 + 2g_3, & \text{REML,} \\ g_1 + g_2 + 2g_3 - b B_d^2, & \text{ML,} \end{cases} \quad b = -\frac{\text{tr}(\mathbf{Q} \mathbf{X}' W^2 \mathbf{X})}{\max(\sum_d w_d^2, 10^{-30})}. \quad (14)$$

Implementation note. B_d pada (13) adalah komplemen dari $B_d = \hat{\sigma}^2 / (\hat{\sigma}^2 + \psi_d)$ yang lazim dipakai Rao–Molina: kode menulis $B_d = \psi_d / (\psi_d + \hat{\sigma}^2)$ (FH-1). Bentuk $g_1 = \psi_d(1 - B_d)$ ekuatip dengan $(B_d^{\text{RM}})^2 \psi_d + (1 - B_d^{\text{RM}})^2 \hat{\sigma}^2$ (FH-2). Jangan tertukar dengan $(1 - B)^2(\psi_d + \hat{\sigma}^2)$ yang kadang muncul di literatur — bentuk itu bukan yang dikodekan.

Untuk model dua-parameter (dua-fold) koreksi bias berbeda: varians $\text{Var}(\hat{\sigma}_v^2)$, $\text{Var}(\hat{\sigma}_u^2)$, dan Cov diambil dari invers matriks informasi Fisher final, dan $\text{MSE} = g_1 + g_2 + g_3$ dengan suku silang $2\mathbb{E}_{vu} \text{Cov}_{vu}$ sudah termasuk di dalam g_3 (TFH-2) — bukan $g_1 + g_2 + 2g_3$. Untuk SFH, empat suku dipakai: $\text{MSE} = g_1 + g_2 + 2g_3 - g_4$ plus koreksi bias ML pada g_1 (bagian 6.5).

4.7 MSE bootstrap

Dua jenis tersedia di paket:

Parametrik. Dari hasil fit $\hat{\beta}, \hat{\sigma}^2$, bangkitkan $y^* = \mathbf{X}\hat{\beta} + u^* + \varepsilon^*$ dengan u^*, ε^* dari distribusi model, refit, lalu

$$\widehat{\text{MSE}}_{\text{pb}} = \frac{1}{B} \sum_{b=1}^B (\hat{\theta}_b^* - \theta_b^*)^2. \quad (15)$$

Ini persis `eblup_tfh.cpp:515-517`, `eblup_stfh_pbmse.cpp:405-412`, `eblup_sf_h_pbmse.cpp:158-164`, dan `R/eblup_bhf.R:360`. Varian bias-koreksi pada SFH memakai

$$\widehat{\text{MSE}}_{\text{pbbc}} = 2(g_1 + g_2) - g_1^* - g_2^* + g_3^*, \quad (16)$$

dengan g_3^* diambil dari selisih $\hat{\theta}^*$ terhadap prediksi SBLUP yang bobotnya berasal dari *fit awal* (`eblup_sf_h_pbmse.cpp:127-128, 164`); kesesuaian (16) dengan rumus publik tidak terikat pada referensi mana pun di repo dan ditandai tidak pasti (SFH-10).

Nonparametrik. Hanya untuk SFH dan hanya REML (`eblup_sf_h_npbmse.cpp:32-34`): residual dibagi menjadi komponen efek acak dan sampling lewat akar kuadrat matriks $\Psi_e = \text{diag}(\psi)P \text{diag}(\psi)$ dan $\Psi_u = (\mathbf{I} - \rho W) G P G (\mathbf{I} - \rho W)'$ yang dieigendekomposisi (kolom $p..m - 1$ dipakai untuk membuang arah proyeksi $\mathbf{X}$), lalu resample indeks residual yang telah distandarisasi (`eblup_sf_h_npbmse.cpp:70-110, 143-149`).

4.8 Domain tanpa sampel dan prediksi sintetis

Tabel 23 merangkum perilaku tiap fungsi terhadap domain tanpa pengamatan. Definisi “tanpa sampel” berbeda antar fungsi, dan perbedaan itu penting bagi pengguna.

Tabel 23: Penanganan domain tanpa sampel. Sumber: cabang kode pada kolom terakhir.

Fungsi	Kriteria	Prediktor dan MSE
<code>eblup_fh</code>	<code>y = NA</code>	$x'_{ns}\hat{\beta}$; $\text{MSE} = \hat{\sigma}^2 + x'_{ns}\mathbf{Q}x_{ns}$; <code>random_effect = NA</code> (<code>eblup_fh.cpp:207-222</code>)
<code>eblup_sf_h</code>	<code>y = NA</code>	kriging $x'_{ns}\hat{\beta} + G_{rs}\mathbf{V}^{-1}r$ dengan sub-blok A_{full}^{-1} ; $\text{MSE} = g_1 + g_2$ saja (<code>eblup_sf_h_core.cpp:576-604</code>)
<code>eblup_stfh</code>	<code>respons NA</code>	<i>tidak diizinkan</i> : panel wajib lengkap, <code>cli_abort</code> (<code>R/eblup_stfh.R:129-139</code>)
<code>eblup_bhf</code>	domain tanpa unit sampel	prediktor sintetis $\bar{x}'_{pop}\hat{\beta}$, <code>samp_size = 0</code> , peringatan (<code>eblup_unit.cpp:94-100</code>)
<code>eblup_twofold</code>	<code>y = NA</code>	area tanpa subarea: $x'\hat{\beta}$; subarea tak-sampel pada area tersampel: $x'\hat{\beta} + \hat{v}_i$ (<code>eblup_tfh.cpp:333-363</code>)
<code>hb_unit</code>	seluruh domain	menambahkan 1 baris <code>y = NA</code> per domain, lalu memakai fitted INLA (<code>hb_unit.R:244-249</code>)
<code>hb_area</code> , <code>hb_twofold</code>	baris <code>y = NA</code>	tetap dievaluasi oleh INLA; domain yang <i>tidak ada dalam data</i> tidak diprediksi (HB-17)

4.9 Benchmarking: pengertian internal dan eksternal

Dalam literatur SAE, *benchmarking* berarti mengkalibrasi prediktor model ke total atau agregat yang diketahui sehingga konsistensi antar tingkat kerapian terpenuhi [Rao and Molina, 2015]. Dua varian muncul di paket ini:

- **Benchmarking eksternal** memakai total populasi yang diketahui dari sumber luar survei (mis. total penduduk per provinsi).
- **Benchmarking internal** menggunakannya sebagai *validasi*: `diagnose()` membandingkan total prediksi terhadap total yang diketahui dan menandai status `CONSISTENT` bila selisihnya di bawah toleransi (`benchmark.R:602`).

Empat metode kalibrasi (`ratio`, `difference`, `optimal`, `logit`) beserta pendukung hierarkinya dijelaskan pada bagian 14; di sini cukup dicatat bahwa seluruhnya bekerja pada vektor prediktor + MSE dan bobot populasi, sehingga dapat dipakai pada hasil model mana pun yang mengembalikan `df_eblup/df_hb`.

5 Model Fay–Herriot area-level: `eblup_fh`

5.1 Setting data dan kapan dipakai

Data berupa satu baris per domain: estimasi langsung y_d (mis. rerata tahun sekolah per kabupaten), varians pengukurannya ψ_d (`vardir`), dan kovariat x_d berdimensi p (jumlah sekolah, dll.). Model ini tepat ketika: (i) survei menghasilkan estimasi langsung beserta variansnya, (ii) domain sangat kecil sampai y_d tidak stabil, dan (iii) ada kovariat yang tersedia untuk semua domain termasuk yang tidak tersample. Data contoh `mys` (42 kabupaten, 10 di antaranya tanpa sampel) persis berbentuk ini. Model ini adalah titik masuk klasik SAE [Fay and Herriot, 1979] dan dibahas lengkap di Rao and Molina [2015].

5.2 Persamaan model

$$y_d = x_d' \beta + u_d + e_d, \quad u_d \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad e_d \sim N(0, \psi_d), \quad (17)$$

dengan β tanpa prior (dihilangkan lewat GLS) dan e_d saling bebas. Varians total per area $v_d = \sigma^2 + \psi_d$ dan bobot $w_d = 1/v_d$ muncul di kode sebagai dasar seluruh turunan (`eblup_fh.cpp:89`). Dalam notasi blok, $\mathbf{V} = \text{diag}(v_1, \dots, v_m)$.

Domain tanpa sampel ditandai *bukan* lewat indeks melainkan lewat `y = NA`: baris dengan `y` non-finite dipisahkan lebih dulu dan $\mathbf{X}$ -nya disimpan sebagai `Xns` (`eblup_fh.cpp:33–47`). Argumen `domain` hanya pelabelan kolom (`R/eblup_fh.R:97`).

5.3 Prediktor titik

Dengan $\hat{\beta} = (\mathbf{X}'W\mathbf{X})^{-1}\mathbf{X}'W\mathbf{y}$ (`eblup_fh.cpp:135–143`), prediktor area adalah EBLUP

$$\hat{\theta}_d = x_d' \hat{\beta} + \hat{u}_d, \quad \hat{u}_d = \frac{\hat{\sigma}^2}{\hat{\sigma}^2 + \psi_d} (y_d - x_d' \hat{\beta}), \quad (18)$$

yang ekuivalen dengan pemulusan y_d terhadap prediktor sintetis:

$$\hat{\theta}_d = B_d (x_d' \hat{\beta}) + (1 - B_d) y_d, \quad B_d = \frac{\psi_d}{\psi_d + \hat{\sigma}^2}. \quad (19)$$

Pada domain tanpa sampel predikturnya jatuh ke prediktor sintetis murni (`eblup_fh.cpp:207-222`):

$$\hat{\theta}_{ns} = x'_{ns}\hat{\beta}, \quad \widehat{\text{MSE}}_{ns} = \hat{\sigma}^2 + x'_{ns}\mathbf{Q}x_{ns}, \quad \text{random_effect} = \text{NA}. \quad (20)$$

5.4 Estimasi komponen varians

Algoritme Fisher scoring persis seperti bagian 4.5 dengan skor ML (10) dan skor REML (11). Rekam jejak lengkapnya:

1. **Nilai awal:** $\hat{\sigma}^{2(0)} = \max(\text{median}(\psi_d), 0)$ (`eblup_fh.cpp:64-65`).
2. **Loop:** `while (diff > precision && k < maxiter)` (baris 88), `precision = 10-4`, `maxiter = 100`.
3. **Per iterasi:** $\mathbf{W}, \mathbf{Q} = (\mathbf{X}'\mathbf{W}\mathbf{X})^{-1}$ lewat `inv_sympd` dengan fallback `solve` (baris 95-96), $\mathbf{P}y = \mathbf{W}y - \mathbf{X}\mathbf{Q}\mathbf{X}'\mathbf{W}y$ (baris 98-99).
4. **Update:** $\hat{\sigma}^2 \leftarrow \hat{\sigma}^2 + s/I$; bila $I \leq 0$ langkah dipetakan ke `numeric_limits::min()`, dan nilai non-finite atau negatif *dipaksa* 0 (baris 120-123).
5. **Konvergensi:** `diff = |(\hat{\sigma}^{2\text{new}} - \hat{\sigma}^2) / \max(\hat{\sigma}^2, 10-12)|` (baris 125); `status convergence` dan `n_iter` dikembalikan, dan wrapper R memperingati bila gagal (`R/eblup_fh.R:104-107`).
6. **Pass akhir:** hitung ulang $\mathbf{Q}, \hat{\beta}$, galat baku `se = sqrt(diag(Q))`, z , dan p dua sisi pada $\hat{\sigma}^2$ final (baris 135-154).

Log-likelihood, AIC, dan BIC dihitung dari (9) dengan m = jumlah area tersampel, $\text{AIC} = -2\ell + 2(p+1)$, $\text{BIC} = -2\ell + (p+1)\log m$ (baris 170-174).

Implementation note. Ketiga ukuran kecocokan itu selalu berbentuk ML meski `method = "REML"` (FH-3), dan koreksi bias orde-kedua $-bB_d^2$ hanya dipakai untuk ML (FH-4) — perilaku yang sama dengan `sae::mseFH`. Kolom `estcoef` memuat dua kolom galat baku yang identik (`std.error` dan `stderr_beta`; FH-5), dan `vardir` wajib positif ketat pada area tersampel (FH-6), yang tidak diperiksa `sae`.

5.5 Estimasi MSE

MSE analitik (14) adalah satu-satunya metode di `eblup_fh()` — tidak ada pilihan bootstrap. RSE dilaporkan sebagai $\text{RSE} = 100\sqrt{\text{MSE}}/|\hat{\theta}|$ dan menjadi NaN bila $\hat{\theta} = 0$ (baris 227-230). Pada domain tanpa sampel dipakai (20) tanpa suku g_3 , sesuai Prasad and Rao [1990] untuk prediktor yang tidak memakai data domain.

5.6 Pseudo-code

5.7 Signature, argumen, objek keluaran, dan contoh

Listing 3: Signature `eblup_fh` (`R/eblup_fh.R:49-58`).

```
eblup_fh(formula, vardir, domain = NULL, data,
         method = c("REML", "ML"), maxiter = 100,
         precision = 1e-4, print_result = TRUE)
```

Algorithm 2:

```
1 Masukan formula, vardir, domain, data, method  $\in \{REML, ML\}$ , maxiter,  
  precision Keluaran df_eblup (prediktor, MSE, RSE), estcoef, goodness ;  
  // Lapis R -- R/eblup_fh.R  
2 method  $\leftarrow$  match.arg; // baris 59  
3 domain  $\leftarrow$  1:nrow(data) bila NULL (60–64);  
4 mf  $\leftarrow$  model.frame(formula, na.action = na.pass) (67);  
5 y  $\leftarrow$  respons, X  $\leftarrow$  model.matrix (74–75);  
6 gagal bila anyNA(X) atau length(vardir)  $\neq$  nrow(mf) (70–80);  
7  $\hat{\theta}, \widehat{MSE}, \dots \leftarrow$  eblup_core(X, y, psi, method, maxiter, precision) (82);  
8 sisipkan domain ke df_eblup; class  $\leftarrow$  "fastsae" (97–102);  
9 if !convergence then  
10 | cli_alert_danger dan kembalikan (104–107)  
11 print(objek) bila print_result (109–111);  
  ; // Lapis C++ -- src/eblup_fh.cpp  
12 Is  $\leftarrow$  find_nonfinite(y); Ins  $\leftarrow$  find_finite(y) ; // 33–47  
13 gagal bila m = 0 atau ada  $\psi_d \leq 0$  pada area tersampel (53–59);  
14  $\hat{\sigma}^2 \leftarrow$  max(median( $\psi$ ), 0);  
15 k  $\leftarrow$  0; diff  $\leftarrow$  precision + 1;  
16 while diff > precision dan k < maxiter do  
17 | W  $\leftarrow$  diag(w); Q  $\leftarrow$  (X'WX)−1; Py  $\leftarrow$  Wy − XQX'Wy (89–99);  
18 | if method = ML then  
19 | | s  $\leftarrow$   $-\frac{1}{2} \sum_d w_d + \frac{1}{2} (Py)'(Py)$ ; I  $\leftarrow$   $\frac{1}{2} \sum_d w_d^2$  (103, 112)  
20 | else  
21 | | s  $\leftarrow$   $-\frac{1}{2} \text{tr } P + \frac{1}{2} (Py)'(Py)$ ; I  $\leftarrow$   $\frac{1}{2} \text{tr}(P^2)$  (105–117)  
22 | ;  
23 |  $\hat{\sigma}^{2\text{new}} \leftarrow \hat{\sigma}^2 + s/I$ ; bila I  $\leq 0$  pakai numeric_limits::min() (120–122);  
24 | bila  $\hat{\sigma}^{2\text{new}} < 0$  atau non-finite  $\rightarrow \hat{\sigma}^{2\text{new}} \leftarrow 0$  (123);  
25 | diff  $\leftarrow |(\hat{\sigma}^{2\text{new}} - \hat{\sigma}^2) / \max(\hat{\sigma}^2, 10^{-12})|$ ;  $\hat{\sigma}^2 \leftarrow \hat{\sigma}^{2\text{new}}$ ; k += 1 (125–126);  
26 hitung ulang Q, β̂, se, z, p pada  $\hat{\sigma}^2$  final (135–154);  
27  $\hat{\theta}_d \leftarrow x'_d \hat{\beta} + \hat{u}_d$ ; loglik ML, AIC, BIC (159–180);  
28 g1, g2, g3  $\leftarrow$  (13);  $\widehat{MSE} \leftarrow g_1 + g_2 + 2g_3$  (REML) atau  $-bB_d^2$  (ML) (183–202);  
29 for d  $\in I_{ns}$  do  
30 |  $\hat{\theta}_d \leftarrow x'_{ns} \hat{\beta}$ ;  $\widehat{MSE} \leftarrow \hat{\sigma}^2 + x'_{ns} \mathbf{Q} x_{ns}$ ;  $\hat{u}_d \leftarrow \text{NA}$  (207–222)  
31 RSE  $\leftarrow 100\sqrt{\widehat{MSE}} / |\hat{\theta}|$ ; susun df_eblup dan estcoef (227–261);
```

- `formula` — $\text{respons} \sim \text{kovariat}$; `respons` boleh berisi NA untuk domain tak-sampel (`na.action = na.pass`).
- `varidir` — nama kolom, formula satu sisi, atau vektor numerik (resolver `.get_variable`, R/utils.R:19–38).
- `domain` — kolom/faktor label domain (bukan penanda sampel).
- `method` — "REML" (default) atau "ML".
- `maxiter`, `precision` — parameter Fisher scoring.
- `print_result` — mencetak `print.fastsaes`.

Objek keluaran: `list` berkelas "fastsaes" berisi `estcoef` (β , dua kolom galat baku, z , p), `random_effect_var` ($\hat{\sigma}^2$), `goodness` (loglik ML, AIC, BIC), `n_iter`, `convergence`, `df_eblup` dengan kolom `domain`, `y`, `eblup`, `varidir`, `random_effect`, `mse`, `rse`, plus `formula`, `model = "FH"`, `call`, `data`.

Listing 4: Contoh yang dapat dijalankan (dari `man/eblup_fh.Rd`; data `mys` berisi 42 domain, 10 di antaranya tanpa sampel).

```
library(fastsae)
m1 <- eblup_fh(y ~ x1 + x2 + x3, data = mys, varidir = "varidir")
head(m1$df_eblup, 3)
m1$random_effect_var      # sigma^2
m1$goodness                # loglik, AIC, BIC

# metode ML dan kontrol iterasi
m2 <- eblup_fh(y ~ x1 + x2 + x3, data = mys, varidir = "varidir",
               method = "ML", maxiter = 50, precision = 1e-6)
```

5.8 Referensi kunci

Fay and Herriot [1979] memperkenalkan model area-level ini; Rao and Molina [2015] menyajikan EBLUP dan dekomposisi MSE-nya; Prasad and Rao [1990] dan Kackar and Harville [1984] memberi kerangka suku g dan pendekatan orde-kedua; Datta and Lahiri [2000] menyajikan ukuran ketidakpastian terpadu; Molina and Marhuenda [2015] adalah referensi implementasi paket `sae` yang dipakai sebagai pembandingan numerik. Blok `@references` fungsi ini hanya memuat Rao and Molina [2015] (R/eblup_fh.R:5–8).

6 Model Fay–Herriot spasial: `eblup_sfh`

6.1 Setting data dan kapan dipakai

Bentuk datanya sama dengan FH (satu baris per domain: y_d, ψ_d , kovariat x_d) tetapi ditambah satu objek wajib: matriks tetangga W berdimensi $m \times m$ termasuk baris/kolom domain tanpa sampel (R/eblup_sfh.R:131–141). Model ini dipakai bila residual direktor mengandung korelasi spasial, misalnya karena faktor geografis yang tidak terukur; ekuivalennya adalah model *spatial error*/SAR pada data area-level [Pratesi and Salvati, 2008, Rao and Molina, 2015]. Karena W dari pengguna, fungsi ini tidak pernah membangun struktur tetangga sendiri; pembuat tetangga rook/queen tersedia lewat `sim_spatial_weights()` (bagian 14).

6.2 Persamaan model

$$y_d = x'_d \beta + u_d + e_d, \quad u \sim N(0, \sigma^2 A^{-1}), \quad e_d \sim N(0, \psi_d), \quad (21)$$

dengan matriks presisi spasial (kode: `eblup_sfh_core.cpp:311`)

$$A = (\mathbf{I} - \rho \mathbf{W}')'(\mathbf{I} - \rho \mathbf{W}) = \mathbf{I} - \rho(\mathbf{W} + \mathbf{W}') + \rho^2 \mathbf{W}'\mathbf{W}, \quad |\rho| < 1. \quad (22)$$

Karena A adalah presisi, (21) ekuivalen dengan bentuk autoregresi spasial serentak $u = \rho \mathbf{W}u + \varepsilon$, $\varepsilon \sim N(0, \sigma^2 \mathbf{I})$; dalam arti ini efek spasialnya *SAR/error-components*, bukan CAR proper (perbandingan kedua notasi ada pada bagian 13.3). Kovarians total $\mathbf{V} = G + \text{diag}(\psi)$ dengan $G = \sigma^2 A^{-1}$ (baris 318, 401). Turunan yang dibutuhkan skoring (derifasi lengkap di lampiran B) adalah

$$\frac{\partial A}{\partial \rho} = -(\mathbf{W} + \mathbf{W}') + 2\rho \mathbf{W}'\mathbf{W}, \quad \frac{\partial \mathbf{V}}{\partial \rho} = -\sigma^2 A^{-1} \frac{\partial A}{\partial \rho} A^{-1}, \quad (23)$$

persis kode `eblup_sfh_core.cpp:315-316` (matriks $\mathbf{W}'\mathbf{W}$ dan $\mathbf{W} + \mathbf{W}'$ di-pra-hitung sekali di luar loop, baris 283-284).

6.3 Prediktor titik

Dengan $Q = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}$ dan $\hat{\beta} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-1}y$ (baris 407-414), prediktor adalah EBLUP matriks persis (6):

$$\hat{\theta} = \mathbf{X}\hat{\beta} + G\mathbf{V}^{-1}(y - \mathbf{X}\hat{\beta}) \quad (\text{eblup_sfh_core.cpp:462}), \quad \hat{u} = G\mathbf{V}^{-1}(y - \mathbf{X}\hat{\beta}). \quad (24)$$

Pada domain tanpa sampel prediktor berubah menjadi *kriging simpel* (baris 576-591): dengan G dihitung dari $\mathbf{W}$ penuh,

$$\hat{u}_{ns} = G_{rs} \mathbf{V}^{-1}(y_s - \mathbf{X}_s \hat{\beta}), \quad \hat{\theta}_{ns} = x'_{ns} \hat{\beta} + \hat{u}_{ns}. \quad (25)$$

Implementation note. Baris 580-587 memakai sub-blok dari A_{full}^{-1} , sedangkan pass fit memakai W_{ss} ; keduanya tidak setara, $[A_{\text{full}}^{-1}]_{ss} \neq [(\mathbf{I} - \rho W_{ss})'(\mathbf{I} - \rho W_{ss})]^{-1}$ (SFH-8). Selain itu dokumentasi menyebut “analytical MSE approximation” untuk area tak-sampel, padahal yang dihitung hanya $g_1 + g_2$ tanpa g_3, g_4 (SFH-7).

6.4 Estimasi komponen varians

Parameter yang diiterasikan dua: $\theta = (\sigma_u^2, \rho)$, nilai awal $\sigma_u^{2(0)} = \text{median}(\psi)$ dan $\rho^{(0)} = 0.5$ (baris 288-289), toleransi relatif 10^{-4} , maksimum 100 iterasi (baris 307). Per iterasi (baris 308-383):

1. bangun A , A^{-1} (`inv_sympd`, fallback `pinv`), $\mathbf{V}$, $\mathbf{V}^{-1}$, Q , $P = \mathbf{V}^{-1} - \mathbf{V}^{-1}\mathbf{X}Q\mathbf{X}'\mathbf{V}^{-1}$;
2. skor dan informasi — untuk REML (baris 349-357)

$$s_a = -\frac{1}{2} \text{tr}(PD_a) + \frac{1}{2} y' PD_a P y, \quad \mathcal{I}_{ab} = \frac{1}{2} \text{tr}(PD_a PD_b), \quad (26)$$

dengan $D_1 = \mathbf{I}$ dan $D_2 = \partial \mathbf{V} / \partial \rho$; untuk ML (baris 338-348) baris pertama skor memakai $\mathbf{V}^{-1}$ tetapi kuadratiknya tetap $y' P D P y$;

3. langkah Newton–Fisher $\Delta = \mathcal{I}^{-1}s$ lewat `solve`; kegagalan memutus loop dengan `convergence = FALSE`;

4. batas: $|\rho| < 0.999$ (baris 371-374); σ_u^2 tidak dibatasi selama iterasi, hanya $\sigma^2 = \max(0, \cdot)$ pada hasil akhir (baris 394);
5. konvergensi $\text{diff} = \max_a |\Delta\theta_a/(\theta_a + 10^{-12})|$ (baris 376-383).

Galat baku kedua komponen $\sqrt{\text{diag}(\mathcal{I}^{-1})}$ dihitung dari $\mathcal{I}$ berbentuk REML tanpa memeriksa `method` (baris 502-510, 647-653), dan `loglikelihood/AIC/BIC` selalu memakai bentuk ML (baris 464-476).

Implementation note. Tiga hal pada penutup paragraf di atas terdaftar sebagai SFH-1 (skor ML setengah REML), SFH-2 (SE dari informasi REML pada fit ML), dan SFH-3 (loglik ML walau REML) di `DISCREPANCIES.md`. Batas akhir $\rho = \pm 0.999$ dipetakan ke ± 1.0 persis tempat A singular lalu jatuh ke `pinv` (baris 389-399), sedangkan jalur bootstrap mempertahankan ± 0.999 — dua perilaku berbeda untuk kasus yang sama (SFH-4).

6.5 Estimasi MSE

Empat suku dihitung setelah loop konvergen (baris 481-543). Dengan $R = \mathbf{I} - G\mathbf{V}^{-1}\mathbf{X}$:

$$g_1 = \text{diag}(G - G\mathbf{V}^{-1}G), \quad (27)$$

$$g_2 = \text{diag}(RQR'), \quad (28)$$

$$g_3(i) = \text{tr}(L_i \mathbf{V}L_i' \mathcal{I}^{-1}), \quad (29)$$

$$g_4(i) = \frac{1}{2} D_{ii}, \quad (30)$$

dengan $L_i = (l'_{1i}, l'_{2i})'$, $l_1 = \mathbf{V}^{-1}D_1 - \sigma^2\mathbf{V}^{-1}D_1\mathbf{V}^{-1}D_1$, $l_2 = \mathbf{V}^{-1}D_2 - \sigma^2\mathbf{V}^{-1}D_2\mathbf{V}^{-1}D_1$, $D = (\Psi\mathbf{V}^{-1}D_{12})(\mathcal{I}_{01}^{-1} + \mathcal{I}_{10}^{-1}) + (\Psi\mathbf{V}^{-1}D_{22})\mathcal{I}_{11}^{-1}$, $\Psi = \text{diag}(\psi)$ (baris 512-541). Lalu

$$\widehat{\text{MSE}}(\hat{\theta}_d) = g_1 + g_2 + 2g_3 - g_4 \quad (\text{baris 543}), \quad \text{dan bila } \text{method} = \text{"ML"}: \widehat{\text{MSE}} -= \mathbf{b}'_{\text{ML}} \nabla g_1. \quad (31)$$

Koreksi bias ML (baris 546-571) memakai $b_a = -\text{tr}(Q\mathbf{X}'\mathbf{V}^{-1}D_a\mathbf{V}^{-1}\mathbf{X})$ dan $b_{\text{ML}} = \frac{1}{2}\mathcal{I}^{-1}b$, tetapi hanya menurunkan g_1 — suku lain tidak dikoreksi. Pada area tak-tersampel berlaku $\text{MSE} = g_1 + g_2$ saja (baris 596-599).

Varian bootstrap. Dua pilihan tambahan lewat `mse_method`:

- **"pbmse"**: bootstrap parametrik (15) — replikat $y^* = X\hat{\beta} + v^* + e^*$, $v^* = (\mathbf{I} - \rho W)^{-1}u^*$, $u^* \sim N(0, \hat{\sigma}^2)$; refit Fisher scoring penuh per replikat dalam region OpenMP (algoritme 1); skema batch menjamin tepat B replikat valid (`eb_lup_sf_h_pbmse.cpp:77-88`). Versi bias-koreksi (16) dihitung bersamaan. Kerangka bootstrap untuk EBLUP spasial dirujuk ke Molina et al. [2009].
- **"npbmse"**: bootstrap nonparametrik atas residual terstandarisasi; error sampling dan efek acak dipisahkan lewat eigen-dekomposisi Ψ_e dan Ψ_u (membuang p eigen terkecil, sesuai proyeksi desain), lalu indeks residual diresample; hanya untuk `method = "REML"` — pemeriksaannya berada di C++, bukan di R (`eb_lup_sf_h_npbmse.cpp:32-34`; SFH-9).

Kedua bootstrap berjalan pada subset area tersampel, lalu hasil fit ulang penuh ditimpa (baris tersampel) oleh hasil bootstrap (`R/eb_lup_sf_h.R:155-200`).

Algorithm 3:

```
1 Masukan formula, vardir, data, W (wajib), method, mse_method, B, n_threads,  
   seed Keluaran df_eblup (+ kolom bootstrap bila ada), rho, estvarcomp, goodness  
   ; // Lapis R  
2 method  $\leftarrow$  match.arg(toupper(...)) (100-101);  
3 gagal bila W kosong atau bukan  $n \times n$  (131-141);  
4 y  $\leftarrow$  respons (na.pass); Is  $\leftarrow$  !is.na(y) (144);  
5 if mse_method  $\in \{pbmse, npbmse\}$  then  
6   subset Xs, ys,  $\psi_s$ , Wss (155-158);  
7   rb  $\leftarrow$  .seblup_pbmse/.seblup_npbmse (161, 167);  
8   bila ada area tak-sampel: .seblup_core penuh, timpa baris Is dengan hasil  
   bootstrap, kolom bootstrap area tak-sampel  $\leftarrow$  NA (179-200)  
9 else  
10  .seblup_core(X, y,  $\psi$ , W, method, maxiter, precision) penuh (205-213)  
11 ;  
   ; // Lapis C++  
12 gagal bila W bukan bujur sangkar vs nrow(X) (223-225);  
13 Ins  $\leftarrow$  find_nonfinite(y); W  $\leftarrow$  W[Is, Is] (240-257);  
14 pra-hitung W', I, W'W, W + W' (279-284);  
15  $\sigma_u^2 \leftarrow$  median( $\psi$ );  $\rho \leftarrow 0.5$  (286-289);  
16 while diff > precision dan k < maxiter do  
17   A  $\leftarrow$   $(\mathbf{I} - \rho \mathbf{W}')'(\mathbf{I} - \rho \mathbf{W})$ ; A-1  $\leftarrow$  inv_sympd, fallback pinv (308-313);  
18    $\partial A / \partial \rho, \partial V / \partial \rho \leftarrow$  (23) (315-316);  
19   V  $\leftarrow$   $\sigma^2 \mathbf{A}^{-1} + \text{diag}(\psi)$ ; V-1  $\leftarrow$  inv_sympd, fallback pinv (318-320);  
20   Q  $\leftarrow$   $(\mathbf{X}' \mathbf{V}^{-1} \mathbf{X})^{-1}$ ; P  $\leftarrow$   $\mathbf{V}^{-1} - \mathbf{V}^{-1} \mathbf{X} \mathbf{Q} \mathbf{X}' \mathbf{V}^{-1}$  (323-331);  
21   if ML then  
22      $s_a \leftarrow -\frac{1}{2} \text{tr}(\mathbf{V}^{-1} \mathbf{D}_a) + \frac{1}{2} \mathbf{y}' \mathbf{P} \mathbf{D} \mathbf{P} \mathbf{y}$ ;  $\mathcal{I}_{ab} \leftarrow \frac{1}{2} \text{tr}(\mathbf{V}^{-1} \mathbf{D}_a \mathbf{V}^{-1} \mathbf{D}_b)$  (338-348)  
23   else  
24      $s_a, \mathcal{I}_{ab} \leftarrow$  (26) (349-357)  
25   ;  
26    $\Delta \leftarrow \mathcal{I}^{-1} s$ ; bila gagal: convergence = FALSE, hentikan (365-369);  
27    $\rho \leftarrow \text{clamp}(\rho + \Delta_\rho, -0.999, 0.999)$ ;  $\sigma_u^2 \leftarrow \sigma_u^2 + \Delta_\sigma$  (371-374);  
28    $\text{diff} \leftarrow \max_a |\Delta \theta_a / (\theta_a + 10^{-12})|$ ; non-finite  $\rightarrow$  gagal (376-383);  
29  $\rho_{\text{fix}} \leftarrow \rho$ ; bila  $= \pm 0.999 \rightarrow \pm 1.0$ ;  $\sigma^2 \leftarrow \max(0, \sigma_u^2)$  (389-394);  
30 bangun ulang A-1, G, V, V-1, Q,  $\hat{\beta}$ , resid (396-427);  
31  $\hat{\theta} \leftarrow$  (24); galat baku, z, p (normal) (451-462);  
32 loglik ML, AIC, BIC (464-476);  
33 g1, g2, g3, g4  $\leftarrow$  (27)-(30); MSE  $\leftarrow g_1 + g_2 + 2g_3 - g_4$  (481-543);  
34 if method = ML then  
35   koreksi MSE  $\leftarrow \mathbf{b}'_{\text{ML}} \nabla g_1$  (546-571)  
36 ;  
37 for d  $\in I_{ns}$  do  
38   kriging (25); MSE  $\leftarrow g_1 + g_2$  (576-604)  
39 ;  
40 RSE  $\leftarrow 100 \sqrt{\text{MSE}} / |\hat{\theta}|$ ; susun keluaran (621-669);
```

6.6 Pseudo-code

6.7 Signature, argumen, objek keluaran, dan contoh

Listing 5: Signature `eblup_sf` (R/`eblup_sf`.R:85-99).

```
eblup_sf(formula, vardir, domain = NULL, data,
         method = c("REML", "ML"),
         mse_method = c("analytical", "pbmse", "npbmse"),
         W = NULL, B = 100, n_threads = 1, seed = -1,
         maxiter = 100, precision = 1e-4, print_result = TRUE)
```

- `W` — matriks tetangga $n_{\text{total}} \times n_{\text{total}}$ (row-standar/sesuai skala yang diinginkan pengguna); *wajib*, tidak ada default.
- `mse_method` — "analytical" (default), "pbmse", "npbmse".
- `B` — jumlah replikat bootstrap (default 100); `n_threads` — > 0 memakai `omp_set_num_threads`, ≤ 0 memakai semua core; `seed = -1` berarti tidak menyentuh RNG R.
- `method` — REML (default) atau ML.

Objek keluaran: "fastsae" dengan `estcoef` (`beta`, `std.error`, `stderr_beta`, `zvalue`, `pvalue`), `random_effect_var`, `rho`, `estvarcomp` (2 baris: `sigma2_u`, `rho` — keduanya dari informasi REML), `goodness` (`loglikelihood`, `AIC`, `BIC`), `df_eblup` (`y`, `vardir`, `eblup`, `random_effect`, `mse`, `rse` + kolom bootstrap), `W`, `n_iter`, `convergence`, `model = "SFH"`, `level = "area"`. Kolom galat baku namanya `zvalue`, bukan `tvalue` seperti tertulis di dokumentasi (SFH-6).

Listing 6: Contoh yang dapat dijalankan (dari `man/eblup_sf`.Rd).

```
library(fastsae)
m1 <- eblup_sf(y ~ x1 + x2 + x3, data = mys, vardir = ~vardir,
              W = mys_proxmat)
m1$rho # autoregressive spatial parameter
m1$estvarcomp # sigma2_u and rho with std.error

m2 <- eblup_sf(y ~ x1 + x2 + x3, data = mys, vardir = ~vardir,
              W = mys_proxmat, mse_method = "pbmse", B = 50)
```

6.8 Referensi kunci

Pratesi and Salvati [2008] mengembangkan FH spasial; Rao and Molina [2015] menyajikan kerangka EBLUP yang dipakai untuk semua suku g ; blok `@references` fungsi ini hanya memuat Rao and Molina [2015] (R/`eblup_sf`.R:5-8). Referensi pembandingan implementasi: sae [Molina and Marhuenda, 2015].

7 Model Fay–Herriot spasio-temporal: `eblup_stfh`

7.1 Setting data dan kapan dipakai

Data harus berupa *panel lengkap*: satu baris per (domain, waktu) dengan tidak ada NA pada respons maupun `vardir`. Secara teknis `eblup_stfh()` menolak respons NA (`cli_abort`,

R/eblop_stfh.R:129-139) dan memeriksa `nrow(X) == D*T` — berbeda dengan dua model FH sebelumnya yang justru memakai NA sebagai penanda domain tanpa sampel. Model ini dipakai bila estimasi tersedia untuk T periode per domain dan kita ingin memakai kedua jenis korelasi: spasial antar domain dan temporal antar waktu dalam domain yang sama. Dokumentasi menyebutnya reimplementasi `sae::eblopSTFH` (R/eblop_stfh.R:3-8); rujukan utamanya Marhuenda et al. [2013].

7.2 Persamaan model

$$y_{dt} = x'_{dt}\beta + u_d^{(1)} + u_{dt}^{(2)} + e_{dt}, \quad e_{dt} \sim N(0, \psi_{dt}), \quad (32)$$

dengan dua komponen (penulisan *domain-major*, $M = D \times T$):

$$u^{(1)} \sim N(0, \sigma_1^2 \Omega_1 \otimes \mathbf{1}_T \mathbf{1}'_T), \quad \Omega_1 = [(\mathbf{I} - \rho_1 \mathbf{W})'(\mathbf{I} - \rho_1 \mathbf{W})]^{-1}, \quad (33)$$

$$u^{(2)} \sim N(0, \mathbf{I}_D \otimes \sigma_2^2 \Omega_2), \quad (\Omega_2)_{tt'} = \frac{\rho_2^{|t-t'|}}{1 - \rho_2^2}, \quad (34)$$

yaitu (i) efek spasial yang *konstan sepanjang waktu* dalam satu domain — karena $\mathbf{1}_T \mathbf{1}'_T$, seluruh titik waktu pada domain d berbagi $u_d^{(1)}$ yang sama — dan (ii) proses AR(1) per domain untuk $u^{(2)}$. Implementasinya persis `Va[0] = kron(Omega1, OnesT)` dan `Va[2] = kron(I_D, Omega2)` (baris 281, 289), sehingga setara dengan $Z_1 \Omega_1 Z_1'$ pada `sae::eblopSTFH`.

Implementation note. Struktur ini *bukan* salah satu interaksi Knorr–Held tipe I–IV: tidak ada interaksi spasial×temporal di mana efek spasial berubah tiap waktu. Model `model = "S"` mematikan struktur temporal ($\Omega_2 = \mathbf{I}$, $A_d = (\sigma_2^2 + \psi_{dt})$ diagonal). Perbedaan ini tercatat sebagai STFH-1 dan harus dipahami saat membaca hasil.

7.3 Prediktor titik

Dengan $r = y - \mathbf{X}\hat{\beta}$ (baris 427), kedua komponen acak diprediksi dari proyeksi spasial dan temporalnya (baris 430-453):

$$\hat{u}^{(1)} = (\sigma_1^2 \Omega_1 \otimes \mathbf{1}_T \mathbf{1}'_T) Z_1' \mathbf{V}^{-1} r, \quad \hat{u}_d^{(2)} = \sigma_2^2 \Omega_2 (\mathbf{V}^{-1} r)_d, \quad \hat{\theta}_{dt} = x'_{dt} \hat{\beta} + \hat{u}_d^{(1)} + \hat{u}_{dt}^{(2)}. \quad (35)$$

Karena eksistensi kuadrat kron tadi, $\hat{u}^{(1)}$ identik pada seluruh periode satu domain (kode memakai ekspansi konstan-waktu). Untuk `model = "S"` suku temporal menjadi $\sigma_2^2 (\mathbf{V}^{-1} r)$ (baris 444).

7.4 Estimasi komponen varians

Parameter: $\theta = (\sigma_1^2, \rho_1, \sigma_2^2, \rho_2)$ untuk "ST" ($n_{\text{param}} = 4$) dan $(\sigma_1^2, \rho_1, \sigma_2^2)$ untuk "S" ($n_{\text{param}} = 3$; baris 207-208). Nilai awal default 0.5 median(ψ) untuk varian dan 0.5 untuk korelasi (baris 201-203), semua dapat dioverride lewat argumen `*_start`. Skoring (baris 310-316) selalu berbentuk REML:

$$S_a = -\frac{1}{2} \text{tr}(PV_a) + \frac{1}{2} y' PV_a P y, \quad F_{ab} = \frac{1}{2} \text{tr}(PV_a PV_b), \quad P = \mathbf{V}^{-1} - \mathbf{V}^{-1} \mathbf{X} Q \mathbf{X}' \mathbf{V}^{-1}, \quad (36)$$

dengan V_a turunan parsial (33)–(34) (baris 276-289). Langkah $F^{-1} S$ (baris 319-323), ρ_1, ρ_2 di-clamp ± 0.999 (baris 326-331), σ^2 hanya dibatasi nonnegatif pada akhir (baris 346-347), konvergensi relatif $\leq 10^{-4}$ dengan maksimum 100 iterasi. Galat baku β dari $\sqrt{\text{diag}(Q)}$ dan galat baku komponen dari $\sqrt{\text{diag}(F^{-1})}$; nilai p dihitung dari distribusi *normal* meski kolomnya bernama `tvalue` (STFH-6), dan F^{-1} dievaluasi pada iterate sebelum update terakhir (STFH-7).

Inversi Woodbury. Karena $\mathbf{V}_A = \text{diag}$ blok per domain (temporal $T \times T$), inversi penuh $M \times M$ dihindari (baris 90-153):

$$\mathbf{V}^{-1} = \mathbf{V}_A^{-1} - \mathbf{V}_A^{-1} \mathbf{Z}_1 \mathbf{C}^{-1} \mathbf{Z}_1' \mathbf{V}_A^{-1}, \quad \mathbf{C} = \frac{\Omega_1^{-1}}{\sigma_1^2} + \text{diag}(\mathbf{Z}_1' \mathbf{V}_A^{-1} \mathbf{Z}_1), \quad (37)$$

dengan $\mathbf{C}$ berdimensi $D \times D$. Biaya inversi turun dari $O((DT)^3)$ menjadi $O(DT^3) + O(D^3)$, dan log-determinan memakai rantai setara $\log |\mathbf{V}| = \log |\mathbf{V}_A| + \log |\sigma_1^2 \Omega_1| + \log |\mathbf{C}|$ (baris 456-471). Memori tetap $O(M^2)$ karena $\mathbf{V}_A^{-1}$, $\mathbf{V}^{-1}$, P , dan n_{param} matriks turunan disimpan penuh.

7.5 Estimasi MSE

Tidak ada MSE analitik. Kolom `mse` dan `rse` diisi NA kecuali `compute_mse = TRUE` (R/eblup_stfh.R:269-272) — kebalikan dari `eblup_sfh()` yang selalu punya MSE analitik (STFH-2).

Dengan `compute_mse = TRUE`, bootstrap parametrik (STFH-3):

1. fit awal penuh pada data asli (baris 257-266);
2. bangkitkan $u^{(1)*} \sim N(0, \sigma_1^2 \Omega_1)$ lewat Cholesky Ω_1 , $u^{(2)*} \sim \text{AR}(1)$ ($u_0^* \sim N(0, \sigma_2^2/(1 - \rho_2^2))$, $u_t^* = \rho_2 u_{t-1}^* + N(0, \sigma_2^2)$), dan $\varepsilon^* \sim N(0, \psi)$ — *sekuensial, sebelum* region paralel (baris 303-337);
3. dalam `#pragma omp parallel for schedule(dynamic)`: $y^* = \mathbf{X}\hat{\beta} + u^{(1)*} + u^{(2)*} + \varepsilon^*$, lalu `fit_stfh_eblup_only` yang menghitung ulang β dan memakai Woodbury, tetapi *komponen varian tidak diestimasi ulang* (komentar baris 91, 368);
4. akumulasi $\widehat{\text{MSE}} = \frac{1}{n_{\text{valid}}} \sum_b (\hat{\theta}_b^* - \theta_b^*)^2$ (baris 386-412).

Implementation note. Pembagi adalah jumlah replikat valid, sehingga efektifnya bisa $< B$ yang diminta, dan `res$B` dikembalikan sebagai n_{valid} (STFH-21); SFH sebaliknya memaksa tepat B replikat valid. Skema ini juga *fixed- θ* : `sae::pbmseSTFH` mengestimasi ulang komponen varian tiap replikat, dan tidak ada versi bias-koreksi seperti SFH (STFH-3).

7.6 Pseudo-code

7.7 Signature, argumen, objek keluaran, dan contoh

Listing 7: Signature `eblup_stfh` (R/eblup_stfh.R:103-122).

```
eblup_stfh(formula, vardir, data, domain, time, W,
  model = c("ST", "S"), maxiter = 100, precision = 1e-4,
  sigma21_start = NULL, rho1_start = 0.5,
  sigma22_start = NULL, rho2_start = 0.5,
  compute_mse = FALSE, B = 100, n_threads = 1, seed = -1,
  print_result = TRUE)
```

- `domain`, `time` — nama kolom/kolom formula penanda domain dan waktu (wajib; panel harus lengkap).
- `W` — matriks tetangga $D \times D$ (hanya antar domain, tanpa dimensi waktu).
- `model` — "ST" (default, AR(1) temporal) atau "S" (tanpa struktur temporal).

Algorithm 4:

```
1 Masukan formula, vardir, data, domain, time, W ( $D \times D$ ), model  $\in \{ST, S\}$ , nilai  
   awal, compute_mse, B, n_threads, seed Keluaran df_eblup (per domain  $\times$  waktu),  
   estvarcomp, goodness ; // Lapis R  
2 gagal bila respons/vardir mengandung NA (129-139, 152);  
3 gagal bila nrow(X)  $\neq D \times T$  atau W bukan  $D \times D$  (163-181);  
4 validasi sigma*_start  $\geq 0$  dan rho_start  $\in (-1, 1)$  (184-195);  
5  $\theta^{(0)} \leftarrow$  argumen, atau  $-1$  untuk “pakai default” (208-210);  
6  $\hat{\theta}, \dots \leftarrow$  .eblup_stfh_core (198-212);  
7 if compute_mse then  
8   | MSE  $\leftarrow$  .pbmse_stfh (241-266)  
9 else  
10  | mse = rse = NA; B = NA (269-272)  
11 ;  
12 method  $\leftarrow$  "REML" ; // hard-coded (225)  
   ; // Lapis C++  
13  $\sigma_1^2 \leftarrow 0.5 \text{ median}(\psi)$  (bila  $< 0$ );  $\rho_{1,2} \leftarrow$  argumen (201-205);  $\theta_0 \leftarrow (\sigma_1^2, \rho_1, \sigma_2^2, \rho_2)$   
   (223-227);  
14 while diff  $>$  precision dan k  $<$  maxiter do  
15   |  $\Omega_1 \leftarrow [(\mathbf{I} - \rho_1 \mathbf{W})'(\mathbf{I} - \rho_1 \mathbf{W})]^{-1}$ ;  $V_{u1} \leftarrow \sigma_1^2 \Omega_1$  (74-80);  
16   for domain d do  
17     |  $A_d \leftarrow \sigma_2^2 \Omega_2 + \text{diag}(\psi_d)$  ( $T \times T$ ), inversi; atau  $1/(\sigma_2^2 + \psi)$  untuk "S" (96-123)  
18     ;  
19      $V^{-1} \leftarrow V_A^{-1} - (V_A^{-1} Z_1) \mathbf{C}^{-1} (V_A^{-1} Z_1)$ ,  $\mathbf{C}$   $D \times D$  (37) (139-153);  
20      $Q \leftarrow (\mathbf{X}' V^{-1} \mathbf{X})^{-1}$ ;  $P \leftarrow V^{-1} - V^{-1} \mathbf{X} Q \mathbf{X}' V^{-1}$  (265-274);  
21      $V_a \leftarrow$  turunan (33)–(34) (276-289);  
22      $S, F \leftarrow$  (36) (292-316);  
23      $\theta_{k+1} \leftarrow \theta_k + F^{-1} S$ ;  $\rho_{1,2} \leftarrow \text{clamp}(\cdot, \pm 0.999)$  (319-331);  
24     diff  $\leftarrow \max |(\theta_{k+1} - \theta_k) / \max(\theta_k, 10^{-4})|$  (334-336);  
25 if tidak konvergen then  
26   | kembalikan semua komponen NULL, convergence = FALSE (236-246, 339-341)  
27 ;  
28  $\sigma^2 \leftarrow \max(0, \cdot)$ ;  $\hat{\beta} \leftarrow Q \mathbf{X}' V^{-1} y$ ;  $r \leftarrow y - \mathbf{X} \hat{\beta}$  (346-427);  
29  $\hat{u}^{(1)}, \hat{u}^{(2)} \leftarrow$  (35);  $\hat{\theta} \leftarrow \mathbf{X} \hat{\beta} + \hat{u}^{(1)} + \hat{u}^{(2)}$  (430-453);  
30  $\log |\mathbf{V}| \leftarrow \log |\mathbf{V}_A| + \log |\sigma_1^2 \Omega_1| + \log |\mathbf{C}|$ ; loglik, AIC, BIC (456-479);  
31 galat baku  $\beta$ , komponen varian, p (normal) (482-512);  
32 susun estcoef, estvarcomp, df_eblup (eblup, random_effect_u1,  
   random_effect_u2) (520-535);
```

- `compute_mse` — FALSE (default) menghasilkan `mse = NA`; TRUE menjalankan bootstrap parametrik.

Objek keluaran: "fastsae" berisi `estcoef` (`beta`, `std.error`, `tvalue`, `pvalue`), `estvarcomp` (4 atau 3 baris `estimate`, `std.error`), `goodness` (`loglike`, `AIC`, `BIC` — nama kolom berbeda dari SFH, STFh-15), `df_eblup` dengan kolom `domain`, `time`, `y`, `eblup`, `varidir`, `mse`, `rse`, `mse_pb`, `random_effect_u1`, `random_effect_u2`, `convergence`, `n_iter`, `method` = "REML".

Listing 8: Contoh yang dapat dijalankan (dari `man/eblup_stfh.Rd`); panel dibuat lengkap dengan penyaringan.

```
library(fastsae)
library(dplyr)

mys_panel_nona <- mys_panel |>
  filter(!is.na(y) & year ≥ 2024)

m1 <- eblup_stfh(y ~ x1 + x2 + x3, data = mys_panel_nona,
  varidir = ~varidir, domain = ~area, time = ~year,
  W = mys_proxmat[-c(21, 25), -c(21, 25)], model = "ST")

# dengan bootstrap MSE
m2 <- eblup_stfh(y ~ x1 + x2 + x3, data = mys_panel_nona,
  varidir = ~varidir, domain = ~area, time = ~year,
  W = mys_proxmat[-c(21, 25), -c(21, 25)], model = "ST",
  compute_mse = TRUE, B = 100, seed = 42)
```

7.8 Referensi kunci

Marhuenda et al. [2013] adalah rujukan model dan sekaligus rujukan yang disebut roxygen (`R/eblup_stfh.R:10–16`) bersama Rao and Molina [2015]; gabungan data deret waktu dengan potongan lintas bagian yang menjadi dasar model semacam ini dirintis Rao and Yu [1994]. Implementasi pembandingnya sae [Molina and Marhuenda, 2015]. Seluruh rujukan terdaftar di `references.bib`.

8 Model unit-level Battese–Harter–Fuller: `eblup_bhf`

8.1 Setting data dan kapan dipakai

Model ini membutuhkan dua sumber data yang berbeda:

- `unit_data` — satu baris per unit sampel: respons y_j , kovariat x_j , dan label domain;
- `Xpop` — *rata-rata kovariat populasi* per domain ($\bar{x}_{\text{pop},d}$) beserta ukuran populasi `popsiz` (N_d).

Cocok ketika tersedia mikrodta survei (unit) dan ringkasan populasi per domain. Dataset contoh `cornsoybean` (37 unit di 12 kabupaten Iowa) bersama `cornsoybeanmeans` adalah data klasik BHF [Battese et al., 1988]. Catatan penting: `Xpop` harus berisi *semua* domain pada sampel — bila ada domain sampel yang tidak ada di `Xpop`, C++ melempar error, berbeda dengan `sae::eblupBHF` yang mengembalikan NA disertai peringatan (BHF-6).

8.2 Persamaan model

$$y_{ij} = x'_{ij}\beta + u_i + e_{ij}, \quad u_i \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2), \quad e_{ij} \sim N(0, \sigma_e^2), \quad (38)$$

dengan $i = 1, \dots, D$ domain, $j = 1, \dots, n_i$ unit sampel, dan N_i unit populasi. Model ini model komponen-kesalahan (*error components*) — tanpa struktur spasial — yang diperkenalkan Battese et al. [1988]. Penting: karena hanya *ringkasan* populasi yang masuk ($\bar{x}_{\text{pop},d}$ dan N_d), model tidak membutuhkan mikrodta populasi.

8.3 Prediktor titik

Estimasi komponen varian tidak ditulis sendiri: `eb lup_bhf()` memanggil `lme4::lmer` [Bates et al., 2015] dengan formula campuran `y ~ x1 + x2 + ... + (1|dom)` dan `REML = (method == "REML")` (R/`eb lup_bhf.R`:73-82):

$$\begin{aligned} \hat{\beta} &= \text{fixef}(\text{fit}), & \hat{\sigma}_u^2 &= \text{VarCorr}(\text{fit})\$dom[1,1], \\ \hat{\sigma}_e^2 &= \text{attr}(\text{VarCorr}(\text{fit}), "sc")^2, & \hat{u}_d &= \text{ranef}(\text{fit})\$dom. \end{aligned} \quad (39)$$

Setelah itu seluruh penyusunan prediktor ada di C++ dengan fraksi sampel $f_d = n_d/N_d$ (baris 64):

$$\hat{\theta}_d = f_d \bar{y}_{s,d} + (\bar{x}_{\text{pop},d} - f_d \bar{x}_{s,d})' \hat{\beta} + (1 - f_d) \hat{u}_d, \quad (40)$$

untuk domain dengan $n_d > 0$ (baris 80-91), dan prediktor sintetis murni

$$\hat{\theta}_d = \bar{x}'_{\text{pop},d} \hat{\beta}, \quad \text{samp_size} = 0, \text{ peringatan} \quad (41)$$

untuk domain tanpa unit sampel (baris 94-100, lalu `cli_warn` di R, baris 128-132).

Implementation note. (40) identik dengan rumus yang dipakai `sae::eb lupBHF` dan ekuivalen dengan $f_d \bar{y}_s + (1 - f_d)(\bar{x}'_{\text{unsamp}} \hat{\beta} + \hat{u}_d)$ — *bukan* bentuk alternatif $f_d \bar{y} + (1 - f_d)(\bar{x}'_{\text{pop}} \hat{\beta} + \hat{u}_d)$ yang kadang dipakai ketika seluruh populasi dianggap tersensus (BHF-9). Pilihan ini masuk akal untuk BHF asli di mana hanya n_d unit yang disurvei.

8.4 Estimasi komponen varians

Fisher scoring tidak dipakai di sini; estimasi dilakukan penuh oleh `lme4` (Newton-type pada likelihood campuran), sesuai `method` ML atau REML. Konsekuensi terhadap objek keluaran:

- `estcoef` memuat kolom `beta`, `std.error`, `stderr_beta`, `tvalue`, `zvalue`, `pvalue`, di mana `zvalue` = t-value `lmer` dan `pvalue` = $2 \Phi(-|t|)$ — `lmer` sendiri tidak menyediakan p-value (BHF-8).
- Tidak ada `goodness` (loglik/AIC/BIC) dan tidak ada `n_iter`; `convergence` di-hardcode TRUE bila tidak ada error, karena kegagalan `lmer` melempar error langsung (BHF-7).

8.5 Estimasi MSE

MSE *hanya* bootstrap parametrik dan hanya bila `compute_mse` = TRUE (default FALSE → `mse` = `rse` = NA). Skemanya ada di R (R/`eb lup_bhf.R`:215-369), serial, tanpa OpenMP (BHF-1): tiap replikat

1. bangkitkan $u_i^* \sim N(0, \hat{\sigma}_u^2)$ untuk semua domain dan $e_{ij}^* \sim N(0, \hat{\sigma}_e^2)$ untuk semua unit sampel, lalu $y_{ij}^* = x'_{ij} \hat{\beta} + u_i^* + e_{ij}^*$ (baris 295-305);

2. refit `lmer` pada y^* ; bila gagal, replikat dilewati *tanpa mengurangi pembagi* (baris 308-320); EBLUP ulang lewat `.eblup_bhf_cpp` (baris 323-332);
3. nilai “kebenaran” populasi replikat (baris 335-354): $\mu_d = \bar{x}'_{\text{pop},d}\hat{\beta}$; bila $r_d = N_d - n_d > 0$, $\theta_d^{*,\text{true}} = \mu_d + \frac{n_d}{N_d}\bar{e}_{s,d}^* + \frac{r_d}{N_d}\mathcal{N}(0, \hat{\sigma}_e^2/r_d)$; bila $r_d = 0$ (enumerasi penuh) hanya $\bar{e}_{s,d}^*$; bila $n_d = 0$, $\mu_d + u_d^* + \mathcal{N}(0, \hat{\sigma}_e^2/N_d)$;
4. akumulasi $(\hat{\theta}_d^* - \theta_d^{*,\text{true}})^2$ dan bagi dengan B (baris 356-360).

Implementation note. Pembagi selalu B meski ada replikat yang dilewati, sehingga MSE ter-bias ke bawah ketika `lmer` gagal; `sae::pbmseBHF` hanya menaikkan penghitung bila refit sukses (BHF-4). Default juga berbeda: $B = 100$ di sini, $B = 200$ pada `sae` (BHF-2). `seed = -1` (default) artinya tanpa seed (BHF-3), dan argumen `popnmean_xpop` tidak diteruskan ke bootstrap, sehingga matriks rata-rata populasi untuk titik estimasi bisa berbeda dari yang dipakai bootstrap (BHF-5).

RSE dihitung $100\sqrt{\text{MSE}}/|\hat{\theta}|$ dengan guard $|\hat{\theta}| < .\text{Machine}\$double.eps \rightarrow \text{NA}$ (baris 161-164).

8.6 Pseudo-code

8.7 Signature, argumen, objek keluaran, dan contoh

Listing 9: Signature `eblup_bhf` (R/`eblup_bhf.R`:44-57).

```
eblup_bhf(formula, unit_data, Xpop, domain_var, popsize_var,
  method = c("REML", "ML"), popnmean_xpop = NULL,
  B = 100, compute_mse = FALSE, n_threads = 1,
  seed = -1, print_result = TRUE)
```

- `Xpop` — data frame berisi kolom domain (sebagai `domain_var`, bukan nama kolom) dan kolom kovariat yang sama dengan formula; nilainya rata-rata populasi.
- `popsize_var` — nama kolom ukuran populasi N_d pada `Xpop`.
- `popnmean_xpop` — matriks alternatif rata-rata populasi (opsional).
- `n_threads` — didokumentasikan tetapi tidak pernah dipakai (BHF-1).
- `compute_mse` — FALSE (default): kolom `mse`, `rse` diisi NA.

Objek keluaran: list berkelas `c("fastsae", "fastsae_unit")` berisi `df_eblup` (domain, `eblup`, `samp_size`, `mse`, `rse`), `estcoef`, `random_effect_var` ($\hat{\sigma}_u^2$), `fit` berisi `method`, `random_effect_var`, `sigma2_e`, `beta`, `random_effect`, `lme` (objek `lmer` asli), `formula`, `model = "BHF"`, `level = "unit"`, `convergence = TRUE`, `data`, `call`. *Tidak ada goodness dan n_iter.*

Listing 10: Contoh yang dapat dijalankan (dari `man/eblup_bhf.Rd`).

```
library(dplyr)
df_meanpop <- cornsoybeanmeans |>
  rename(CornPix = MeanCornPixPerSeg, SoyBeansPix = MeanSoyBeansPixPerSeg)
df_cornsoybean <- cornsoybean |>
  rename(CountyIndex = County)

res <- eblup_bhf(
```

Algorithm 5:

```
1  Masukan formula, unit_data, Xpop, domain_var, popsize_var, method,  
   compute_mse, B, seed Keluaran df_eblup (domain, eblup, samp_size, mse, rse),  
   fit (objek lmer) mf  $\leftarrow$  model.frame(formula, na.action = na.omit); dom  
   dipotong mengikuti baris ter-omit (61-65);  
2  selectdom  $\leftarrow$  unique(dom); digabung dengan domain Xpop lalu Xpop diurutkan sebaris  
   (88-89);  
3  Xs  $\leftarrow$  model.matrix; gagal bila ada NA (66-72);  
4  fit  $\leftarrow$  lme4::lmer(y ~ ..., (1|dom), REML = (method == "REML")) (73-82);  
5   $\hat{\beta}, \hat{u}_d, \hat{\sigma}_u^2, \hat{\sigma}_e^2 \leftarrow$  (39) (83-108);  
6  meanxpop  $\leftarrow$  model.matrix atas Xpop, atau argumen popnmean_xpop (92-104);  
7   $\hat{\theta} \leftarrow$  .eblup_bhf_cpp(selectdom, dom, Xs, meanxpop, ys, popnsize, betah,  
   upred) (111-120);  
8  if domain sampel tidak ada di Xpop then  
9  | gagal (C++, src/eblup_unit.cpp:23-31)  
10 ;  
11 if compute_mse then  
12 | MSE  $\leftarrow$  .pbmse_unit(...) (145-150)  
13 else  
14 | mse = rse = NA  
15 ;  
16 perakitan df_eblup, estcoef, kelas c("fastsae", "fastsae_unit") (156-211);  
17 Data ; // Bootstrap parametrik -- R/eblup_bhf.R:215-369, serial  
18 if seed  $\geq 0$  then  
19 | set.seed(seed) (285)  
20 ;  
21 for b = 1, ..., B do  
22 |  $u^* \sim N(0, \hat{\sigma}_u^2)$  semua domain;  $e^* \sim N(0, \hat{\sigma}_e^2)$  semua unit sampel (295-298);  
23 |  $y^* \leftarrow X\hat{\beta} + u_{d(j)}^* + e_j^*$  (301-305);  
24 | fit  $\leftarrow$  lmer(...) pada  $y^*$ ;  
25 | if fit gagal then  
26 | | next ; // 317: tanpa mengurangi pembagi  
27 |  $\hat{\beta}^*, \hat{u}^* \leftarrow$  fit*;  $\hat{\theta}^* \leftarrow$  .eblup_bhf_cpp dengan  $y^*$  (319-332);  
28 |  $\theta_d^{*, \text{true}} \leftarrow$  tiga kasus pada langkah 3 bagian 8.5 (335-354);  
29 | akumulasi  $(\hat{\theta}_d^* - \theta_d^{*, \text{true}})^2$  (356-357);  
30 MSE  $\leftarrow$  akumulasi/B (360); RSE  $\leftarrow 100\sqrt{\text{MSE}}/|\hat{\theta}|$  (161-164);
```

```

formula = CornHec ~ CornPix + SoyBeansPix,
Xpop = df_meanpop,
unit_data = df_cornsoybean,
domain_var = "CountyIndex",
popsize_var = "PopnSegments"
)
head(res$df_eblup)

```

8.8 Referensi kunci

Blok roxygen fungsi ini memuat [Battese et al. \[1988\]](#) (R/eblup_bhf.R:22-25); kerangka EBLUP unit-level dan MSE dibahas di [Rao and Molina \[2015\]](#); perbandingan numeriknya sae [[Molina and Marhuenda, 2015](#)]; pemakaian lme4 mengacu ke [Bates et al. \[2015\]](#).

9 Model sub-area dua-lipat: eblup_twofold

9.1 Setting data dan kapan dipakai

Data memiliki tiga tingkat: area (mis. kabupaten), *sub-area* di dalam area (mis. kecamatan), dan unit sampel di dalam sub-area. Satu baris data = satu unit sampel, dengan kolom penanda `domain` (area) dan `subarea`. Model ini dipakai ketika tersedia kovariat pada tingkat unit tetapi target estimasi pada dua tingkat sekaligus (area dan sub-area), termasuk sub-area yang tidak tersampel. Rujukan aslinya [Torabi and Rao \[2014\]](#); roxygen fungsi ini menyebut model dua-lipat tanpa mengutip DOI (R/eblup_twofold.R:7-14).

9.2 Persamaan model

Dua tingkat persamaan (komentar `eblup_tfh.cpp:4-8`):

$$y_{ij} = \theta_{ij} + e_{ij}, \quad e_{ij} \sim N(0, \psi_{ij}), \quad (42)$$

$$\theta_{ij} = x'_{ij}\beta + v_i + u_{ij}, \quad v_i \sim N(0, \sigma_v^2), \quad u_{ij} \sim N(0, \sigma_u^2), \quad (43)$$

dengan v_i = efek area (notasi kode: `s2v`) dan u_{ij} = efek sub-area (`s2u`). Untuk tiap area d kovariasinya adalah

$$V_d = \sigma_v^2 \mathbf{1}\mathbf{1}' + \text{diag}(\sigma_u^2 + \psi_d), \quad S_d = \sigma_v^2 \mathbf{1}\mathbf{1}' + \sigma_u^2 \mathbf{I}, \quad (44)$$

dan inversinya memakai identitas Sherman–Morrison per blok (2) (biaya $O(n_d)$, bukan $O(n_d^3)$).

9.3 Prediktor titik

$$\hat{v}_i = \sigma_v^2 \mathbf{1}' V^{-1} r, \quad \hat{u}_{ij} = \sigma_u^2 (V^{-1} r)_{ij}, \quad \hat{\theta}_{ij} = x'_{ij} \hat{\beta} + \hat{v}_i + \hat{u}_{ij}, \quad (45)$$

dengan $r = y - \mathbf{X}\hat{\beta}$ dan V^{-1} per blok lewat (2) (baris 351-353). Tiga kasus domain (baris 333-363):

- sub-area tersampel pada area tersampel: (45);
- sub-area *tak*-sampel pada area tersampel: $\hat{\theta}_{ij} = x'_{ij} \hat{\beta} + \hat{v}_i$ dan $\hat{u} = 0$ (data hilang hanya menyisakan informasi area);

- area tanpa sub-area tersampel sama sekali: $\hat{\theta} = x'\hat{\beta}$ (prediktor sintetis).

Domain tanpa sampel didefinisikan lewat respons $y = \text{NA}$ (baris 290-292), sama seperti FH. Validasi mensyaratkan minimal dua area tersampel dan $N_s > p$ (baris 301, 311).

9.4 Estimasi komponen varians

Fisher scoring dua parameter (σ_v^2, σ_u^2) , nilai awal $0.5 \text{median}(\psi)$ keduanya (baris 181-182), toleransi 10^{-4} , maksimum 100 iterasi (baris 186). Per iterasi (fungsi `tfh_pass`, baris 80-169) dihitung $Q = (\mathbf{X}'V^{-1}\mathbf{X})^{-1}$, $r = V^{-1}(y - \mathbf{X}\hat{\beta})$, lalu skor dan informasi:

$$s_v = -\frac{1}{2}q_d + \frac{1}{2}(\mathbf{1}'r)^2, \quad s_u = -\frac{1}{2}\text{tr } P + \frac{1}{2}r'r, \quad q_d = \mathbf{1}'V^{-1}\mathbf{1} - (\mathbf{X}'V^{-1}\mathbf{1})'Q(\mathbf{X}'V^{-1}\mathbf{1}), \quad (46)$$

$$\mathcal{I}_{vv} = \frac{1}{2}q_d^2, \quad \mathcal{I}_{uu} = \frac{1}{2}\text{tr}(P^2), \quad \mathcal{I}_{vu} = \frac{1}{2}[\mathbf{1}'V^{-1}\mathbf{1} - 2\mathbf{z}'Q\bar{x} + \bar{x}'QM\bar{x}], \quad (47)$$

untuk REML (baris 131-151); untuk ML (baris 152-158) suku $\text{tr } P$ dan q_d diganti oleh $\mathbf{1}'V^{-1}\mathbf{1}$ dan $\text{tr } V$. Langkah $\Delta = \mathcal{I}^{-1}s$ dengan fallback diagonal $s_k/\mathcal{I}_{kk}$ bila inversi gagal (baris 193-204), nilai negatif dipaksa 0 (baris 210-211), dan konvergensi relatif (baris 213-215).

Implementation note. Dua hal yang tidak ada pada FH: (i) varian estimasi komponen diambil dari *invers matriks informasi Fisher* final, bukan bentuk tertutup $\text{Var}(\hat{\sigma}^2) = 2/\sum w^2$ (TFH-3); (ii) loglik REML dihitung benar, $\ell_R = -\frac{1}{2}[(n-p)\log 2\pi + \text{core} + \log |\mathbf{X}'V^{-1}\mathbf{X}| - \log |\mathbf{X}'\mathbf{X}|]$ (baris 259-265), berbeda dengan FH dan SFH yang selalu memakai bentuk ML (TFH-9 juga: dasar AIC/BIC memakai jumlah area dengan sub-area tersampel, bukan jumlah baris).

9.5 Estimasi MSE

Analitik (default). Untuk sub-area tersampel (baris 369-411):

$$g_1 = \text{diag}(S - SV^{-1}S), \quad (48)$$

$$g_2 = \text{diag}(DQD'), \quad D = (\mathbf{I} - SV^{-1})\mathbf{X}_d, \quad (49)$$

$$g_3 = \mathbb{E}_{vv} \text{var}_v + \mathbb{E}_{uu} \text{var}_u + 2\mathbb{E}_{vu} \text{cov}_{vu}, \quad (50)$$

di mana $\text{var}_v, \text{var}_u, \text{cov}_{vu}$ adalah elemen $(\mathcal{I}^{-1})$ final (baris 324, 407) dan $\mathbb{E}_{uu} = \text{diag}(M_u V M_u')$ dengan $M_u = V^{-1} - SV^{-2}$, sedangkan $M_v = \mathbf{1}(\mathbf{1}'V^{-1})' - SV^{-1}\mathbf{1}(\mathbf{1}'V^{-1})'$ (baris 395-406). Totalnya

$$\widehat{\text{MSE}} = g_1 + g_2 + g_3, \quad (51)$$

bukan $g_1 + g_2 + 2g_3$: faktor dua pada suku silang sudah termasuk di dalam g_3 persis seperti tertulis di komentar kode.

Implementation note. Di sinilah perbedaan paling menonjol dengan publikasi. Komentar kode (`eblup_tfh.cpp:19-24`) menyatakan bahwa persamaan (3.4) Torabi and Rao [2014] mengandung suku $[A][B]$ yang semu dan koefisien varian u yang salah bentuk (plus tanda salah pada lampiran), sehingga pendekatan matriks g_3 dipakai dan divalidasi dengan turunan beda pemisah (korelasi 0,97/0,96/0,74 terhadap uji numerik). Laporan ini melaporkannya sebagai TFH-1: apa yang dikodekan adalah pendekatan matriks, bukan rumus tertutup Torabi–Rao.

Untuk sub-area tak-sampel (baris 415-468): area tanpa sub-area tersampel memperoleh $x'Qx + \sigma_v^2 + \sigma_u^2$ (baris 421-427); sub-area tak-sampel pada area tersampel memperoleh $g_1^* + g_2^* + g_3^*$ dengan $g_1^* = \sigma_v^2 - \sigma_v^4(\mathbf{1}'V^{-1}\mathbf{1}) + \sigma_u^2$ dan $g_2^* = (x - \sigma_v^2\mathbf{X}'V^{-1}\mathbf{1})'Q(x - \sigma_v^2\mathbf{X}'V^{-1}\mathbf{1})$ (baris 445-464). Nilai negatif dalam rentang $(-10^{-8}, 0)$ dipangkas ke 0; lebih negatif dibiarkan sehingga RSE menjadi NaN (TFH-8).

Bootstrap parametrik. Dengan `mse = "bootstrap"` (default $B = 200$): semua gambaran dibuat lebih dulu secara sekuensial ($v^* \in \mathbb{R}^{m \times B}$, $u^* \in \mathbb{R}^{N \times B}$, $e^* \in \mathbb{R}^{N_s \times B}$; baris 475-478), lalu region `#pragma omp parallel for schedule(static)` (baris 481) berjalan per replikat: $\theta^* = \mathbf{X}\hat{\beta} + v_i^* + u_j^*$, $y^* = \theta_{\text{sampel}}^* + e^*$, refit Fisher scoring penuh, prediktor bootstrap dengan prediktor yang sama seperti estimasi titik (termasuk cabang tak-sampel), dan $\widehat{\text{MSE}} = \text{rata}((\hat{\theta}^* - \theta^*)^2)$ (baris 486-517). Karena semua RNG dipanggil sebelum pragma, hasil tidak bergantung jumlah thread (TFH-6: pemakaian prediktor yang sama persis juga dinyatakan kode sebagai perbaikan bug).

9.6 Pseudo-code

9.7 Signature, argumen, objek keluaran, dan contoh

Listing 11: Signature `eblup_twofold` (R/`eblup_twofold.R`:65-78). Aliasing: `eblup_tfh <- eblup_twofold` (baris 150-151).

```
eblup_twofold(formula, vardir, domain = NULL, subarea = NULL, data,
              method = c("REML", "ML"),
              mse = c("analytical", "bootstrap"),
              B = 200, seed = NULL, maxiter = 100,
              precision = 1e-4, print_result = TRUE)
```

- `domain` — wajib (bila NULL fungsi berhenti); `subarea` — opsional, default penomoran unit.
- `mse` — "analytical" (default) atau "bootstrap" (B default 200).
- `seed` — dipanggil pada semua jalur, bukan hanya bootstrap (TFH-7).

Objek keluaran: "fastsae" berisi `random_effect_var` bernama `sigma2_v` (area) dan `sigma2_u` (sub-area), `estcoef`, `df_eblup`, `goodness` (loglikelihood, AIC, BIC dengan $\text{AIC} = -2\ell + 2(p+2)$ dan $\text{BIC} = -2\ell + (p+2) \log m_{\text{fit}}$), `n_iter`, `convergence`, `method = "eblup"`, `level = "subarea"`, `model = "TWOFOOLD"`.

Listing 12: Contoh yang dapat dijalankan (dari `man/eblup_twofold.Rd`); membutuhkan kolom penanda area dan sub-area.

```
library(fastsae)
m1 <- eblup_twofold(y ~ x1 + x2, data = your_data, vardir = "vardir",
                  domain = "area", subarea = "kec")
m1$random_effect_var      # sigma2_v (area), sigma2_u (subarea)

m2 <- eblup_twofold(y ~ x1 + x2, data = your_data, vardir = "vardir",
                  domain = "area", subarea = "kec",
                  mse = "bootstrap", B = 100, seed = 42)
```

9.8 Referensi kunci

Rujukan model dua-lipat: [Torabi and Rao \[2014\]](#) (disebut DESCRIPTION beserta DOI-nya dan menjadi dasar komentar kode `eblup_tfh.cpp`:19-24); kerangka EBLUP: [Rao and Molina \[2015\]](#); pembandingan: `sae` [[Molina and Marhuenda, 2015](#)].

Algorithm 6:

```
1 Masukan formula, vardir, domain (wajib), subarea, method, mse, B, seed, maxiter,  
   precision Keluaran df_eblup (area × sub-area), random_effect_var = ( $\sigma_v^2, \sigma_u^2$ ),  
   goodness domain  $\leftarrow$  wajib (81-83); subarea  $\leftarrow$  seq_len(nrow(data)) bila NULL  
   (85-89);  
2 area_idx  $\leftarrow$  as.integer(factor(domain)) - 1L; // 0-based (107)  
3 if seed tidak NULL then  
4   | set.seed(seed) (109)  
5 ;  
6 ...  $\leftarrow$  .eblup_tfh_core(X, y,  $\psi$ , area, method, mse_type, B, maxiter,  
   precision) (111-121);  
7 Data; // Lapis C++  
8 gagal bila method/mse_type tak sah,  $N_s \leq p$ ,  $\psi \leq 0$ , atau area tersampel  $< 2$   
   (281-311);  
9  $\sigma_v^2 \leftarrow \sigma_u^2 \leftarrow 0.5 \text{ median}(\psi)$  (181-182);  
10 while diff  $>$  precision dan  $k <$  maxiter do  
11   | per blok  $d$ :  $V_d^{-1}a \leftarrow$  (2) (98-108, 345-350);  
12   |  $\hat{\beta}, r, q_d, \text{tr } P, \text{tr } V, \text{tr } P^2 \leftarrow$  akumulasi (110-145);  
13   | if ML then  
14   |   |  $s, \mathcal{I} \leftarrow$  bentuk ML (152-158)  
15   | else  
16   |   |  $s, \mathcal{I} \leftarrow$  (46)–(47) (131-151)  
17   | ;  
18   |  $\Delta \leftarrow \mathcal{I}^{-1}s$ ; bila inversi gagal  $\rightarrow \Delta_k = s_k / \mathcal{I}_{kk}$  (193-204);  
19   |  $\sigma_k^2 \leftarrow \max(\sigma_k^2 + \Delta_k, 0)$ ; non-finite  $\rightarrow$  nilai lama (206-211);  
20   |  $\text{diff} \leftarrow \max_k |(\sigma_k^{2(\text{new})} - \sigma_k^2) / \max(\sigma_k^2, 10^{-12})|$  (213-215);  
21 pass final pada varian final:  $\hat{\beta}, Q, \mathcal{I}^{-1}$  (223-237);  
22  $\hat{\theta} \leftarrow$  (45), termasuk cabang tak-sampel (333-363);  
23 if mse = analytical then  
24   |  $g_1, g_2, g_3 \leftarrow$  (48)–(50); MSE  $\leftarrow$  (51) per baris tersampel (369-411); cabang  
   | tak-sampel (415-468)  
25 else  
26   |  $v^*, u^*, e^* \leftarrow$  bangkit sekuensial (475-478);  
27   | #pragma omp parallel for schedule(static) (481);  
28   | for  $b = 0, \dots, B - 1$  parallel do  
29   |   |  $\theta^*, y^* \leftarrow$  (486-488); refit tfh_fit (490-491); SqDiff[:,  $b$ ]  $\leftarrow (\hat{\theta}^* - \theta^*)^2$  (495-517)  
30 ;  
31  $\ell, \text{AIC}, \text{BIC} \leftarrow$  loglik ML/REML, dasar  $m_{\text{fit}}$  (239-267, 545-548);  
32 susun df_eblup (domain, subarea, y, eblup, vardir, random_effect_area,  
   random_effect_subarea, mse, rse) (550-553);
```

10 Model hierarki Bayes area-level: `hb_area`

10.1 Setting data dan kapan dipakai

Data berbentuk FH (satu baris per domain: respons y_d , kovariat x_d , dan opsional ψ_d), tetapi estimasi dilakukan sepenuhnya dalam kerangka Bayes lewat INLA [Rue et al., 2009, Lindgren and Rue, 2015]. Fungsi ini paling luas cakupannya di paket ini: enam family likelihood, enam struktur spasial, lima struktur temporal, dan tujuh pilihan interaksi spatio-temporal. Cocok ketika (i) indikator non-Gaussian (rasio, proporsi, jumlah) perlu dimodelkan langsung, atau (ii) struktur spasial/temporal eksplisit diinginkan dengan ketidakpastian penuh posterior.

10.2 Persamaan model

Kerangka umum yang dirangkai fungsi ini adalah model latent Gaussian:

$$g(\mu_d) = x_d' \beta + \varphi_d, \quad y_d \mid \mu_d \sim \mathcal{F}(\mu_d; \tau), \quad \varphi \sim N(0, \tau^{-1} Q^{-1}), \quad (52)$$

dengan g link default family (identitas, logit, log) dan Q struktur presisi yang dipilih lewat argumen `spatial`, `temporal`, dan `st_interaction`. Struktur spasial yang tersedia persis seperti yang didefinisikan INLA (baris 411-488 R/hb_area.R):

- "none": φ_d i.i.d. — hanya dibuat bila tidak ada interaksi lain (baris 411-413);
- "bym2": BYM2 dengan presisi $Q = \tau(s \varphi_b Q_{\text{bym2}} + (1-s)\mathbf{I})$ pada skala parsimonius (bagian 13.3);
- "bym": BYM klasik, dua parameter presisi (`prec.unstruct`, `prec.spatial`);
- "besag": ICAR murni Q_{ICAR} ;
- "generic1": $Q = \tau(\mathbf{I} - (\beta/\lambda_{\max})C)$ dengan C matriks ketetanggaan;
- "slm": model lag spasial $x = (\mathbf{I} - \rho \mathbf{W})^{-1}(\mathbf{X}\beta + \varepsilon)$ dengan ρ dipetakan ke $[0, 1]$ lewat rentang akar eigen $\mathbf{W}$.

Struktur temporal: "none", "rw1", "rw2", "ar1", "iid" pada indeks waktu `..time_id..` (baris 494-498), dengan interaksi opsional yang dipetakan ke empat tipe Knorr-Held (Tabel 24).

Tabel 24: Pemetaan `st_interaction` ke bentuk interaksi Knorr-Held. Sumber: penyusunan string `f(...)` di R/hb_area.R:491-566.

Pilihan kode	Bentuk presisi	Padanan KH
none	Q_{time} saja (efek utama waktu)	—
domain-specific	grup per domain, model temporal	(dipakai tipsae)
separable	$Q_{\text{space}} \otimes Q_{\text{time}}$	—
type1	$\mathbf{I}_{DT}$ i.i.d. + efek waktu	KH I
type2	Q_{time} per domain + efek waktu	KH II
type3	Q_{space} per waktu + efek waktu	KH III
type4	$Q_{\text{space}} \otimes \mathbf{I}_T$ + efek waktu	KH IV

Implementation note. Tiga hal pada tabel di atas harus dibaca bersama temuan DISCREPANCIES.md: `type2` *selalu gagal* karena dua `f()` memakai indeks waktu yang sama, yang ditolak INLA (HB-1); `type3/type4` dengan `spatial` $\neq$ "none" *selalu gagal* karena term

spasial ditambah dua kali (HB-2); dan `type3/type4` dengan `spatial = "none"` diam-diam tidak membuat interaksi sama sekali (HB-3). Selain itu `spatial = "slm"` tidak punya penjaga `separable`, sehingga keduanya menggabungkan dua term spasial (HB-5).

10.3 Prediktor titik

Prediksi diambil dari ringkasan nilai terpasang posterior (`inla_utils.R:274-284`):

$$\begin{aligned}\hat{\theta}_d &= \mathbb{E}[\mu_d | y] \text{ (skala respons, lewat link invers), } sd_d = \sqrt{\text{Var}(\mu_d | y)}, \\ CI_{95\%} &= (q_{0.025}, q_{0.975}) \text{ (kuantil posterior).}\end{aligned}\tag{53}$$

Untuk area-level, nilai terpasang INLA memang sudah mewakili rata-rata area, sehingga tidak ada transformasi skala tambahan. Kolom turunan dihitung sesuai family: `trials` → `estimated_total` = $\hat{\theta} \times \text{trials}$; `exposure` → `rate` dan `estimated_count` = $\hat{\theta} \times \text{exposure}$.

Implementation note. Domain tanpa sampel tidak pernah membuat baris baru: baris yang hilang dari data tidak dievaluasi INLA, sedangkan baris dengan `y = NA` tetap dievaluasi karena `na.pass` (HB-17). Jadi “unsampled” di sini berarti *baris ada tetapi responsnya NA*, bukan domain yang tidak ada dalam data — kontras dengan `hb_unit()` yang menambahkan satu baris NA per domain.

10.4 Estimasi komponen varians

Tidak ada Fisher scoring: seluruh inferensi diserahkan ke `INLA::inla()` dengan pengaturan berikut (`R/hb_area.R:578-609`):

- `control.compute = dic, waic, cpo, mlik, config` semuanya `TRUE`;
- `control.inla = strategy` pilihan pengguna ("laplace" default);
- `control.predictor = compute = TRUE, link = 1` — argumen `link` pengguna *tidak pernah dipakai* (HB-6);
- prior komponen acak spasial/temporal: `prior_prec` default `pc.prec(1, 0.01)`; prior korelasi spasial `prior_phi` default `pc(0.5, 0.5)`; `prior_prec_time` default juga `pc.prec(1, 0.01)` (baris 399-405);
- `control.fixed` *tidak pernah diset paket*, sehingga berlaku default INLA: rata-rata tetap 0, presisi tetap 0.001 (intersep: presisi 0, terbatas), strategi faktor `model.matrix` (HB-21).

Likelihood Gaussian dengan `vardir` memakai `scale = 1/ψd` dan presisi tetap 1 sehingga $\text{Var}(y_d) = \psi_d$ persist; family lain memakai `scale/(Ntrials, E)` sesuai parameterisasi INLA (baris 612-667). `method = "laplace"` berarti `strategy` dipaksa "laplace", sedangkan jalur `lme4` (baris 258-267) hanya terbuka untuk binomial/poisson tanpa struktur spasial/temporal (HB-14) dan tidak menghasilkan ketidakpastian (HB-15).

10.5 Estimasi MSE

MSE dihitung analitik dari momen posterior (`hb_area.R:280`):

$$\widehat{\text{MSE}}(\hat{\theta}_d) = sd_d^2, \quad \text{RSE}_d = 100 sd_d / |\hat{\theta}_d|, \quad \text{CI} = \hat{\theta}_d \pm z_{0.975} sd_d \text{ (jalur fallback).}\tag{54}$$

Tidak ada `inla.posterior.sample` di `hb_area()`; ketidakpastian murni analitik. Berbeda dengan `hb_twofold()` yang menambahkan agregasi area dengan sampling posterior (bagian 12.5).

10.6 Pseudo-code

Algorithm 7:

```

1  Masukan formula, data, domain, time, family, spatial, temporal,
   st_interaction, W, varidir, trials, exposure, method, strategy, prior, ...
   Keluaran objek fastsae_hb_area berisi df_hb, fit, hyperpar match.arg untuk 6
   argumen pilihan (174-179);
2  domain_vec ← .get_variable; time wajib bila temporal ≠ "none" (188-211);
3  mf ← model.frame(na.pass); y ← respons (214-215);
4  if family = binomial then
5    | trials wajib; y ← round(y · trials) bila pecahan (224-240)
6  if family = gamma then
7    | y > 0 wajib (242-247)
8  ;
9  W_obj ← .convert_spatial_weights bila spatial ≠ "none" (250-253);
10 if method = laplace dan tanpa spasial/temporal dan family ∈ {binomial, poisson} then
11   | kembalikan .fit_glmm_laplace (258-267, tanpa ketidakpastian)
12 if method = laplace then
13   | strategy ← "laplace" (269-276)
14 ;
   ; // .fit_inla_area (318-704)
15 indeks ..domain_id..., ..obs_id..., ..time_id.. (363-377);
16 hyper_time ← {prec: pc.prec(1, 0.01)}; tambah rho bila ar1 (399-405);
17 baris spasial ← Tabel 24/teks bagian 10.2 (411-488);
18 baris temporal + interaksi ← Tabel 24 (491-566);
19 susun formula y ~ ... ("slm": tanpa intercept) (569-575);
20 control.compute (dic, waic, cpo, mlik, config), control.predictor (link = 1),
   control.inla (578-601);
21 for family do
22   | sesuaikan scale, Ntrials, E, control.family — (52) (612-667)
23 ;
24 fit ← tryCatch(do.call(INLA::inla, ...)) (670-678);
25  $\hat{\theta}$ , sd, CI, mse, rse ← (53)–(54) (681-701, 274-284);
26 perakitan df_hb, hyperpar, goodness (DIC, WAIC, marginal likelihood), kelas
   c("fastsae_hb_area", "fastsae") (394, 811);

```

10.7 Signature, argumen, objek keluaran, dan contoh

Listing 13: Signature hb_area (R/hb_area.R:148-148).

```

hb_area(formula, data, domain = NULL, time = NULL,
  family = c("gaussian", "binomial", "poisson", "nbinomial", "beta", "gamma"),
  spatial = c("none", "bym2", "bym", "besag", "generic1", "slm"),
  temporal = c("none", "rw1", "rw2", "ar1", "iid"),
  st_interaction = c("none", "domain-specific", "separable",
    "type1", "type2", "type3", "type4"),
  W = NULL, varidir = NULL, trials = NULL, exposure = NULL,
  method = c("inla", "laplace"),
  strategy = c("laplace", "simplified.laplace", "gaussian"),
  link = NULL, scale_model = TRUE,

```

```
prior_prec = list(prior = "pc.prec", param = c(1, 0.01)),
prior_phi   = list(prior = "pc",      param = c(0.5, 0.5)),
prior_rho = NULL, prior_prec_time = NULL, prior_rho_time = NULL,
print_result = TRUE, ...)
```

- `family` menentukan kolom pendukung yang wajib: Gaussian → `vardir` (opsional; bila ada, dipakai sebagai `scale`); Binomial → `trials`; Poisson/Negatif Binomial → `exposure`; Beta → `vardir` atau `trials` untuk presisi.
- `W` — matriks ketetanggaan (dapat berupa `listw`, `nb`, `matrix`, atau `inla.graph`); bobot dibakar ke graf biner simetris (bagian 13.3).
- ... — diteruskan ke `INLA::inla`, tetapi `control.compute` tidak dapat ditimpa karena sudah dibuat lebih dulu (HB-13).

Objek keluaran: `c("fastsae_hb_area", "fastsae")` berisi `df_hb` (kolom `domain`, `y`, `hb`, `sd`, `mse`, `rse`, `ci_lower`, `ci_upper`, `linear_pred` + kolom `family`), `fit` (objek `inla`). `hyperpar`, `goodness`, `random_effect_var`, `W`, `n_iter`, `convergence`, `formula`, `method`, `call`, `data`.

Listing 14: Contoh yang dapat dijalankan (dari `man/hb_area.Rd`).

```
library(fastsae)
if (requireNamespace("INLA", quietly = TRUE)) {
  # Gaussian Fay-Herriot tanpa spasial
  m_norm <- hb_area(y ~ x1 + x2 + x3, data = mys, vardir = "vardir",
                    family = "gaussian")

  # Gaussian dengan efek spasial BYM2
  m_bym2 <- hb_area(y ~ x1 + x2 + x3, data = mys, vardir = "vardir",
                    family = "gaussian", spatial = "bym2",
                    W = mys_proxmat)
  head(m_norm$df_hb)
}
```

10.8 Referensi kunci

Rue et al. [2009] untuk metode INLA, Lindgren and Rue [2015] untuk implementasi R-INLA, Riebler et al. [2016] untuk BYM2 (blok roxygen fungsi ini memuat lima rujukan: Rao and Molina [2015], Riebler et al. [2016], Marhuenda et al. [2013], De Nicolò and Gardini [2024], Rue et al. [2009]; lihat `R/hb_area.R:110-121`).

11 Model hierarki Bayes unit-level: `hb_unit`

11.1 Setting data dan kapan dipakai

Mirip `eb lup_bhf()`: dua sumber data — `unit_data` (mikrodata survei) dan `Xpop` (ringkasan populasi per domain) — tetapi inferensinya Bayes penuh lewat INLA. `popsize_var` bersifat opsional; bila diberikan, prediksi dikombinasikan dengan rata-rata sampel (koreksi populasi hingga/fin population). Dibandingkan `hb_area()`, fungsi ini secara eksplisit membangkitkan *baris prediksi* untuk setiap domain, sehingga domain tanpa sampel selalu ikut dievaluasi. Family yang didukung hanya `gaussian`, `binomial`, `poisson`, dan struktur spasial hanya `none`, `bym2`, `besag`.

11.2 Persamaan model

$$y_{ij} = x'_{ij}\beta + u_i + e_{ij}, \quad u \sim N(0, \tau_u^{-1}Q_u^{-1}), \quad e_{ij} \sim \mathcal{F}, \quad (55)$$

dengan $Q_u = \mathbf{I}$ (`spatial = "none"`, bimod 1), $Q_u = Q_{\text{bym2}}$, atau $Q_u = Q_{\text{ICAR}}$ (baris 253-263). Tidak ada `Ntrials` maupun `E` yang dikirim ke INLA (baris 274-282), sehingga binomial terbaca sebagai Bernoulli per unit dan Poisson tanpa offset/ekspresi. Formula acak yang dirangkai (baris 253-263):

```
y ~ <fixed_str> + f(..dom_id.., model = 'iid',
hyper = list(prec = prior_prec))
```

11.3 Prediktor titik

Data INLA disusun dari baris sampel (y nyata) *ditambah satu baris prediksi per domain dengan* `y = NA` (baris 244-249); prediksi dibaca dari indeks `(n_sample+1):nrow(combined_df)` (baris 298):

$$\hat{\theta}_i = \mathbb{E}[\mu_i | y], \quad \text{sd}_i = \sqrt{\text{Var}(\mu_i | y)}, \quad (56)$$

skala respons (superpopulation). Bila `popsize_var` diberikan dan $f_d = n_d/N_d$ dihitung (dipangkas ke $[0, 1]$, baris 317-319):

$$\hat{\theta}_d^{\text{adj}} = f_d \bar{y}_{s,d} + (1 - f_d) \hat{\theta}_d, \quad \text{sd}^{\text{adj}} = (1 - f_d) \text{sd}_d, \quad \text{CI} = \hat{\theta}_d^{\text{adj}} \pm 1.96 \text{sd}^{\text{adj}}, \quad (57)$$

dengan penjagaan batas sesuai family (binomial $\rightarrow [0, 1]$, Poisson ≥ 0 ; baris 322-338). Untuk domain tanpa sampel $f_d = 0$, sehingga $\hat{\theta}_d^{\text{adj}} = \hat{\theta}_d$ — prediktor murni. Tanpa `popsize_var`, kuantil posterior INLA dipakai apa adanya (baris 344-350).

Implementation note. Pada jalur `popsize_var`, kolom `linear_pred` tetap memuat η tanpa koreksi, sementara `hb` sudah tercampur $f_d \bar{y}_s + (1 - f_d) \hat{\theta}$, sehingga keduanya tidak lagi saling invers; `sd_adj` dipangkas dengan faktor $(1 - f_d)$ — aproksimasi, bukan hasil posterior (HB-19). Jenis interval juga berubah-ubah: kuantil posterior bila tanpa `popsize_var`, dan normal ± 1.96 bila ada (HB-18).

11.4 Estimasi komponen varians

- Prior presisi komponen acak: `prior_prec` default `loggamma(0.01, 0.01)` — *berbeda* dari `hb_area()` dan `hb_twofold()` yang memakai `pc.prec(1, 0.01)` (HB-8).
- `strategy` default `"laplace"`; `num.threads` dipaksa `"1:1"` dengan pemulihan `on.exit` (baris 268-272), sehingga fungsi ini selalu serial.
- `control.compute = dic, waic, cpo, mlik` tanpa `config` (baris 280); ... menimpa nama argumen yang sudah ada (baris 283-284), berbeda dengan `hb_area()` yang membentuk daftar ganda dan bisa error (HB-13).

Estimasi $\hat{\sigma}_u^2 = 1/\text{prec}$ dan, untuk Gaussian, $\hat{\sigma}_e^2$ dari baris `"Gaussian"` pada `summary.hyperpar` (baris 378-390); `phi` diambil bila ada (baris 394-397).

11.5 Estimasi MSE

$$\widehat{\text{MSE}} = \text{sd}^2, \quad \text{RSE} = 100 \text{sd} / |\hat{\theta}|, \quad (58)$$

dengan sd sudah melalui (57) bila `popsize_var` diberikan (baris 412-413). Varian empiris direktor untuk keperluan pelaporan diestimasi dari data: Gaussian $\rightarrow \hat{\sigma}_e^2/n_d$, binomial $\rightarrow \bar{p}(1 - \bar{p})/n$, Poisson $\rightarrow \bar{y}/n$ (baris 401-409). Tidak ada posterior sampling di fungsi ini.

11.6 Pseudo-code

Algorithm 8: `hb_unit` — alur sebenarnya (R/hb_unit.R:124-480)

```

1 Masukan formula, unit_data, Xpop, domain_var, popsize_var, family, spatial,
  W, popnmean_xpop, strategy, prior, ... Keluaran objek fastsae_hb_unit berisi
  df_hb, fit, goodness .check_inla_installed() (142); match.arg (144-146);
2 sampel  $\leftarrow$  model.frame(na.omit);  $y_s \leftarrow$  respons (172-178);
3 all_domains  $\leftarrow$  unique(Xpop[[domain_var]]);
4 gagal bila ada domain sampel tanpa di Xpop (191-196);
5 unsampled_domains  $\leftarrow$  setdiff(all_domains, unique(dom_s)) (199);
6 bila nrow(Xpop) > jumlah domain: agregasi mean per domain (202-214);
7 meanxpop  $\leftarrow$  model.matrix atas ringkasan domain (217-224);
8  $W \leftarrow$  .convert_spatial_weights (228-232);
9 data INLA  $\leftarrow$  baris sampel + 1 baris  $y = \text{NA}$  per domain (244-249);
10 formula  $\leftarrow y \sim \langle \text{fixed} \rangle + f(\dots \text{dom\_id} \dots, \dots)$  (253-263);
11 num.threads  $\leftarrow$  "1:1" (dipulihkan via on.exit) (268-272);
12 fit  $\leftarrow$  do.call(INLA::inla, ...) (287-295);
13  $\hat{\theta}$ , sd, CI  $\leftarrow$  prediksi indeks (n_sample+1):n (298-306);
14 if popsize_var diberikan then
15   |  $f_d \leftarrow$  (57);  $\hat{\theta}^{\text{adj}}$ ,  $\text{sd}^{\text{adj}}$ , CI  $\leftarrow$  (315-343)
16 else
17   | CI  $\leftarrow$  kuantil INLA (344-350)
18 ;
19 MSE, RSE  $\leftarrow$  (58) (412-413);
20  $\hat{\sigma}_u^2 \leftarrow 1/\text{prec}$ ; phi; goodness = list(DIC, WAIC, mlik) (378-477);
21 kelas c("fastsae_hb_unit", "fastsae_hb", "fastsae") (471);

```

11.7 Signature, argumen, objek keluaran, dan contoh

Listing 15: Signature `hb_unit` (R/hb_unit.R:124-140).

```

hb_unit(formula, unit_data, Xpop, domain_var, popsize_var = NULL,
  family = c("gaussian", "binomial", "poisson"),
  spatial = c("none", "bym2", "besag"),
  W = NULL, popnmean_xpop = NULL,
  strategy = c("laplace", "simplified.laplace"),
  scale_model = TRUE,
  prior_prec = list(prior = "loggamma", param = c(0.01, 0.01)),
  prior_phi = list(prior = "pc", param = c(0.5, 0.5)),
  print_result = TRUE, ...)

```

Objek keluaran: `c("fastsae_hb_unit", "fastsae_hb", "fastsae")` berisi `df_hb` (termasuk `samp_size`, `pop_size`, `f`, `hb_adj`, `sd_adj` bila `popsize_var` ada), `fit`, `hyperpar`,

goodness berupa `list(dic, p_eff_dic, waic, p_eff_waic, mlik)`, `random_effect_var`, `unsampled_domains`, `method`, `call`, `data`.

Listing 16: Contoh yang dapat dijalankan (dari `man/hb_unit.Rd`).

```
library(fastsae)
data(cornsoybean); data(cornsoybeanmeans)

df_pop <- cornsoybeanmeans
names(df_pop)[names(df_pop) == "MeanCornPixPerSeg"] <- "CornPix"
names(df_pop)[names(df_pop) == "MeanSoyBeansPixPerSeg"] <- "SoyBeansPix"
df_sample <- cornsoybean
names(df_sample)[names(df_sample) == "County"] <- "CountyIndex"

fit_hb_u <- hb_unit(formula = CornHec ~ CornPix + SoyBeansPix,
                    unit_data = df_sample, Xpop = df_pop,
                    domain_var = "CountyIndex",
                    popsize_var = "PopnSegments")

print(fit_hb_u)
```

11.8 Referensi kunci

Blok roxygen fungsi ini memuat [Battese et al. \[1988\]](#) (struktur unit-level), [Rao and Molina \[2015\]](#), [Riebler et al. \[2016\]](#), dan [Rue et al. \[2009\]](#) (`R/hb_unit.R:83-94`); kerangka INLA dirujuk ke [Lindgren and Rue \[2015\]](#).

12 Model hierarki Bayes sub-area dua-lipat: `hb_twofold`

12.1 Setting data dan kapan dipakai

Data dan penanda sama dengan `eblup_twofold()`: satu baris per unit sampel dengan kolom `domain` (area, wajib) dan `subarea` (opsional, default penomoran unit). Perbedaannya inferensial: model ditempatkan dalam kerangka hierarki Bayes lewat INLA, dengan dua komponen acak terpisah (efek area dan efek sub-area) serta pilihan prediktor sintetis pada tingkat area. Fungsi ini diekspor dua nama: `hb_twofold` dan alias `hb_tfh` (`R/hb_twofold.R:513-514`).

12.2 Persamaan model

$$y_{ij} = x'_{ij}\beta + v_i + u_{ij}, \quad v \sim N(0, \tau_v^{-1}Q_v^{-1}), \quad u_{ij} \stackrel{\text{iid}}{\sim} N(0, \tau_u^{-1}), \quad (59)$$

dengan Q_v dipilih `spatial` $\in \{\text{none (i.i.d.), bym2, besag}\}$ dan u selalu i.i.d. pada indeks sub-area (baris 242-258):

```
y ~ <fixed_str> + <rand_area> +
  f(..subarea_id.., model = 'iid',
    hyper = list(prec = prior_prec_subarea))
```

`rand_area` adalah `f(..area_id.., model='iid'|'bym2'|'besag', graph=..., hyper=list(prec = prior_prec_area[, phi = prior_phi]))`. Likelihood: Gaussian (wajib `vardir`, dipakai sebagai `scale = 1/ψ`, baris 213-215), Binomial (wajib `trials`), Poisson (exposure opsional; baris 278-287).

12.3 Prediktor titik

Prediksi sub-area diambil dari `summary.fitted.values` untuk `1..nsubarea` (baris 304-311), lalu tingkat area diperoleh sebagai rata-rata berbobot (baris 345-359):

$$\hat{\theta}_i^{\text{area}} = \sum_{j \in i} w_{ij} \hat{\theta}_{ij}, \quad w_{ij} = \frac{w_{ij}^{\text{user}}}{\sum_{k \in i} w_{ik}^{\text{user}}}, \quad w_{ij} = \frac{1}{n_i} \text{ bila } \text{weight} = \text{NULL}. \quad (60)$$

Bobot yang tidak valid (NA/negatif) diubah menjadi 0; bila jumlah bobot area bernilai 0, kembali ke $1/n_i$ (baris 345-356).

12.4 Estimasi komponen varians

Sama seperti dua fungsi Bayes lain: INLA dengan `strategy` default "laplace", `control.compute` berisi `dic`, `waic`, `cpo`, `mlik` plus `config` yang diaktifkan *hanya* bila `compute_area = TRUE` (karena butuh konfigurasi untuk posterior sampling), dan `num.threads = 1` (baris 261-276). Prior: `prior_prec_area` dan `prior_prec_subarea` keduanya `pc.prec(1, 0.01)`, `prior_phi` `pc(0.5, 0.5)` (baris 139-160). Hyperparameter akhir: $\hat{\sigma}_v^2 = 1/\text{prec}$ pada indeks area, $\hat{\sigma}_u^2 = 1/\text{prec}$ pada indeks sub-area, dan `phi` bila ada (baris 444-468).

12.5 Estimasi MSE

Tingkat sub-area (baris 321-322):

$$\widehat{\text{MSE}}_{ij} = \text{sd}_{ij}^2, \quad \text{RSE}_{ij} = 100 \text{sd}_{ij} / \left| \hat{\theta}_{ij} \right|. \quad (61)$$

Tingkat area memakai sampling posterior (baris 367-408), bila `compute_area = TRUE`:

1. `ps` ← `INLA::inla.posterior.sample(n = n_samples, fit)` dengan `n_samples` default 200;
2. tarik baris `Predictor:1..Predictor:nsubarea` dari `rownames(ps[[1]]$latent)`;
3. transformasi balik link manual (binomial $1/(1 + e^{-x})$, Poisson e^x , Gaussian tanpa transformasi);
4. agregasi per gambar posterior $\theta_i^{\text{area},(k)} = \sum_j w_{ij} \theta_{ij}^{(k)}$;
5. $\text{sd}^{\text{area}} = \text{sd}(\theta^{\text{area}})$, CI dari kuantil 0.025/0.975 gambar posterior.

$$\widehat{\text{MSE}}_{\text{area}} = (\text{sd}^{\text{area}})^2, \quad \text{fallback bila sampling gagal: } \text{sd}^{\text{area}} = \sqrt{\sum_j (w_{ij} \text{sd}_{ij})^2}, \quad (62)$$

dengan fallback itu berasumsi sub-area saling bebas (baris 398-408), dan CI jatuh ke $\pm 1.96 \text{sd}$ (HB-18). Bila `compute_area = FALSE`, `df_area = NULL` (baris 342).

12.6 Pseudo-code

12.7 Signature, argumen, objek keluaran, dan contoh

Algorithm 9: `hb_twofold` — alur sebenarnya (R/hb_twofold.R:139-510; alias `hb_tfh`)

```

1  Masukan formula, vardir (wajib bila Gaussian), domain (wajib), subarea, data,
   family, spatial, W, weight, trials, exposure, prior, compute_area, n_samples,
   ... Keluaran df_hb (sub-area), df_area (area, bila diaktifkan), goodness
   .check_inla_installed() (162); match.arg (164-166);
2  domain wajib; subarea  $\leftarrow$  1:n bila NULL (178-187);
3  y, terms  $\leftarrow$  model.frame(na.pass) (197-199);
4  Gaussian: vardir wajib, scale_vec =  $1/\psi$  (baris NA/ $\leq 0/\infty \rightarrow 1$ ) (213-215);
   Binomial: trials wajib (217-223);
5  W  $\leftarrow$  .convert_spatial_weights (226-230);
6  formula  $\leftarrow$  (59) (242-258);
7  num.threads  $\leftarrow$  "1:1"; control.compute = {dic, waic, cpo, mlik, config =
   compute_area} (261-276);
8  fit  $\leftarrow$  do.call(INLA::inla, ...) (293-301);
9   $\hat{\theta}_{ij}$ ,  $\text{sd}_{ij}$ , CI  $\leftarrow$  (304-311);  $\widehat{\text{MSE}}$   $\leftarrow$  (61) (321-322);
10 wij  $\leftarrow$  (60) (345-356);  $\hat{\theta}_i^{\text{area}}$   $\leftarrow$  (359);
11 if compute_area then
12   inla.posterior.sample n = 200 (368-371);
13   transformasi balik link per gambar (378-380);
14   agregasi berbobot per gambar (387);
15    $\text{sd}^{\text{area}}$ , CI  $\leftarrow$  kuantil (388-390);
16   fallback (62) bila sampling gagal (398-408)
17 if compute_area = FALSE then
18   df_area  $\leftarrow$  NULL (342)
19 ;
20  $\hat{\sigma}_v^2$ ,  $\hat{\sigma}_u^2$ ,  $\phi$ , goodness  $\leftarrow$  (444-477);
21 kelas c("fastsae_hb_twofold", "fastsae_hb", "fastsae") (504);

```

Listing 17: Signature `hb_twofold` (R/hb_twofold.R:139–160); alias `hb_tfh`.

```
hb_twofold(formula, vardir = NULL, domain, subarea = NULL, data,
  family = c("gaussian", "binomial", "poisson"),
  spatial = c("none", "bym2", "besag"), W = NULL, weight = NULL,
  trials = NULL, exposure = NULL,
  strategy = c("laplace", "simplified.laplace"), scale_model = TRUE,
  prior_prec_area = list(prior = "pc.prec", param = c(1, 0.01)),
  prior_prec_subarea = list(prior = "pc.prec", param = c(1, 0.01)),
  prior_phi = list(prior = "pc", param = c(0.5, 0.5)),
  compute_area = TRUE, n_samples = 200, print_result = TRUE, ...)
```

Objek keluaran: `c("fastsae_hb_twofold", "fastsae_hb", "fastsae")` berisi `df_hb` (juga `df_subarea` sebagai alias, baris 486), `df_area` (atau `NULL`), `random_effect_var` bernama `sigma2_v` dan `sigma2_u`, `hyperpar`, `goodness` berupa `list`, `fit`, `method`, `call`, `data`.

Listing 18: Contoh yang dapat dijalankan (dari `man/hb_twofold.Rd`).

```
library(fastsae)
set.seed(42)
m <- 10
dat <- do.call(rbind, lapply(1:m, function(d) {
  nd <- sample(2:4, 1)
  data.frame(area = d, subarea = paste0(d, "-", seq_len(nd)),
    x1 = rnorm(nd), vardir = runif(nd, 0.2, 0.8))
}))
dat$y <- 1 + dat$x1 + rnorm(m)[dat$area] +
  rnorm(nrow(dat), sd = 0.5) + rnorm(nrow(dat), sd = sqrt(dat$vardir))

fit <- hb_twofold(y ~ x1, vardir = "varidir", domain = "area",
  subarea = "subarea", data = dat)
summary(fit)
```

12.8 Referensi kunci

Blok roxygen memuat [Torabi and Rao \[2014\]](#) (model dua-lipat), [Rao and Molina \[2015\]](#), dan [Riebler et al. \[2016\]](#) (R/hb_twofold.R:105–112); kerangka INLA mengacu ke [Rue et al. \[2009\]](#) dan [Lindgren and Rue \[2015\]](#).

13 Kerangka Bayes: INLA, GMRF, struktur spasial, dan prior

Bagian ini menjelaskan perangkat yang dipakai ketiga fungsi `hb_--` (`hb_area()`, `hb_unit()`, `hb_twofold()`). Semua rumus di bawah adalah rumus yang *dirujuk* oleh kode dan oleh dokumentasi INLA yang terpasang; penyesuaian khusus paket ini ditandai *implementation note*.

13.1 Model latent Gaussian dan aproksimasi INLA

Keluarga yang dapat ditangani INLA [[Rue et al., 2009](#)] berbentuk

$$y_i \mid x_i, \theta \sim p(y_i \mid g(\mu_i) = \eta_i), \quad \eta_i = x_i, \quad x \mid \theta \sim N(0, Q(\theta)^{-1}), \quad \pi(\theta), \quad (63)$$

yaitu respons bergantung pada field laten Gaussian x lewat link g , dan parameter hiper θ hanya muncul dalam presisi Q . INLA mengejar marginal posterior

$$\pi(x_i \mid y) \approx \int \tilde{\pi}_{\text{INLA}}(x_i \mid \theta) \tilde{\pi}(\theta \mid y) d\theta \quad (64)$$

lewat tiga aproksimasi bertumpuk (Laplace untuk $\pi(x_i \mid \theta)$ dan $\pi(\theta \mid y)$, plus simplifikasi strategi yang dipilih pengguna). Strategi yang tersedia di `hb_area()`: `laplace` (default), `simplified.laplace`, `gaussian`; di `hb_unit()` dan `hb_twofold()`: `laplace` dan `simplified.laplace`. Rujukan buku untuk pemakaian praktis INLA dari R, termasuk cara membaca argumen `control.compute` yang dipakai bagian 10, adalah Gómez-Rubio [2020]. Alternatif MCMC untuk masalah ini dibahas Datta and Ghosh [1991] untuk prediksi Bayes dan Molina and Marhuenda [2015] untuk SAE tingkat daerah.

13.2 Gaussian Markov Random Field

Field laten x berdimensi n adalah GMRF [Rue and Held, 2005] bila

$$\pi(x) \propto \exp\left(-\frac{1}{2}(x - \mu)'Q(x - \mu)\right), \quad Q \text{ sparse}, \quad (65)$$

di mana sparsitas Q mencerminkan *conditional independence*: $x_i \perp x_j \mid x_{-i,j}$ bila $Q_{ij} = 0$. Struktur Q diambil dari graf ketetanggaan, dan inversi dilakukan lewat Cholesky sparse (dalam INLA, format supernode). Untuk SAE, n = jumlah domain dan graf-nya adalah ketetanggaan spasial atau rantai waktu.

13.3 Struktur presisi: CAR, ICAR, BYM, dan varian lain

Definisi dasar. Misalkan W matriks ketetanggaan, D matriks derajat, dan $C = W$ atau $C = D^{-1}W$ menentukan skala yang dipakai. Tabel 25 merangkum pilihan yang tersedia di INLA beserta padanannya di `hb_area()`.

Tabel 25: Struktur presisi spasial dan pemakainya di `fastsae`. Sumber: penyusunan `f(...)` di `R/hb_area.R:411-488` dan `R/hb_unit.R:253-263`, `R/hb_twofold.R:242-258`.

Pilihan	Presisi Q	Catatan
<code>none</code>	$\mathbf{I}$ (i.i.d.)	tanpa struktur; hanya bila tidak ada interaksi lain
<code>besag</code> (ICAR)	$D - W$	intrinsik: tak terbatas pada konstanta; diperbaiki lewat konstraint dan <code>scale.model</code>
<code>bym</code> (BYM)	$Q_{\text{ICAR}} + \mathbf{I}$, dua presisi	BYM klasik [Besag et al., 1991]
<code>bym2</code> (BYM2)	$s Q_{\text{ICAR}} + (1 - s)\mathbf{I}$	satu presisi + fraksi spasial s [Riebler et al., 2016]
<code>generic1</code>	$\mathbf{I} - (\beta/\lambda_{\max})C$, $\beta \in [0, 1)$	presisi terikat graf
<code>slm</code>	melalui $(\mathbf{I} - \rho W)$	model lag spasial; ρ dipetakan ke $[0, 1]$

Konversi bobot ke graf: `.convert_spatial_weights`. Sebelum masuk `INLA::inla`, matriks ketetanggaan harus berupa `inla.graph` (graf biner simetris tanpa bobot). Fungsi `R/inla_utils.R:27-88` menerima `listw` (`spdep`), `nb`, `matrix`, atau `inla.graph` langsung; bobot apa pun dibakar menjadi $w_{ij} > 0 \Rightarrow \text{simpul } (i, j)$, simetrisasi $A \leftarrow \max(A, A')$, lalu ditulis sebagai baris teks graf. Untuk `spatial = "slm"` bobot mentah dipakai apa adanya (bukan graf) karena `args.slm$W` memang matriks bobot — konsekuensinya berbeda pada kasus W berupa `inla.graph` (HB-20).

CAR proper vs ICAR. CAR proper memakai

$$Q = \tau(D - \rho C), \quad \rho \in (1/\omega_{\min}, 1/\omega_{\max}) \quad (66)$$

dengan ω eigen C — di luar rentang itu Q tidak positif definitif. ICAR adalah kasus batas tanpa ρ :

$$Q_{\text{ICAR}} = D - W, \quad \pi(x) \propto \exp\left(-\frac{1}{2}\tau x'(D - W)x\right), \quad (67)$$

yang *tidak terintegrasi* pada konstanta (presisi punya satu nol) sehingga perlu constraint jumlah-nol atau referensi; INLA menambahkannya otomatis untuk `bym2/bym/besag/rw1/rw2` (konfirmasi lewat `inla.models()`). Kedua kasus diperkenalkan Besag [1974] dan dibahas Banerjee et al. [2014].

BYM dan BYM2. BYM [Besag et al., 1991] menggabungkan dua komponen $u = u^s + u^u$ dengan dua presisi terpisah; parameter sulit diinterpretasikan dan korelasinya tinggi. BYM2 [Riebler et al., 2016] merapkannya menjadi satu presisi τ dan fraksi spasial

$$\varphi = \frac{\text{Var}(u^s)}{\text{Var}(u^s) + \text{Var}(u^u)} \in [0, 1], \quad u \sim N\left(0, \tau^{-1}[\varphi \tilde{Q}_{\text{ICAR}} + (1 - \varphi)\mathbf{I}]^{-1}\right), \quad (68)$$

dengan $\tilde{Q}_{\text{ICAR}}$ yang telah diskalakan [Sørbye and Rue, 2014] (`scale.model = TRUE` pada `hb_area()`). Karena presisi terikat, prior PC untuk φ menjadi interpetabel (bagian 13.4).

Implementation note. Kode `generic1` membangun $R = \text{diag}(\text{baris sum}) - W$, $C = \mathbf{I} - R$ (`hb_area.R:439-441`), sehingga C bernilai dua kali derajat pada diagonal — inilah $C = \mathbf{I} - R$ yang diminta INLA untuk `generic1`, dan ρ terkait melalui $\beta/\lambda_{\max}$. Untuk `slm`, rentang ρ dihitung dari akar eigen matriks row-standar lalu diklem ke $[-0.999, 0.999]$ (baris 453-477), dan prior default-nya `logitbeta(1,1)` (bukan PC).

13.4 Prior PC dan log-gamma

Prior *penalised complexity* [Simpson et al., 2017] mencabut kompleksitas dari prior dasar (keseragaman untuk varian, ketiadaan korelasi untuk ρ). Untuk standar deviasi:

$$\Pr(\sigma > u_0) = \alpha \implies \pi(\sigma) = \lambda e^{-\lambda\sigma}, \quad \lambda = \frac{-\log \alpha}{u_0}, \quad (69)$$

ditulis INLA sebagai `pc.prec` dengan `param = (u0, alpha)`. Untuk fraksi spasial BYM2 dan korelasi lain:

$$\Pr(|\varphi| > u_0) = \alpha \implies \pi(\varphi) = \frac{\lambda}{2} e^{-\lambda|\varphi|}, \quad (70)$$

ditulis `pc` dengan `param = (u0, alpha)`. Prior log-gamma $\pi(\tau) = \text{loggamma}(a, b)$ lama dipakai untuk presisi dan tetap menjadi default INLA untuk presisi likelihood Gaussian (`loggamma(1, 5e-5)`).

Tabel 26 mencatat prior yang *sebenarnya* dipakai tiap fungsi, yang tidak konsisten antar fungsi.

Tabel 26: Prior default di tiga fungsi Bayes (baca: “argumen bawaan yang didefinisikan dalam signature”). Sumber: signature fungsi dan pemakaian `hyper` di `R/hb_area.R:399-488`, `R/hb_unit.R:136`, `R/hb_twofold.R:153-154`.

Fungsi	Prior presisi komponen acak	Prior korelasi
<code>hb_area</code>	<code>pc.prec(1, 0.01)</code>	<code>pc(0.5, 0.5)</code>
<code>hb_unit</code>	<code>loggamma(0.01, 0.01)</code>	<code>pc(0.5, 0.5)</code>
<code>hb_twofold</code>	<code>pc.prec(1, 0.01)</code> per tingkat (area, sub-area)	<code>pc(0.5, 0.5)</code>

Implementation note. Prior tetap (intercept, koefisien regresi) *tidak pernah diset fastsae*, sehingga berlaku default INLA: rata-rata 0, presisi 0.001 (intersep: presisi 0 = prior rata di $\mathbb{R}$). Nilai ini, beserta prior lain pada tabel di atas, adalah prior yang dipakai seluruh hasil Bayes di laporan ini (HB-21). Selain itu `prior_phi` pada `hb_area()` juga dipakai ulang untuk `beta generic1` dan `rho slm` bila nilainya bukan “pc” (HB-7), dan untuk `bym2 + prior_phi = “pc”` prior jatuh ke default INLA `pc(0.5, 0.5)`.

13.5 Likelihood, link, dan parameterisasi scale

Tabel 27 memetakan family ke link dan ke apa yang benar-benar dikirim paket ke INLA. Ini penting karena *kolom link* pada argumen `hb_area` tidak pernah dipakai (HB-6): selalu `control.predictor$link = 1` (link default family).

Tabel 27: Family likelihood dan parameterisasi yang dikirim `fastsae` ke INLA. Sumber: R/hb_area.R:612–667, R/hb_unit.R:274–282, R/hb_twofold.R:278–287.

Family	Link yang dipakai	Apa yang benar-benar dikirim ke INLA
gaussian + vardir	identitas	scale = 1/vardir, presisi likelihood diklem tetap (<code>prec = list(initial = 0, fixed = TRUE)</code>)
beta + vardir	logit	scale = $y(1-y)/\text{vardir} - 1$ diklem ≥ 1 , hiperparameter <code>theta</code> tetap
beta + trials	logit	scale = <code>trials - 1</code> diklem ≥ 1
gamma + vardir	log	scale = y^2/vardir
binomial + trials	logit	<code>Ntrials = trials</code>
poisson, nbinomial + exposure	log	<code>E = exposure</code>
hb_unit (semua family)	link = 1	tanpa scale/ <code>Ntrials</code> / <code>E</code> ; penyesuaian hanya lewat ...
hb_twofold	link = 1	per tingkat: scale (gaussian), <code>Ntrials</code> (binomial), <code>E</code> (poisson)


Parametrisasi `scale` pada baris beta, gamma, dan gaussian bukan pilihan gaya: INLA memakai `scale` sebagai presisi hipotetis (*scale-inverse-dispersion*) sehingga varians per observasi menjadi $1/\text{scale}$. Untuk beta, `phi_dir` diturunkan dari $\text{Var}(y) = \phi^{-1}y(1-y)$ lalu diklem ke ≥ 1 ; untuk gamma, `scale` = y^2/ψ meniru bentuk varians $\phi\mu^2$. Rujukan parametrisasi beta area-level ada di Janicki [2020].

Implementation note. Argumen `link` pada `hb_area()` diabaikan (HB-6): ketiga fungsi menyetel `control.predictor$link = 1` secara eksplisit, jadi link selalu link default family. Konsekuensinya, family non-Gaussian yang dipanggil dengan link bukan bawaan tidak akan menerima link yang diminta pengguna; kolom “Link yang dipakai” pada tabel di atas adalah link bawaan itulah.


Peta ke bab model. Tiga pemakaian praktis kerangka di atas terlihat pada bagian 10 (pilihan `f(...)`, prior, dan argumen `hyper`), bagian 11 (field laten per unit observasi), dan bagian 12 (dua tingkat ketetanggaan); perbedaan perilaku antar ketiganya terkumpul di DISCREPANCIES.md bagian E (ID HB-1–HB-21).

14 Lapisan utilitas: benchmarking, diagnostik, perbandingan, ekspor, peta

Kelima kelompok fungsi di bawah ini bekerja pada objek apa pun berkelas `fastsae` (atau turunannya) dan membentuk “alur kerja” setelah sebuah model selesai dipasang pada data: *kalibrasi* $\rightarrow$ *diagnosis* $\rightarrow$ *perbandingan* $\rightarrow$ *pelaporan/pemetaan*. Semua rumus adalah rumus persis yang dikodekan; selisih terhadap rujukan ditandai *implementation note* dan dikumpulkan di DISCREPANCIES.md bagian G (ID UT-1–UT-16).



Gambar 6: Graf tetangga enam domain beserta matriks yang diturunkannya. Derajat dibaca dari graf: d_1 dan d_3 bertiga, sisanya bertua. Matriks bobot apa pun (matrix, nb, listw) dikonversi ke graf biner simetris oleh `.convert_spatial_weights` sebelum masuk `inla.graph`. Sumber: `R/inla_utils.R:27-88` dan pemakaian `Q` di `R/hb_area.R:411-488`.



Gambar 7: Struktur ketergantungan pada field laten GMRF: hanya pasangan dengan $Q_{ij} \neq 0$ yang bersambung (markov blanket), sementara y_i bergantung pada x_i lewat link. Struktur Q inilah yang diisi oleh CAR/ICAR/BYM/BYM2 pada Tabel 25. Sumber: (65) dan `R/hb_area.R:411-488`.

14.1 Benchmarking: `benchmark_sae`

Definisi. Agregat per grup dihitung dari bobot yang sudah disterilkan oleh `type`:

$$w_{ig}^{\text{calc}} = \begin{cases} w_{ig} / \sum_{k \in g} w_{ik} & \text{type} = \text{"mean"} \\ w_{ig} & \text{type} = \text{"total"} \end{cases} \quad A_g = \sum_{i \in g} w_{ig}^{\text{calc}} y_i, \quad (71)$$

dan target T_g dipaksa tercapai lewat empat metode (`R/benchmark.R:451-512`):

$$\textbf{ratio:} \quad \lambda_g = \frac{T_g}{A_g}, \quad \tilde{y}_i = y_i \lambda_g; \quad (72)$$

$$\textbf{difference:} \quad \delta_g = T_g - A_g, \quad \tilde{y}_i = y_i + \frac{\delta_g}{\sum_i w_{ig}^{\text{calc}}}; \quad (73)$$

$$\textbf{optimal:} \quad \lambda_g = \frac{\delta_g}{\sum_i \tilde{m}_i}, \quad \tilde{y}_i = y_i + \frac{\tilde{m}_i}{w_{ig}^{\text{calc}}} \lambda_g; \quad (74)$$

$$\textbf{logit:} \quad \text{cari } \alpha \text{ dari } \sum_i w_{ig}^{\text{calc}} \text{logit}^{-1}(\text{logit}(y_i) + \alpha) = T_g, \\ \tilde{y}_i = \text{logit}^{-1}(\text{logit}(y_i) + \hat{\alpha}), \quad (75)$$

dengan $\tilde{m}_i = \max(\text{mse}_i, 10^{-8})$; galat **ratio** dicatat bila $|A_g| < \text{double.eps}$. Persamaan (75) dicari lewat `uniroot` pada bracket $[-20, 20]$, diperluas ke $[-50, 50]$ bila tandanya sama, dengan `tol = 1e-9`; persyaratan $0 < y < 1$ (dan $0 < T_g < 1$ untuk `type = "mean"`) diperiksa lebih dulu. Kepatuhan constraint $\sum_i w_{ig}^{\text{calc}} \tilde{y}_i = T_g$ terverifikasi aljabar untuk keempat metode.

Implementation note. Metode **optimal** memakai alokasi $\delta_i = (\text{mse}_i / w_i) \lambda$ sementara solusi KKT standar dari $\min \sum \delta_i^2 / \text{mse}_i$ s.t. $\sum w_i \delta_i = \Delta$ adalah $\delta_i \propto w_i \text{mse}_i$. Constraint tetap tercapai, tetapi alokasinya berbeda ketika bobot tidak seragam (UT-6); variabelnya juga dinamai `inv_prec` padahal isinya `mse`.

Dua tahap hierarkis. Aktif bila `national_target` diberikan dan ada > 1 grup (`R/benchmark.R:318`): STAGE 1 menyetel target grup T_g agar agregatnya menyamai target nasional (empat metode yang sama, `W_share`=porsi bobot grup), STAGE 2 menyetel estimasi level kecil ke T_g ; keduanya dicatat `stage_1_summary` dan diverifikasi ulang.

Algorithm 10: `benchmark_sae` — alur sebenarnya (`R/benchmark.R:120-573`)

- 1 **Masukan** objek model (atau vektor numerik), `target`, `weight`, `method` $\in \{\text{ratio}, \text{difference}, \text{optimal}, \text{logit}\}$, `group`, `type`, `national_target`, `outer_target`, `mse`
Keluaran data frame kelas `fastsae_benchmark` + atribut verifikasi estimasi $\leftarrow$
`df_hb %||% df_ebp %||% df_eblup`; $y \leftarrow \text{hb/ebp/eblup/est}$; `mse` $\leftarrow$ `mse` atau `sd`²
(142-153);
 - 2 bobot $\leftarrow$ nama kolom / vektor / seragam 1 (157-173);
 - 3 grup $\leftarrow$ nama kolom / vektor / "A11" (178-191);
 - 4 $A_g, T_g \leftarrow$ (71) + parsing target (328-393);
 - 5 **if** `national_target` $\neq$ `NULL` **dan** > 1 grup **then**
 - 6 └ STAGE 1: setel T_g agar $\sum_g W_{\text{share},g} T_g = T_{\text{nas}}$ (395-438);
 - 7 STAGE 2: $\tilde{y} \leftarrow$ (72)–(75) per grup (440-512);
 - 8 verifikasi $|\sum w^{\text{calc}} \tilde{y} - T_g|$; status **CONSISTENT** bila $< 10^{-5}$ (534-560);
 - 9 susun `domain`, `weight`, `original`, `benchmarked`, `adjustment`,
`rel_adjustment_pct`, `target` (515-531);
-

Keluaran. `data.frame` kelas `c("fastsae_benchmark", "data.frame")` dengan atribut `method`, `type`, `hierarchical`, `stage1_summary`, `verification`, `national_verification`; metode S3: `print` (status konsistensi per grup), `summary`, `autoplot` (sebaran `original` vs `benchmarked` dengan garis 1:1), dan `plot` yang bila diberi `sf_geom` meneruskan ke `map_sae()`. Rujukan yang memverifikasi pendekatan restrisi/benchmarking di tingkat estimasi: Rao and Molina [2015] (bab 10), You and Rao [2002] dan Wang et al. [2008].

14.2 Diagnostik: diagnose

`diagnose()` adalah fungsi biasa (bukan generic S3) dan mensyaratkan objek `fastsae` (`R/diagnose.R:53-60`). Kuantitas dasar (`R/diagnose.R:84-130`):

$$\text{RSE}_d^{\text{direct}} = 100 \frac{\sqrt{\psi_d}}{|y_d|}, \quad \text{eff}_d = \frac{\psi_d}{\text{mse}_d}, \quad r_d = \frac{y_d - \hat{\theta}_d}{\sqrt{\psi_d}}, \quad \widehat{\text{Pr}}(\text{RSE} < T) = \frac{\#\{\text{RSE} < T\}}{n}, \quad (76)$$

dengan ambang default $T = 25\%$ dan area tanpa sampel dihitung terpisah (`N_sampled/N_unsampled`).

Kalibrasi Brown et al. (2001) (asal: kode). Untuk minimal lima pasang $(y, \hat{\theta})$ ter-sampel:

$$y_d = \alpha + \beta \hat{\theta}_d + e_d \quad (\text{OLS polos}), \quad (77)$$

$$F = \frac{c' V^{-1} c}{2}, \quad c = (\hat{\alpha}, \hat{\beta})' - (0, 1)', \quad c \sim F_{2, n-2}, \quad (78)$$

$$W = \sum_d \frac{(y_d - \hat{\theta}_d)^2}{\psi_d + \text{mse}_d}, \quad W \sim \chi_{n_w}^2 \quad (\text{asimptotik}). \quad (79)$$

`is_unbiased` diputuskan dari p -value F ; `is_good_fit` diputuskan dari penerimaan interval dua sisi $\chi_{\alpha/2, n_w}^2 \leq W \leq \chi_{1-\alpha/2, n_w}^2$.

Implementation note. Empat hal pada paragraf di atas adalah temuan lapangan dan dicatat sebagai UT-1–UT-3: regresi memakai OLS tanpa bobot (bukan WLS $\propto 1/(\psi + \text{mse})$ seperti yang lazim dikutip), statistik Wald dibagi 2 lalu dibandingkan $F(2, n-2)$ (bukan $\chi^2(2)$), keputusan GOF memakai interval dua sisi sedangkan p -value yang dicetak ekor-atas tunggal sehingga status bisa **CAUTION** walau $p \geq \alpha$, dan tidak ada teks rujukan Brown et al. dalam repo — dokumen resminya laporan internal ONS yang tidak dapat diverifikasi di Crossref (lihat `TODO_REFERENCES.md`).

Moran's I residual (`R/diagnose.R:193-246`) dihitung pada residual mentah area ter-sampel (bukan terstandarisasi), W dipotong ke baris ter-sampel, minimal lima area:

$$I = \frac{n}{S_0} \cdot \frac{\sum_{ij} w_{ij} z_i z_j}{\sum_i z_i^2}, \quad (80)$$

$$\text{Var}(I) = \frac{n[(n^2 - 3n + 3)S_1 - nS_2 + 3S_0^2] - \kappa[(n^2 - n)S_1 - 2nS_2 + 6S_0^2]}{(n-1)(n-2)(n-3)S_0^2} - (\mathbb{E}I)^2, \quad (81)$$

dengan $S_0 = \sum_{ij} w_{ij}$, $z = r - \bar{r}$, $S_1 = \frac{1}{2} \sum (w_{ij} + w_{ji})^2$, $S_2 = \sum_i (\sum_j w_{ij} + \sum_j w_{ji})^2$, $\kappa = n \sum z^4 / (\sum z^2)^2$, $\mathbb{E}I = -1/(n-1)$, dan $\text{Var} \geq 10^{-8}$; z -statistik dua sisi $2\Phi(-|z|)$.

Metrik simulasi dan diagnostik Bayes. Bila `truth` diberikan: $rb = 100(\hat{\theta} - \theta)/\theta$, $rmse = 100|\hat{\theta} - \theta|/|\theta|$ (dinamakan “Mean Relative RMSE” padahal ini rerata galat relatif absolut, UT-4), dan `coverage` dari kolom CI apa adanya (UT-5). Untuk model Bayes, DIC/WAIC/marginal likelihood diambil dari `goodness`, CPO/PIT dari `fit$cpo`, jumlah `failure`, lalu uji KS `ks.test(pit, "punif")` (syarat lima nilai PIT di (0,1)).

Status akhir (`R/diagnose.R:334-349`) berurutan: **PASS** bila semua tes lolos, lalu **CAUTION** untuk bias, **CAUTION** untuk GOF, lalu **WARNING** bila proporsi $RSE \geq$ ambang terlalu besar. Bila suatu tes tidak tersedia dianggap lolos.

Algorithm 11: diagnose — alur sebenarnya (`R/diagnose.R:53-386`)

```

1 Masukan objek fastsae, W, truth, rse_threshold = 25, alpha_level = 0.05
   Keluaran list kelas fastsae_diagnose + string status ekstrak df, y,  $\hat{\theta}$ ,  $\psi$ , mse
   (63-73);
2 (76): RSE direct/SAE, efisiensi, residual, proporsi andal (84-130);
3 if  $n_{pasang} \geq 5$  then
4   | regresi (77); Wald (78); GOF (79) (133-191)
5 ;
6 if W tersedia dan  $n \geq 5$  then
7   | Moran's I (80)–(81) pada residual terpotong (193-246)
8 ;
9 if truth diberikan then
10  | rb, rmse, coverage (251-271)
11 ;
12 if objek Bayes then
13  | DIC/WAIC/CPO/PIT + uji KS (276-332)
14 ;
15 status  $\leftarrow$  aturan berurutan pada teks (341-349);
16 susun df_diag (domain, direct_y, sae_pred, vardir, mse, direct_rse,
   sae_rse, eff_ratio, residuals, std_residuais, is_sampled[, cpo, pit])
   (351-382);

```

Keluaran dicetak `print.fastsae_diagnose` dalam lima bagian (efisiensi, kalibrasi Brown, Moran's I, simulasi, Bayes) plus penilaian akhir; grafik lewat `autoplot` dengan tipe `all`, `calibration`, `rse`, `residuals`, `qq`, `pit`, `cpo`. Tidak ada `summary` maupun `plot` untuk kelas ini (UT-13).

14.3 Perbandingan dua model: `compare_sae`

`compare_sae(model1, model2, names, thresholds = c(20,30))` hanya memiliki method `.default` (UT-14); kunci gabung adalah `domain`, atau `c(domain, subarea)`, atau `c(domain, time)` (inner join; error bila tumpang tindih nol). Metrik yang dihitung (`R/compare_sae.R:112-176`):

$$r = \text{cor}(\hat{\theta}_1, \hat{\theta}_2), \quad \rho = \text{Spearman}, \quad \text{MAE} = |\overline{d}|, \quad \text{RMSD} = \sqrt{\overline{d^2}}, \quad d = \hat{\theta}_2 - \hat{\theta}_1, \quad (82)$$

plus rasio $\text{mse}_1/\text{mse}_2$, jumlah `domain` dengan $\text{mse}_2 < \text{mse}_1$, dan $\Delta \overline{\text{RSE}}$. Tidak ada argumen `truth`, sehingga `RMSD/MAE` di sini adalah selisih antarmodel, bukan galat terhadap kebenaran.

`thresholds` hanya dipakai sebagai garis horizontal pada plot `rse` (UT-14). Lima tipe `autoplot`: `scatter` (garis 1:1), `comparison` (default, dodged), `difference` (lollipop), `mse` (bar dodged), `rse` (garis + ambang).

14.4 Flag reliabilitas dan ekspor: `export_sae`

`add_reliability_flags` memotong RSE dengan `cut(breaks = (-∞, 20, 30, ∞))` menjadi tiga tingkat *Reliable* ($<20\%$), *Use with Caution* ($20\text{--}30\%$), *Unreliable* ($\geq 30\%$); bila kolom RSE tidak ada, ia menghitung $100\sqrt{\text{mse}}/|\hat{\theta}|$.

Implementation note. Dokumen menyebut fungsi menerima “objek atau data frame” tetapi nilai kembalian selalu berupa data frame saja — penugasan balik ke `object$df_*` tidak efektif karena aturan copy-on-modify R (UT-9).

`export_sae(object, file, benchmark, thresholds, overwrite)` hanya menerima ekstensi `xlsx/csv`; sheet yang ditulis: `Estimates`, `Model_Summary`, `Benchmarked` dan `Benchmarked_Groups` (bila hierarkis) — bisa empat, bukan “hingga tiga” seperti dokumentasi (UT-10). Penulisan `xlsx` memakai `writexl`, fallback `openxlsx`, fallback terakhir CSV berisi `Estimates` saja; sheet `Benchmarked` tidak pernah ikut pada mode `csv`. Sheet `Estimates` memuat $\text{SE} = \sqrt{\text{mse}}$, $\text{CI}_{95\%} = \hat{\theta} \pm 1.96 \text{SE}$ (bila kolom CI tidak ada), serta flag reliabilitas; sheet `Model_Summary` berupa pasangan `Parameter/Value` (paket, tipe model, method, konvergensi, komponen ragam, goodness of fit, koefisien + SE + p).

14.5 Peta choropleth: `map_sae`

Empat method: `.fastsae`, `.fastsae_benchmark`, `.list`, `.default`; semuanya mensyaratkan `sf` dan menghasilkan `ggplot`. Lima tipe `type`:

- `estimate` — `geom_sf` + `viridis`;
- `rse` — `option = "magma"`, arah terbalik;
- `reliability` — tiga warna manual `#198754` / `#ffc107` / `#dc3545` sesuai tingkat §14.4;
- `comparison` — facet Direct Survey vs SAE (otomatis jatuh ke `estimate` bila kolom direct seluruhnya NA);
- `difference` — $\hat{\theta} - y$ dengan `gradient2 #2b83ba/#ffffbf/#d7191c`.

Pencocokan kunci otomatis memakai daftar kandidat `domain`, `area`, `id`, `code`, `kd_kab`, `kode`, `kabupaten`, `provinsi`, `district`, `region` dan mengadopsi pasangan dengan tum-pang tindih terbesar *bila mencapai* 40% jumlah domain; gagal → error.

Implementation note. Argumen `thresholds = c(20,30)` diteruskan tetapi tidak pernah dipakai: pemotongan reliabilitas hard-coded di extractor (UT-12). Pemetaan dua model menyusun `data.frame(matched_sf[, c("domain", "geometry")], ...)`, yang akan gagal bila kolom geometri `sf` bukan `"geometry"` (UT-16).

14.6 Metode S3 dan grafik

Tabel 28 merangkum metode yang terdaftar di `NAMESPACE:25–54`.

Pada `autoplot` model tunggal, bila kolom CI belum ada, pita dibuat $\hat{\theta} \pm 1.96\sqrt{\text{mse}}$; tipe `rse` membandingkan RSE SAE vs RSE direct dengan dua ambang `c(20,30)`.

Tabel 28: Metode S3 utama beserta file sumbernya.

Generic	Objek	Perilaku ringkas
print	fastsae	Call, konvergensi + n_iter, tipe model, komponen ragam, printCoefmat(estcoef), head(df,6)
summary	fastsae	list 20 komponen; dicetak print.summary.fastsae
coef, fitted, residuals	fastsae	estcoef\$beta; hb/ebp/eblup; $y - \hat{\theta}$
plot, autoplot	fastsae	7 tipe: comparison, ribbon, mse, estimates, scatter, rse, map
autoplot	list fastsae	comparison, mse, scatter (butuh names(x) — UT-15)
autoplot	fastsae_diagnose	all, calibration, rse, residuals, qq, pit, cpo
print, summary, autoplot, plot	fastsae_benchmark	lihat §14.1
print, summary, autoplot, plot	fastsae_comparison	lihat §14.3

14.7 Data simulasi

Tiga pembangkit tersedia, semuanya menghasilkan matriks ketetanggaan lewat `sim_spatial_weights()` (tipe `knn/grid/ring`, gaya B biner atau `W` row-standar; kNN disimetrisasi $A \leftarrow \max(A, A')$).

DGP area-level (`sim_area_data`, `R/sim_area_data.R:63-166`):

$$v = (\mathbf{I} - \rho W_{\text{std}})^{-1} \varepsilon, \quad \tilde{v} = \text{standarisasi}(v), \quad \tilde{u} = \text{standarisasi}(N(0, 1)), \quad (83)$$

$$u = \sigma_u(\sqrt{\varphi} \tilde{v} + \sqrt{1 - \varphi} \tilde{u}), \quad \eta = x' \beta + u, \quad (84)$$

$$y \mid \eta \sim \begin{cases} \eta + \mathcal{N}(0, \psi) & \psi \sim U(0.04, 0.16) \\ \text{Poisson}(\text{exposure} \cdot e^{\text{clip}(\eta/2 - 0.5, -4, 4)}) & \text{offset} \\ \text{Binomial}(\text{trials}, \text{logit}^{-1}(\eta - 1)) & \text{peluang} \\ \text{NB}(\theta = 3, \mu = 15 e^{\text{clip}(\eta/2, -3, 4)}) & \text{gamma-Poisson} \\ \text{Beta}(\mu\kappa, (1 - \mu)\kappa) & \kappa = 25 \\ \text{Gamma}(k = 5, \mu/k) & k = 5 \end{cases} \quad (85)$$

dengan $x_1 \sim N(2, 1)$, $x_2 \sim U(0, 5)$, parameter dipotong $\rho \in [-0.95, 0.95]$, $\varphi \in [0, 1]$, dan `n_unsampled` domain diset `NA`; `exposure` $\sim \text{round } U(80, 400)$ dan `trials` $\sim \text{round } U(50, 250)$. Rata-rata pada Beta adalah $\mu = \text{clip}(\text{logit}^{-1}(\eta - 1), 0.02, 0.98)$ (dan y dipotong ke $[0.001, 0.999]$), pada Gamma $\mu = \exp(\text{clip}(\eta/2, -3, 3))$, dan pada NB $\mu = 15 \exp(\text{clip}(\eta/2, -3, 4))$. (84) adalah campuran gaya BYM2 yang sama dengan (68).

DGP panel (`sim_series_data`) menambah efek spasial $u_1 = \sigma_s \text{standar}((\mathbf{I} - \rho_s W_{\text{std}})^{-1} \varepsilon)$, proses AR(1) per domain $u_2[d, t] = \rho_t u_2[d, t-1] + \mathcal{N}(0, \sigma_t \sqrt{1 - \rho_t^2})$ (varian stasioner σ_t^2), dan tren deterministik (`linear/random_walk/ar1/none`); pengurutan baris `domain-major` memenuhi syarat `eblup_stfh()`.

Implementation note. Dataset terlampir berbeda dari keluaran pembangkit: `sim_area` memakai kolom `area` dengan 14 kolom tanpa `truth_gaussian`, sedangkan `sim_area_data()` menghasilkan 15 kolom dengan `domain` dan `truth_gaussian` (UT-11); hal yang sama berlaku untuk `sim_panel`.

14.8 Rujukan lapisan utilitas

Blok roxygen `R/benchmark.R:79-93` memuat lima rujukan dan `R/diagnose.R:27-33` memuat tiga; yang berhasil diverifikasi dipakai di sini: [Rao and Molina \[2015\]](#) (bab benchmarking), [You and Rao \[2002\]](#), [Datta et al. \[2010\]](#) (benchmarking Bayes), dan [Berg and Fuller \[2014\]](#). Rujukan yang tidak dapat diverifikasi (Steorts et al. 2014; Brown et al. 2001; Cliff & Ord 1981) tidak dikutip sebagai referensi bibliografis dan didaftarkan di `TODO_REFERENCES.md` bagian 5, termasuk dua koreksi judul/tahun terhadap teks kode.

A Derivasi identitas Woodbury dan penerapannya

Identitas. Untuk matriks yang saling kompatibel,

$$(\mathbf{V}_A + \mathbf{Z}\mathbf{G}\mathbf{Z}')^{-1} = \mathbf{V}_A^{-1} - \mathbf{V}_A^{-1}\mathbf{Z}(\mathbf{G}^{-1} + \mathbf{Z}'\mathbf{V}_A^{-1}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{V}_A^{-1}, \quad (86)$$

dan log-determinannya

$$\log |\mathbf{V}_A + \mathbf{Z}\mathbf{G}\mathbf{Z}'| = \log |\mathbf{V}_A| + \log |\mathbf{G}| + \log |\mathbf{G}^{-1} + \mathbf{Z}'\mathbf{V}_A^{-1}\mathbf{Z}|. \quad (87)$$

Bukti singkat: tulis $\mathbf{V}_A + \mathbf{Z}\mathbf{G}\mathbf{Z}' = [\mathbf{I} \ \mathbf{Z}] \begin{pmatrix} \mathbf{V}_A & 0 \\ 0 & \mathbf{G} \end{pmatrix} \begin{pmatrix} \mathbf{I} \\ \mathbf{Z}' \end{pmatrix}$ dan pakai rumus invers blok ((86) adalah kasus $\mathbf{C} = \mathbf{G}$, $\mathbf{U} = \mathbf{Z}$); untuk (87) pakai determinan matriks blok pada representasi yang sama. Kasus khusus $\mathbf{G} = \gamma\mathbf{I}$ berkurang ke Sherman–Morrison,

$$(\mathbf{V}_A + \gamma\mathbf{z}\mathbf{z}')^{-1} = \mathbf{V}_A^{-1} - \frac{\gamma \mathbf{V}_A^{-1}\mathbf{z}\mathbf{z}'\mathbf{V}_A^{-1}}{1 + \gamma\mathbf{z}'\mathbf{V}_A^{-1}\mathbf{z}}. \quad (88)$$

Penerapan pada `fastsae`. Tabel 29 mencatat persis di mana identitas ini dipakai, dan di mana ia *tidak* dipakai (padahal strukturnya memungkinkan).

Tabel 29: Pemakaian identitas Woodbury di dalam paket. Sumber: baris kode yang dikutip pada kolom terakhir.

Fungsi	Bentuk pemakaian	Lokasi
<code>eblup_stfh</code>	$\mathbf{V}_A = \text{diag blok } T \times T \text{ per domain, } \mathbf{G} = \sigma_1^2\Omega_1,$ $\mathbf{Z} = \mathbf{Z}_1; \mathbf{C}$ berdimensi $D \times D$	<code>eblup_stfh_core.cpp:90-153</code>
<code>eblup_twofold</code>	per blok area: $V_d = \sigma_v^2\mathbf{1}\mathbf{1}' + \text{diag}(\sigma_u^2 + \psi_d),$ kasus (88) dengan $z = \mathbf{1}$	<code>eblup_tfh.cpp:98-108, 345-350</code>
<code>eblup_hb_--</code>	— (diatasi INLA lewat Cholesky sparse)	—
<code>eblup_fh, eblup_sfh</code>	tidak dipakai: V diinversi penuh $m \times m$ dengan <code>inv_sympd/pinv</code>	<code>eblup_fh.cpp,</code> <code>eblup_sfh_core.cpp:318-320</code>

- **STFH.** Dengan $\mathbf{V}_A$ blok diagonal per domain, $\mathbf{V}_A^{-1}\mathbf{Z}_1$ dan $\mathbf{Z}_1'\mathbf{V}_A^{-1}\mathbf{Z}_1$ dihitung per blok, lalu (86) dengan $\mathbf{G} = \sigma_1^2\Omega_1$ memberi $\mathbf{V}^{-1}$ dengan biaya $O(DT^2) + O(D^3)$ alih-alih $O((DT)^3)$; (87) menurunkan $\log |\mathbf{V}|$ dari $O((DT)^3)$ menjadi $O(DT^3) + O(D^3)$. Catatan: $\mathbf{C}$ yang muncul di kode adalah $\mathbf{C} = \sigma_1^{-2}\Omega_1^{-1} + \text{diag}(\mathbf{Z}_1'\mathbf{V}_A^{-1}\mathbf{Z}_1)$, ekuivalen dengan (86) setelah kedua sisi dikalikan σ_1^2 .
- **Two-fold.** Karena $\sigma_v^2\mathbf{1}\mathbf{1}'$ berderajat 1, (88) dipakai per area dengan $d = 1/(\sigma_u^2 + \psi_d)$, $s = \sum_i d_i$ dan $c = \sigma_v^2/(1 + \sigma_v^2s)$ (kode `dd`, `s`, `c`), sehingga $V_d^{-1}a = d \odot a - c d(d'a)$ — biaya $O(n_d)$ per blok.
- **Memori.** Bahkan dengan Woodbury, $\mathbf{V}^{-1}$, P , dan matriks turunan disimpan penuh, sehingga jejak memori tetap $O(M^2)$; yang dihemat hanyalah flops inversi dan log-determinan.

B Derivasi skor dan informasi Fisher (ML dan REML)

Misalkan $y \sim N(\mathbf{Z}\beta, \mathbf{V}(\theta))$ dengan $\theta \in \{\sigma^2, \rho, \dots\}$ dan $D_a = \partial \mathbf{V} / \partial \theta_a$. Dari $\ell = -\frac{1}{2} [n \log 2\pi + \log |\mathbf{V}| + (\beta - \hat{\beta})' \mathbf{X}' \mathbf{V}^{-1} \mathbf{X}(\dots) + r' \mathbf{V}^{-1} r]$ dengan $r = y - \mathbf{X}\hat{\beta}$ dan $\hat{\beta} = (\mathbf{X}' \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}' \mathbf{V}^{-1} y$, turunan parsial memakai $\partial \mathbf{V}^{-1} / \partial \theta_a = -\mathbf{V}^{-1} D_a \mathbf{V}^{-1}$ memberi

$$s_a = \frac{\partial \ell}{\partial \theta_a} = -\frac{1}{2} \text{tr}(\mathbf{V}^{-1} D_a) + \frac{1}{2} r' \mathbf{V}^{-1} D_a \mathbf{V}^{-1} r \quad (\text{ML}). \quad (89)$$

Estimasi terbatas (REML) memakai residual berbentuk Pr dengan $P = \mathbf{V}^{-1} - \mathbf{V}^{-1} \mathbf{X} \mathbf{Q} \mathbf{X}' \mathbf{V}^{-1}$ (yang membatalkan komponen desain), sehingga

$$s_a^{\text{REML}} = -\frac{1}{2} \text{tr}(P D_a) + \frac{1}{2} y' P D_a P y, \quad \mathcal{I}_{ab}^{\text{REML}} = \frac{1}{2} \text{tr}(P D_a P D_b), \quad (90)$$

dan $\mathcal{I}_{ab}^{\text{ML}} = \frac{1}{2} \text{tr}(\mathbf{V}^{-1} D_a \mathbf{V}^{-1} D_b)$. Yang dikodekan: untuk `eblup_sfh` dan `eblup_stfh`, (90) dipakai apa adanya bila `method = "REML"`; untuk `method = "ML"` pada SFH, baris tracenya memakai $\mathbf{V}^{-1}$ tetapi kuadratiknya masih $y' P D P y$ — persis implementasi yang menjadi temuan SFH-1 dan FH-1. Untuk `eblup_twofold` kedua bentuk ditulis terpisah dalam (46) dan (47).

Langkah iterasi. Karena ℓ tidak konkav linear pada θ , digunakan langkah Newton–Fisher $\Delta = \mathcal{I}^{-1} s$ (dengan pembakuan `solve` dan fallback `pinv` bila singular), diikuti pembatasan domain parameter (ρ diklem ± 0.999 , $\sigma^2 \geq 0$) dan pemberhentian berdasarkan galat relatif $\max_a |\Delta_a / (\theta_a + 10^{-12})| \leq 10^{-4}$. Galat baku komponen ragam diambil dari $\sqrt{\text{diag}(\mathcal{I}^{-1})}$ pada informasi final.

Turunan D_a yang dipakai. Untuk SFH/STFH dengan $A = (\mathbf{I} - \rho \mathbf{W}')'(\mathbf{I} - \rho \mathbf{W})$,

$$\frac{\partial A}{\partial \rho} = -(\mathbf{W} + \mathbf{W}') + 2\rho \mathbf{W}' \mathbf{W}, \quad \frac{\partial G}{\partial \rho} = -\sigma^2 A^{-1} \frac{\partial A}{\partial \rho} A^{-1}, \quad \frac{\partial G}{\partial \sigma^2} = A^{-1}, \quad (91)$$

dan pada dua-fold dua turunan hanya terhadap σ_v^2 dan σ_u^2 lewat $\partial V_d / \partial \sigma_v^2 = \mathbf{1}\mathbf{1}'$, $\partial V_d / \partial \sigma_u^2 = \mathbf{I}$ (matriks identitas pada blok d).

C Derivasi suku-suku MSE (g1, g2, g3, g4)

Dekomposisi galat prediktor. Dengan $G = \sigma^2 A^{-1}$, $\mathbf{V} = G + \Psi$ ($\Psi = \text{diag}(\psi)$), dan prediktor $\hat{\theta} = \mathbf{Z}\hat{\beta} + G\mathbf{V}^{-1}(y - \mathbf{Z}\hat{\beta})$, tulis $y = \mathbf{Z}\beta + \theta + e$. Menggunakan $\mathbf{V}^{-1}\Psi = \mathbf{I} - \mathbf{V}^{-1}G$ dan $\Psi\mathbf{V}^{-1} = \mathbf{I} - G\mathbf{V}^{-1}$:

$$\hat{\theta} - \theta = \underbrace{(\mathbf{I} - G\mathbf{V}^{-1})\mathbf{Z}(\hat{\beta} - \beta)}_{\text{galat } \beta} + \underbrace{G\mathbf{V}^{-1}e - \Psi\mathbf{V}^{-1}\theta}_{\text{galat } u, e}. \quad (92)$$

g_1 . Dari suku kedua (kosinus nol karena $e \perp \theta$):

$$\begin{aligned} \text{Var}(G\mathbf{V}^{-1}e - \Psi\mathbf{V}^{-1}\theta) &= G\mathbf{V}^{-1}\Psi\mathbf{V}^{-1}G + \Psi\mathbf{V}^{-1}G\mathbf{V}^{-1}\Psi \\ &= \underbrace{G\mathbf{V}^{-1}\Psi\mathbf{V}^{-1}G}_{A\Psi A', A=G\mathbf{V}^{-1}} + \underbrace{(\mathbf{I} - A)G(\mathbf{I} - A)'}_{\text{perluasan}} \\ &= G\mathbf{V}^{-1}G - G\mathbf{V}^{-1}G\mathbf{V}^{-1}G + G - 2G\mathbf{V}^{-1}G + G\mathbf{V}^{-1}G\mathbf{V}^{-1}G \\ &= G - G\mathbf{V}^{-1}G, \end{aligned} \quad (93)$$

sehingga $g_1 = \text{diag}(G - G\mathbf{V}^{-1}G)$ — bentuk yang persis dikodekan (`Ga = G - GV-1 * G`).

g_2 . Dari suku pertama (92) dengan $\text{Var}(\hat{\beta} - \beta) = Q = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}$:

$$g_2 = \text{diag}(R Q R'), \quad R = (\mathbf{I} - G\mathbf{V}^{-1})\mathbf{Z} \quad (\text{kode: } R = X - GV^{-1}X). \quad (94)$$

g_3 (**ketidakpastian parameter ragam**). Karena G bergantung pada θ , tulis $\hat{\theta}_i(\hat{\theta}) \approx \hat{\theta}_i(\theta) + \xi'_i(\hat{\theta}_{\text{param}} - \theta)$ dengan $\text{Var}(\hat{\theta}_{\text{param}}) \approx \mathcal{I}^{-1}$, sehingga

$$g_3(i) = \xi'_i \mathcal{I}^{-1} \xi_i = \sum_{a,b} (\mathcal{I}^{-1})_{ab} \xi_{ia} \xi_{ib}. \quad (95)$$

Kode SFH mengekspresikan bentuk ini lewat $l_1 = \mathbf{V}^{-1}D_1 - \sigma^2\mathbf{V}^{-1}D_1\mathbf{V}^{-1}D_1$ dan $l_2 = \mathbf{V}^{-1}D_2 - \sigma^2\mathbf{V}^{-1}D_2\mathbf{V}^{-1}D_1$ ($D_1 = \mathbf{I}$, $D_2 = \partial\mathbf{V}/\partial\rho$): dengan L_i matriks $2 \times m$ yang barisnya adalah l'_{1i} dan l'_{2i} ,

$$g_3(i) = \text{tr}(L_i \mathbf{V} L'_i \mathcal{I}^{-1}) = \sum_{a,b} (\mathcal{I}^{-1})_{ab} l'_{ai} \mathbf{V} l_{bi}, \quad (96)$$

identik dengan (95) melalui $\xi'_a \xi_b = l'_{ai} \mathbf{V} l_{bi}$. Untuk FH (satu parameter) ini meluruh menjadi $g_3 = \text{Var}(\hat{\sigma}^2) \cdot (\text{derivative-squared})$ seperti ditulis pada (13).

g_4 (**koreksi orde keempat, hanya SFH**). Suku ini berasal dari estimasi Ψ (varian direktor) yang juga tidak diketahui; kode membangun $D = (\Psi\mathbf{V}^{-1}D_{12})(\mathcal{I}_{01}^{-1} + \mathcal{I}_{10}^{-1}) + (\Psi\mathbf{V}^{-1}D_{22})\mathcal{I}_{11}^{-1}$ dengan $D_{12} = -\partial^2 A/\partial\rho^2$ -faktor dan D_{22} orde kedua pada ρ , lalu $g_4(i) = \frac{1}{2}D_{ii}$. Totalnya (31): $g_1 + g_2 + 2g_3 - g_4$; untuk dua-fold faktor dua sudah termasuk di dalam g_3 sehingga totalnya $g_1 + g_2 + g_3$ ((51)), sesuai komentar kode.

Domain tanpa sampel. Karena tidak ada informasi langsung, g_2 menjadi $x'_{ns} Q x_{ns}$ (baris estimasi langsung dari Q) dan g_3 tidak dapat dihitung (tidak ada pasangan $y, \hat{\theta}$), sehingga

$$\widehat{\text{MSE}}(\hat{\theta}_{ns}) = g_{1,ns} + g_{2,ns} \quad (\text{FH/SFH}), \quad (97)$$

sementara bentuk yang dikodekan dua-fold untuk sub-area tak-sampel adalah $g_1^* + g_2^* + g_3^*$ (baris 445-464) karena g_3^* hanya bergantung pada parameter ragam yang tetap diketahui.

Catatan dua-fold. Komentar kode `eb lup_tfh.cpp:19-24` menyatakan bahwa pendekatan g_3 matriks menggantikan rumus tertutup Torabi and Rao [2014] (persamaan 3.4) karena suku $[A][B]$ dianggap semu; pendekatan itu divalidasi dengan turunan beda pemisah (korelasi 0,97/0,96/0,74 terhadap uji numerik). Laporan ini memperlakukannya sebagai perbedaan implementasi TFH-1, bukan sebagai kekeliruan yang diverifikasi ulang di sini.

D Glosarium

Tabel 30 menautkan istilah, simbol, dan nama di kode.

E Reproduksi angka dan gambar dalam laporan ini

Seluruh tabel dan gambar di bagian 3 dihasilkan ulang dari data mentah di `inst/extdata` oleh dua skrip; tidak ada angka benchmark yang diketik manual.

Tabel 30: Glosarium tiga arah: istilah — simbol — nama di kode.

Istilah	Simbol	Nama di kode
Estimasi BLUP empirik	$\hat{\theta}_d$	eblup, hb, ebp
Varians direktor	ψ_d	vardir
Fungsi presisi spasial	A	A (eblup_sfh_core.cpp:311)
Matriks proyeksi	P	$P = V_i - X_t V_i.t() * Q * X_t V_i$
Matriks info Fisher	$\mathcal{I}$	Idev (SFH), F (STFH), I (FH)
Korelasi spasial (SAR)	ρ	rho, rho_fix
Fraksi spasial BYM2	φ	phi (hyperpar)
Fraksi sampel	$f_d = n_d/N_d$	f, ratio (BHF)
Suku g MSE	$g_1, \dots, g_4$	g1d, g2d, g3d, g4d
Galat mutlak relatif	RSE	rse ($100\sqrt{\text{mse}}/ \hat{\theta} $)
Domain tanpa sampel	I_{ns}	find_nonfinite(y), unsampled_domains
Inversi Woodbury	(86)	variabel C (STFH), dd/s/c (two-fold)
Aproksimasi Laplace	—	strategy pada INLA::inla
Prior PC	(69)	prior_prec = list(prior="pc.prec", ...)
Graf ketetanggaan	W, Q	W, graph (inla.graph)
Indeks domain (0-based)	—	domain_idx, area_idx
Kelas hasil	—	"fastsae", "fastsae_hb", "fastsae_benchmark"

Listing 19: Perintah regenerasi (dikerjakan dari direktori paper/).

```
# 1. tabel (.tex berisi lingkungan float lengkap) -> paper/tables/
Rscript scripts/01_tables.R

# 2. gambar log-scale -> paper/figures/
Rscript scripts/02_figures.R

# 3. laporan
latexmk -pdf main.tex          # atau: latexmk -pdf -jobname=fastsae_technical_report main.tex
```

Setiap \caption hasil skrip menyertakan baris *Sumber:* yang menunjuk berkas .rds sumber, dan setiap angka diformat formatC(format="g", digits=6), sehingga perbedaan pembulatan antara laporan ini dan README dapat ditelusuri ke skrip, bukan ke pengetikan.

Lingkungan eksekusi. Kutipan sessionInfo() yang berlaku untuk pembuatan laporan ini tersimpan di scripts/sessionInfo.txt; ringkasannya:

- R 4.6.1 (2026-06-24), aarch64-apple-darwin23, macOS Tahoe 26.6.2, zona waktu Asia/Makassar;
- paket: fastsae 1.0.0, sae 1.3, emdi 2.2.3, tipsae 1.0.3, INLA 26.8.7, lme4 2.0.1, Matrix 1.7.5, Rcpp 1.1.2, RcppArmadillo 15.4.2.1, bench 1.1.4, ggplot2 4.0.3, sf 1.1.1, cli 3.6.6, testthat 3.3.2, covr 3.6.5.

Yang tidak dapat direproduksi dari repo. Berdasarkan pemeriksaan terhadap inst/extdata dan benchmarks/ (bagian 3, temuan DOC-11):

- empat berkas — `eblup_benchmark.rds`, `seblup_benchmark.rds`, `steblup_benchmark.rds`, `beta_estimates_n1000.rds` — tidak memiliki skrip pembuat di repo, sehingga isinya tidak dapat dibangkitkan ulang;
- jumlah iterasi nyata sebagian besar run tidak tercatat di dalam berkas (hanya `n_iter` hasil `bench::mark`);
- jenis CPU, jumlah thread, dan `OMP_NUM_THREADS` tidak pernah direkam oleh skrip mana pun, sehingga angka waktu hanya dapat dibandingkan *di dalam* satu berkas yang sama;
- memori yang dilaporkan adalah total alokasi `bench::mark()`\$`mem_alloc`, bukan puncak RSS (label “Peak” pada dokumen lain salah).

Untuk pengujian unit dan cakupan kode, perintah yang dipakai pada pengembangan paket adalah:

```
# unit test (membutuhkan GCC/Homebrew untuk gcov bila ingin cakupan)
R CMD build . && R CMD check fastsae_*.tar.gz
# cakupan: hasilnya disimpan sebagai cov_res.rds, lalu
# covr::tally_coverage(readRDS("cov_res.rds"))
```

Referensi yang tidak dapat diverifikasi. Daftar lengkap entri yang ada di blok `@references` kode tetapi tidak dapat diverifikasi (Steorts et al. 2014; Brown et al. 2001; Cliff & Ord 1981) beserta dua koreksi judul/tahun terhadap teks kode terdapat di `TODO_REFERENCES.md`; seluruh perbedaan implementasi terkumpul di `DISCREPANCIES.md`.

Pustaka

- Sudipto Banerjee, Bradley P. Carlin, and Alan E. Gelfand. *Hierarchical Modeling and Analysis for Spatial Data*. Chapman & Hall/CRC Monographs on Statistics and Applied Probability. Chapman & Hall/CRC, Boca Raton, FL, 2nd edition, 2014. ISBN 978-1-4398-1917-3. doi: 10.1201/b17115.
- Douglas Bates, Martin Mächler, Ben Bolker, and Steve Walker. Fitting linear mixed-effects models using lme4. *Journal of Statistical Software*, 67(1), 2015. doi: 10.18637/jss.v067.i01.
- George E. Battese, R. M. Harter, and Wayne A. Fuller. An error-components model for prediction of county crop areas using survey and satellite data. *Journal of the American Statistical Association*, 83:28–36, 1988. doi: 10.1080/01621459.1988.10478561.
- Emily J. Berg and Wayne A. Fuller. Small area prediction of proportions with applications to the Canadian Labour Force Survey. *Journal of Survey Statistics and Methodology*, 2(3): 227–256, 2014. doi: 10.1093/jssam/smu011.
- Julian Besag. Spatial interaction and the statistical analysis of lattice systems. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 36(2):192–236, 1974. doi: 10.1111/j.2517-6161.1974.tb00999.x.
- Julian Besag, Jeremy York, and Annie Mollié. Bayesian image restoration, with two applications in spatial statistics. *Annals of the Institute of Statistical Mathematics*, 43(1):1–20, 1991. doi: 10.1007/BF00116466.
- G. S. Datta, M. Ghosh, R. Steorts, and J. Maples. Bayesian benchmarking with applications to small area estimation. *TEST*, 20(3):574–588, 2010. doi: 10.1007/s11749-010-0218-y.

- Gauri Sankar Datta and Malay Ghosh. Bayesian prediction in linear models: Applications to small area estimation. *The Annals of Statistics*, 19(4):1748–1770, 1991. doi: 10.1214/aos/1176348369.
- Gauri Sankar Datta and P. Lahiri. A unified measure of uncertainty of estimated best linear unbiased predictors in small area estimation problems. *Statistica Sinica*, 10:613–627, 2000.
- Silvia De Nicolò and Aldo Gardini. The R package tipsae: Tools for mapping proportions and indicators on the unit interval. *Journal of Statistical Software*, 108(1):1–36, 2024. doi: 10.18637/jss.v108.i01.
- Silvia De Nicolò, Maria Rosaria Ferrante, and Silvia Pacei. Small area estimation of inequality measures using mixtures of Beta. *Journal of the Royal Statistical Society: Series A (Statistics in Society)*, 187(1):85–109, 2024. doi: 10.1093/jrssa/qnad083.
- María Dolores Esteban, María José Lombardía, Esther López-Vizcaíno, Domingo Morales, and Agustín Pérez. Small area estimation of proportions under area-level compositional mixed models. *TEST*, 29(3):793–818, 2019. doi: 10.1007/s11749-019-00688-w.
- Robert E. Fay and Roger A. Herriot. Estimates of income for small places: An application of James-Stein procedures to census data. *Journal of the American Statistical Association*, 74:269–277, 1979. doi: 10.1080/01621459.1979.10482505.
- Silvia L. P. Ferrari and Francisco Cribari-Neto. Beta regression for modelling rates and proportions. *Journal of Applied Statistics*, 31(7):799–815, 2004. doi: 10.1080/0266476042000214501.
- Virgilio Gómez-Rubio. *Bayesian Inference with INLA*. Chapman & Hall/CRC, Boca Raton, FL, 2020. ISBN 978-1-138-03987-2. doi: 10.1201/9781315175584.
- Ryan Janicki. Properties of the beta regression model for small area estimation of proportions and application to estimation of poverty rates. *Communications in Statistics – Theory and Methods*, 49(9):2264–2284, 2020. doi: 10.1080/03610926.2019.1570266.
- R. N. Kacker and David A. Harville. Approximations for standard errors of estimators of fixed and random effects in mixed linear models. *Journal of the American Statistical Association*, 79:853–862, 1984. doi: 10.1080/01621459.1984.10477102.
- Ann-Kristin Kreutzmann, Sören Pannier, Natalia Rojas-Perilla, Timo Schmid, Matthias Templ, and Nikos Tzavidis. The R package emdi for estimating and mapping regionally disaggregated indicators. *Journal of Statistical Software*, 91(7):1–33, 2019. doi: 10.18637/jss.v091.i07.
- Finn Lindgren and Håvard Rue. Bayesian spatial modelling with R-INLA. *Journal of Statistical Software*, 63(19), 2015. doi: 10.18637/jss.v063.i19.
- Eduardo Marhuenda, Isabel Molina, and Domingo Morales. Small area estimation with spatio-temporal Fay–Herriot models. *Computational Statistics & Data Analysis*, 58:308–325, 2013. doi: 10.1016/j.csda.2012.09.002.
- Isabel Molina and Yolanda Marhuenda. sae: An R package for small area estimation. *The R Journal*, 7(1):81–98, 2015. doi: 10.32614/RJ-2015-007.
- Isabel Molina and J. N. K. Rao. Small area estimation of poverty indicators. *Canadian Journal of Statistics*, 38(3):369–385, 2010. doi: 10.1002/cjs.10051.
- Isabel Molina, Nicola Salvati, and Monica Pratesi. Bootstrap for estimating the MSE of the spatial EBLUP. *Computational Statistics*, 24(3):441–458, 2009. doi: 10.1007/s00180-008-0138-4.

- Danny Pfeffermann. New important developments in small area estimation. *Statistical Science*, 28(1):40–68, 2013. doi: 10.1214/12-STS395.
- N. G. N. Prasad and J. N. K. Rao. The estimation of the mean squared error of small-area estimators. *Journal of the American Statistical Association*, 85:163–171, 1990. doi: 10.1080/01621459.1990.10475320.
- Monica Pratesi and Nicola Salvati. Small area estimation: the EBLUP estimator based on spatially correlated random area effects. *Statistical Methods and Applications*, 17(1):113–141, 2008. doi: 10.1007/s10260-007-0061-9.
- J. N. K. Rao and Isabel Molina. *Small Area Estimation*. John Wiley & Sons, Hoboken, NJ, 2nd edition, 2015. ISBN 9781118735787. doi: 10.1002/9781118735855.
- J. N. K. Rao and M. Yu. Small-area estimation by combining time-series and cross-sectional data. *Canadian Journal of Statistics*, 22:511–528, 1994. doi: 10.2307/3315407.
- Andrea Riebler, Sigrunn H. Sørbye, Daniel Simpson, and Håvard Rue. An intuitive Bayesian spatial model for disease mapping that accounts for scaling. *Statistical Methods in Medical Research*, 25(4):1145–1165, 2016. doi: 10.1177/0962280216660421.
- Håvard Rue and Leonhard Held. *Gaussian Markov Random Fields: Theory and Applications*, volume 104 of *Monographs on Statistics and Applied Probability*. Chapman & Hall/CRC, Boca Raton, FL, 2005. ISBN 978-1-58488-432-3. doi: 10.1201/9780203492024.
- Håvard Rue, Sara Martino, and Nicolas Chopin. Approximate Bayesian inference for latent Gaussian models by using integrated nested Laplace approximations. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 71(2):319–392, 2009. doi: 10.1111/j.1467-9868.2008.00700.x.
- Daniel Simpson, Håvard Rue, Andrea Riebler, Thiago G. Martins, and Sigrunn H. Sørbye. Penalising Model Component Complexity: A principled, practical approach to constructing priors. *Statistical Science*, 32(1):1–28, 2017. doi: 10.1214/16-STS576.
- Sigrunn H. Sørbye and Håvard Rue. Scaling intrinsic Gaussian Markov random field priors in spatial modelling. *Spatial Statistics*, 8:39–51, 2014. doi: 10.1016/j.spasta.2013.06.004.
- Mahmoud Torabi and J. N. K. Rao. On small area estimation under a sub-area level model. *Journal of Multivariate Analysis*, 127:36–55, 2014. doi: 10.1016/j.jmva.2014.02.001.
- Junyuan Wang, Wayne A. Fuller, and Yongming Qu. Small area estimation under a restriction. *Survey Methodology*, 34(1):29–36, 2008.
- Yong You and J. N. K. Rao. A pseudo-empirical best linear unbiased prediction approach to small area estimation using survey weights. *Canadian Journal of Statistics*, 30:431–439, 2002. doi: 10.2307/3316146.