

Model-Model *Small Area Estimation* dalam Paket `fastsae` Formulasi Matematis, Penduga, dan Rujukan

Dokumen teknis disusun dari `codebase ridsonap/fastvae v0.1.0`

30 September 2026

Contents

1	Pendahuluan dan Notasi	3
2	Model Fay–Herriot: <code>eblup_fh</code>	3
2.1	Spesifikasi model	3
2.2	Pendugaan parameter	3
2.3	Prediktor EBLUP	4
2.4	Penduga MSE	4
2.5	Area tak tersampel	4
2.6	Pseudocode	5
3	Model Fay–Herriot Spasial: <code>eblup_sfh</code>	5
3.1	Spesifikasi model	5
3.2	Prediktor SEBLUP	5
3.3	Penduga MSE analitik	6
3.4	MSE bootstrap	6
3.5	Area tak tersampel: prediksi kriging spasial	6
3.6	Pseudocode	7
4	Model Fay–Herriot Spasio-Temporal: <code>eblup_stfh</code>	7
4.1	Spesifikasi model	7
4.2	Prediktor EBLUP	8
4.3	Pendugaan parameter dan MSE	8
4.4	Pseudocode	8
5	Model Battese–Harter–Fuller: <code>eblup_bhf</code>	8
5.1	Spesifikasi model	8
5.2	Pendugaan dan EBLUP	9
5.3	MSE bootstrap	9
5.4	Pseudocode	9
6	Model Bayes Hierarkis Area-Level: <code>hb_area</code>	9
6.1	Kerangka umum	9
6.2	Keluarga sebaran	10
6.3	Efek acak spasial	10
6.4	Efek temporal dan interaksi spasio-temporal	10
6.5	Pseudocode	11
7	Kalibrasi <i>Benchmarking</i>: <code>benchmark_sae</code>	11
7.1	Pseudocode	12

8	Metode Estimasi MSE dalam Paket	12
9	Penggunaan Kode <code>fastsae</code>	12
9.1	Model berbasis area	12
9.2	Model berbasis unit	13
9.3	Model Bayes hierarkis (INLA)	13
9.4	Kalibrasi, diagnostik, dan visualisasi	13
A	Riwayat Perbaikan Implementasi	13

1 Pendahuluan dan Notasi

Paket **fastsae** mengimplementasikan sejumlah model *small area estimation* (SAE) berbasis area dan berbasis unit dengan komputasi berkinerja tinggi (C++ melalui **RcppArmadillo**, paralelisasi OpenMP, serta *Integrated Nested Laplace Approximations*/INLA). Dokumen ini merangkum formulasi matematis setiap model yang diimplementasikan, cara pendugaan parameternya, prediktor yang dihasilkan, penduga *mean squared error* (MSE), dan rujukan pustaka yang mendasarinya.

Notasi yang dipakai konsisten di seluruh dokumen:

- $d = 1, \dots, D$: indeks area (domain); $t = 1, \dots, T$: indeks waktu.
- y_d : penduga langsung (*direct estimator*) bagi parameter area θ_d .
- $\psi_d > 0$: varians penarikan contoh (*sampling variance*) dari y_d , dianggap diketahui.
- $\mathbf{x}_d \in \mathbb{R}^p$: vektor peubah bantu (termasuk intersep) bagi area d ; $\mathbf{X}$: matriks desain $D \times p$; $\boldsymbol{\beta} \in \mathbb{R}^p$: vektor koefisien tetap.
- u_d : pengaruh acak (*random effect*) area; e_d : galat penarikan contoh.
- $\mathbf{W}$: matriks bobot spasial $D \times D$ yang dibakukan per baris (*row-standardized*), $0 \leq w_{ij} \leq 1$, $w_{ii} = 0$.

Fungsi-fungsi pemodelan utama dalam paket ini diringkas pada Tabel 1.

Table 1: Fungsi pemodelan utama paket **fastsae**.

Fungsi	Level	Model
eblup_fh	Area	Fay–Herriot (1979), EBLUP
eblup_sfh	Area	Fay–Herriot spasial, SAR(1) pada pengaruh acak
eblup_stfh	Area	Fay–Herriot spasio-temporal (model “S” dan “ST”)
eblup_bhfh	Unit	Battese–Harter–Fuller (1988), EBLUP
hb_area	Area	Bayes hierarkis GLMM via INLA (6 keluarga sebaran)
benchmark_sae	—	Kalibrasi <i>benchmarking</i> (4 metode)

2 Model Fay–Herriot: eblup_fh

2.1 Spesifikasi model

Model Fay–Herriot [1] terdiri dari dua tingkat:

$$\text{Model penarikan contoh:} \quad y_d = \theta_d + e_d, \quad e_d \stackrel{\text{ind}}{\sim} N(0, \psi_d), \quad (1a)$$

$$\text{Model penghubung:} \quad \theta_d = \mathbf{x}_d^\top \boldsymbol{\beta} + u_d, \quad u_d \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2), \quad (1b)$$

dengan $\{e_d\}$ dan $\{u_d\}$ saling bebas. Bentuk gabungannya adalah model linear campuran

$$y_d = \mathbf{x}_d^\top \boldsymbol{\beta} + u_d + e_d, \quad \mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \mathbf{V}), \quad \mathbf{V} = \text{diag}(\sigma_u^2 + \psi_d). \quad (2)$$

Varians penarikan contoh ψ_d dianggap diketahui (diestimasi terlebih dahulu dari data survei, misalnya melalui linearisasi Taylor atau replikasi).

2.2 Pendugaan parameter

Parameter $(\boldsymbol{\beta}, \sigma_u^2)$ diduga dengan kemungkinan maksimum (ML) atau kemungkinan maksimum terkendala (REML) melalui algoritma *Fisher-scoring*. Untuk REML, fungsi skor dan informasi Fisher bagi σ_u^2 adalah

$$s(\sigma_u^2) = -\frac{1}{2} \text{tr}(\mathbf{P}) + \frac{1}{2} \mathbf{y}^\top \mathbf{P}^2 \mathbf{y}, \quad \mathcal{I}(\sigma_u^2) = \frac{1}{2} \text{tr}(\mathbf{P}^2), \quad (3)$$

dengan $\mathbf{P} = \mathbf{V}^{-1} - \mathbf{V}^{-1}\mathbf{X}(\mathbf{X}^\top\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{V}^{-1}$, dan iterasi $\sigma_{u,(k+1)}^2 = \sigma_{u,(k)}^2 + s/\mathcal{I}$ (varian ML memakai $\mathbf{V}^{-1}$ sebagai pengganti $\mathbf{P}$). Nilai awal $\sigma_{u,(0)}^2 = \text{median}(\psi_d)$; iterasi berhenti jika perubahan relatif $< 10^{-4}$ atau mencapai 100 iterasi.

2.3 Prediktor EBLUP

Untuk σ_u^2 diketahui, *best linear unbiased predictor* (BLUP) bagi θ_d adalah

$$\tilde{\theta}_d = \mathbf{x}_d^\top \tilde{\boldsymbol{\beta}} + \gamma_d (y_d - \mathbf{x}_d^\top \tilde{\boldsymbol{\beta}}), \quad \gamma_d = \frac{\sigma_u^2}{\sigma_u^2 + \psi_d}, \quad (4)$$

dengan $\tilde{\boldsymbol{\beta}} = (\sum_d \mathbf{x}_d \mathbf{x}_d^\top / (\sigma_u^2 + \psi_d))^{-1} \sum_d \mathbf{x}_d y_d / (\sigma_u^2 + \psi_d)$ penduga GLS dan $\gamma_d \in [0, 1]$ faktor penyusutan (*shrinkage*): semakin kecil ψ_d relatif terhadap σ_u^2 , semakin besar bobot pada penduga langsung y_d . Mengganti σ_u^2 dengan $\hat{\sigma}_u^2$ menghasilkan EBLUP $\hat{\theta}_d^{\text{EBLUP}}$ [17].

2.4 Penduga MSE

MSE dari EBLUP diduga dengan aproksimasi Prasad–Rao [3]:

$$\text{mse}(\hat{\theta}_d^{\text{EBLUP}}) \approx g_{1d} + g_{2d} + 2g_{3d}, \quad (5)$$

dengan

$$g_{1d} = \gamma_d \psi_d, \quad (6)$$

$$g_{2d} = (1 - \gamma_d)^2 \mathbf{x}_d^\top \left(\sum_j \frac{\mathbf{x}_j \mathbf{x}_j^\top}{\hat{\sigma}_u^2 + \psi_j} \right)^{-1} \mathbf{x}_d, \quad (7)$$

$$g_{3d} = \frac{\psi_d^2}{(\hat{\sigma}_u^2 + \psi_d)^3} \overline{\text{Var}}(\hat{\sigma}_u^2), \quad \overline{\text{Var}}(\hat{\sigma}_u^2) = \frac{2}{\sum_j (\hat{\sigma}_u^2 + \psi_j)^{-2}}. \quad (8)$$

Suku g_{1d} adalah ketidakpastian prediksi jika $\boldsymbol{\beta}$ dan σ_u^2 diketahui; g_{2d} berasal dari pendugaan $\boldsymbol{\beta}$; g_{3d} berasal dari pendugaan σ_u^2 . Untuk penduga ML ditambahkan koreksi bias orde-dua $-b(\hat{\sigma}_u^2) \nabla g_{1d}$ menurut Datta dan Lahiri [5], sebagaimana diimplementasikan dalam kode.

2.5 Area tak tersampel

Area dengan y_d hilang (NA) diperlakukan sebagai tak tersampel dan diprediksi dengan penduga sintetis $\hat{\theta}_d = \mathbf{x}_d^\top \hat{\boldsymbol{\beta}}$ dengan $\text{mse}(\hat{\theta}_d) = \hat{\sigma}_u^2 + \mathbf{x}_d^\top (\mathbf{X}^\top \hat{\mathbf{V}}^{-1} \mathbf{X})^{-1} \mathbf{x}_d$.

2.6 Pseudocode

Algoritma 1 eblup_fh: EBLUP Fay–Herriot via *Fisher-scoring*

Require: $\mathbf{y}, \mathbf{X}, \boldsymbol{\psi}$; method $\in \{\text{REML}, \text{ML}\}$; maxiter = 100; precision = 10^{-4}

Ensure: $\hat{\boldsymbol{\theta}}^{\text{EBLUP}}$, mse, $\hat{\boldsymbol{\beta}}$, $\hat{\sigma}_u^2$, penanda konvergensi

```

1:  $\sigma^2 \leftarrow \text{median}(\boldsymbol{\psi})$ ;  $k \leftarrow 0$ ;  $\text{diff} \leftarrow \text{precision} + 1$ 
2: while  $\text{diff} > \text{precision}$  dan  $k < \text{maxiter}$  do
3:    $V_i \leftarrow 1/(\psi_i + \sigma^2)$  untuk semua  $i$  ▷  $\mathbf{V} = \text{diag}(\sigma^2 + \boldsymbol{\psi})$ 
4:   Bentuk  $\mathbf{P} = \mathbf{V}^{-1} - \mathbf{V}^{-1}\mathbf{X}(\mathbf{X}^\top \mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}^\top \mathbf{V}^{-1}$  (REML) atau pakai  $\mathbf{V}^{-1}$  (ML)
5:    $s \leftarrow -\frac{1}{2} \text{tr}(\mathbf{P}) + \frac{1}{2} \mathbf{y}^\top \mathbf{P}^2 \mathbf{y}$  ▷ skor
6:    $\mathcal{I} \leftarrow \frac{1}{2} \text{tr}(\mathbf{P}^2)$  ▷ informasi Fisher
7:    $\sigma_{\text{baru}}^2 \leftarrow \max(\sigma^2 + s/\mathcal{I}, 0)$ 
8:    $\text{diff} \leftarrow |\sigma_{\text{baru}}^2 - \sigma^2|$ ;  $\sigma^2 \leftarrow \sigma_{\text{baru}}^2$ ;  $k \leftarrow k + 1$ 
9: end while
10: konvergen  $\leftarrow (\text{diff} \leq \text{precision})$ ;  $\hat{\sigma}_u^2 \leftarrow \sigma^2$ 
11:  $\hat{\boldsymbol{\beta}} \leftarrow (\mathbf{X}^\top \hat{\mathbf{V}}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \hat{\mathbf{V}}^{-1} \mathbf{y}$  ▷ GLS
12: for  $d = 1, \dots, D$  do
13:    $\gamma_d \leftarrow \hat{\sigma}_u^2 / (\hat{\sigma}_u^2 + \psi_d)$ 
14:   if  $y_d$  tersedia then
15:      $\hat{\theta}_d \leftarrow \mathbf{x}_d^\top \hat{\boldsymbol{\beta}} + \gamma_d (y_d - \mathbf{x}_d^\top \hat{\boldsymbol{\beta}})$ 
16:     mse $d$   $\leftarrow g_{1d} + g_{2d} + 2g_{3d}$  (+ koreksi bias Datta–Lahiri bila ML)
17:   else
18:      $\hat{\theta}_d \leftarrow \mathbf{x}_d^\top \hat{\boldsymbol{\beta}}$  ▷ sintetik
19:     mse $d$   $\leftarrow \hat{\sigma}_u^2 + \mathbf{x}_d^\top (\mathbf{X}^\top \hat{\mathbf{V}}^{-1} \mathbf{X})^{-1} \mathbf{x}_d$ 
20:   end if
21: end for
22: return  $\hat{\boldsymbol{\theta}}, \text{mse}, \hat{\boldsymbol{\beta}}, \hat{\sigma}_u^2, \text{konvergen}$ 

```

3 Model Fay–Herriot Spasial: eblup_sfh

3.1 Spesifikasi model

Model Fay–Herriot spasial [10] menambahkan autokorelasi spasial pada pengaruh acak melalui proses simultan-autoregresif SAR(1):

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u} + \mathbf{e}, \quad (9a)$$

$$\mathbf{u} = \rho \mathbf{W}\mathbf{u} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma_u^2 \mathbf{I}_D), \quad (9b)$$

$$\mathbf{e} \sim N(\mathbf{0}, \boldsymbol{\Psi}), \quad \boldsymbol{\Psi} = \text{diag}(\boldsymbol{\psi}_d), \quad (9c)$$

sehingga $\mathbf{u} \sim N(\mathbf{0}, \mathbf{G})$ dengan

$$\mathbf{G} = \sigma_u^2 \boldsymbol{\Omega}(\rho), \quad \boldsymbol{\Omega}(\rho) = [(\mathbf{I}_D - \rho \mathbf{W})^\top (\mathbf{I}_D - \rho \mathbf{W})]^{-1}, \quad (10)$$

dan $\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \mathbf{V})$ dengan $\mathbf{V} = \mathbf{G} + \boldsymbol{\Psi}$. Parameter spasial $\rho \in (-1, 1)$ mengukur kekuatan ketergantungan antar-area bertetangga; $\rho = 0$ mengembalikan model Fay–Herriot biasa.

3.2 Prediktor SEBLUP

Spatial EBLUP (SEBLUP) didefinisikan sebagai

$$\hat{\boldsymbol{\theta}}^{\text{SEBLUP}} = \mathbf{X}\hat{\boldsymbol{\beta}} + \hat{\mathbf{G}}\hat{\mathbf{V}}^{-1}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}), \quad (11)$$

dengan $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \hat{\mathbf{V}}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \hat{\mathbf{V}}^{-1} \mathbf{y}$ dan $(\hat{\sigma}_u^2, \hat{\rho})$ diduga via ML/REML dengan *Fisher-scoring* dua parameter (skor dan informasi harapan dihitung dari turunan $\partial \mathbf{V} / \partial \sigma_u^2$ dan $\partial \mathbf{V} / \partial \rho$; ρ dibatasi pada $(-0,999; 0,999)$).

3.3 Penduga MSE analitik

MSE analitik memakai dekomposisi Singh, Shukla, dan Kundu [9]:

$$\text{mse}(\hat{\theta}_d^{\text{SEBLUP}}) \approx g_{1d} + g_{2d} + 2g_{3d} - g_{4d}, \quad (12)$$

dengan, untuk $\mathbf{b}_d^\top$ baris ke- d dari $\mathbf{G}\mathbf{V}^{-1}$,

$$g_{1d} = [\mathbf{G} - \mathbf{G}\mathbf{V}^{-1}\mathbf{G}]_{dd}, \quad (13)$$

$$g_{2d} = (\mathbf{x}_d - \mathbf{b}_d^\top \mathbf{X})(\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1}(\mathbf{x}_d - \mathbf{b}_d^\top \mathbf{X})^\top, \quad (14)$$

$$g_{3d} = \text{tr} \left\{ [\nabla \mathbf{b}_d] \mathbf{V} [\nabla \mathbf{b}_d]^\top \bar{\mathcal{I}}^{-1} \right\}, \quad (15)$$

di mana $\nabla \mathbf{b}_d$ adalah gradien $\mathbf{b}_d$ terhadap (σ_u^2, ρ) dan $\bar{\mathcal{I}}$ matriks informasi harapan. Suku g_{4d} adalah koreksi orde-dua yang melibatkan turunan kedua matriks kovarians spasial $\mathbf{G}$ terhadap (σ_u^2, ρ) , diboboti oleh invers matriks informasi; ia mengoreksi bias akibat pendugaan ρ . Untuk ML ditambahkan koreksi bias $-\mathbf{b}_{\text{ML}}^\top \nabla g_{1d}$ [5]. Semua komponen dievaluasi pada $(\hat{\sigma}_u^2, \hat{\rho})$.

3.4 MSE bootstrap

Selain analitik, tersedia `mse_method = "pbmse"` (*parametric bootstrap* MSE) dan `"npbmse"` (*non-parametric bootstrap* MSE):

- **PB-MSE** [11]: bangkitkan B populasi bootstrap dari model terpasang $N(\mathbf{X}\hat{\boldsymbol{\beta}}, \hat{\mathbf{V}})$, hitung SEBLUP tiap replikasi, lalu $\text{mse}_{\text{PB},d} = B^{-1} \sum_b (\hat{\theta}_d^{*(b)} - \theta_d^{*(b)})^2$, beserta versi koreksi-biasnya.
- **NPB-MSE**: residual $(y_d - \mathbf{x}_d^\top \hat{\boldsymbol{\beta}})$ diambil-ulang (*resampling*) secara non-parametrik untuk membangun populasi bootstrap tanpa asumsi normalitas penuh.

Komputasi bootstrap diparalelkan dengan OpenMP.

3.5 Area tak tersampel: prediksi kriging spasial

Area tak tersampel diprediksi dengan kriging memakai seluruh matriks $\mathbf{W}$ (termasuk baris/kolom area tak tersampel):

$$\hat{\theta}_d = \mathbf{x}_d^\top \hat{\boldsymbol{\beta}} + \mathbf{G}_{rs} \mathbf{V}_{ss}^{-1} (\mathbf{y}_s - \mathbf{X}_s \hat{\boldsymbol{\beta}}), \quad (16)$$

dengan MSE analitik $g_{1d} + g_{2d}$ yang bersesuaian (r = tak tersampel, s = tersampel). MSE bootstrap hanya terdefinisi bagi area tersampel.

3.6 Pseudocode

Algoritma 2 eblup_sfh: SEBLUP spasial via *Fisher-scoring* dua parameter

Require: $\mathbf{y}, \mathbf{X}, \psi$; $\mathbf{W}$ row-standardized; $\text{method} \in \{\text{REML}, \text{ML}\}$; $\text{mse_method} \in \{\text{analytical}, \text{pbmse}, \text{npbmse}\}$; B ; n_threads

Ensure: $\hat{\boldsymbol{\theta}}^{\text{SEBLUP}}$, mse , $\hat{\sigma}_u^2$, $\hat{\rho}$

```

1: Inisialisasi  $(\sigma_u^2, \rho)$ ;  $k \leftarrow 0$ 
2: while belum konvergen dan  $k < \text{maxiter}$  do
3:    $\boldsymbol{\Omega}(\rho) \leftarrow [(\mathbf{I} - \rho \mathbf{W})^\top (\mathbf{I} - \rho \mathbf{W})]^{-1}$ 
4:    $\mathbf{G} \leftarrow \sigma_u^2 \boldsymbol{\Omega}(\rho)$ ;  $\mathbf{V} \leftarrow \mathbf{G} + \text{diag}(\psi)$ 
5:   Hitung skor  $\mathbf{s}$  dan informasi Fisher  $\mathcal{I}$  dari  $\partial \mathbf{V} / \partial \sigma_u^2$  dan  $\partial \mathbf{V} / \partial \rho$ 
6:    $(\sigma_u^2, \rho) \leftarrow (\sigma_u^2, \rho) + \mathcal{I}^{-1} \mathbf{s}$ ;  $\rho \leftarrow \text{clip}(\rho, -0,999, 0,999)$ 
7:    $k \leftarrow k + 1$ 
8: end while
9:  $\hat{\boldsymbol{\beta}} \leftarrow (\mathbf{X}^\top \hat{\mathbf{V}}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \hat{\mathbf{V}}^{-1} \mathbf{y}$ 
10:  $\hat{\boldsymbol{\theta}} \leftarrow \mathbf{X} \hat{\boldsymbol{\beta}} + \hat{\mathbf{G}} \hat{\mathbf{V}}^{-1} (\mathbf{y} - \mathbf{X} \hat{\boldsymbol{\beta}})$  ▷ SEBLUP, (11)
11: if  $\text{mse\_method} = \text{analytical}$  then
12:    $\text{mse}_d \leftarrow g_{1d} + g_{2d} + 2g_{3d} - g_{4d}$  (+ koreksi bias bila ML)
13: else if  $\text{mse\_method} = \text{pbmse}$  then
14:   for  $b = 1, \dots, B$  do ▷ paralel OpenMP
15:     Bangkitkan  $\mathbf{y}^{*(b)} \sim N(\mathbf{X} \hat{\boldsymbol{\beta}}, \hat{\mathbf{V}})$  dan  $\boldsymbol{\theta}^{*(b)}$ 
16:     Pasang ulang SEBLUP  $\rightarrow \hat{\boldsymbol{\theta}}^{*(b)}$ 
17:     Akumulasi  $(\hat{\boldsymbol{\theta}}_d^{*(b)} - \boldsymbol{\theta}_d^{*(b)})^2$ 
18:   end for
19:    $\text{mse}_d \leftarrow B^{-1} \sum_b (\hat{\boldsymbol{\theta}}_d^{*(b)} - \boldsymbol{\theta}_d^{*(b)})^2$  (dengan opsi koreksi bias)
20: else ▷ npbmse
21:   Bangun populasi bootstrap via resampling residual  $\mathbf{y} - \mathbf{X} \hat{\boldsymbol{\beta}}$ , lalu seperti PB
22: end if
23: Area tak tersampel: kriging  $\hat{\boldsymbol{\theta}}_d = \mathbf{x}_d^\top \hat{\boldsymbol{\beta}} + \mathbf{G}_{rs} \mathbf{V}_{ss}^{-1} (\mathbf{y}_s - \mathbf{X}_s \hat{\boldsymbol{\beta}})$ 
24: return  $\hat{\boldsymbol{\theta}}, \text{mse}, \hat{\sigma}_u^2, \hat{\rho}$ 

```

4 Model Fay–Herriot Spasio-Temporal: eblup_stfh

4.1 Spesifikasi model

Model spasio-temporal Fay–Herriot [14] untuk panel seimbang (D area $\times T$ waktu, data diurut per area) adalah

$$y_{dt} = \mathbf{x}_{dt}^\top \boldsymbol{\beta} + u_{1d} + u_{2dt} + e_{dt}, \quad d = 1, \dots, D, \quad t = 1, \dots, T, \quad (17)$$

dengan tiga komponen galat yang saling bebas:

- u_{1d} : pengaruh acak area yang *tidak berubah terhadap waktu*, mengikuti SAR(1) spasial seperti pada (10): $\mathbf{u}_1 \sim N(\mathbf{0}, \sigma_1^2 \boldsymbol{\Omega}_1(\rho_1))$.
- u_{2dt} : pengaruh acak area-waktu, dengan dua varian model:

Model “S” (spasial saja): $u_{2dt} \stackrel{\text{iid}}{\sim} N(0, \sigma_2^2)$.

Model “ST” (spasio-temporal): $\mathbf{u}_{2d} = (u_{2d1}, \dots, u_{2dT})^\top \sim N(\mathbf{0}, \sigma_2^2 \boldsymbol{\Omega}_2(\rho_2))$ bebas antar d , dengan korelasi AR(1) stasioner

$$[\boldsymbol{\Omega}_2(\rho_2)]_{ts} = \frac{\rho_2^{|t-s|}}{1 - \rho_2^2}, \quad |\rho_2| < 1. \quad (18)$$

- $e_{dt} \stackrel{\text{ind}}{\sim} N(0, \psi_{dt})$: galat penarikan contoh dengan varians diketahui.

Matriks kovarians $\mathbf{V}$ berukuran $DT \times DT$ dibangun per blok domain dengan identitas Woodbury agar inversi efisien.

4.2 Prediktor EBLUP

Dengan $\hat{\boldsymbol{\theta}} = (\hat{\sigma}_1^2, \hat{\rho}_1, \hat{\sigma}_2^2, \hat{\rho}_2)$ hasil pendugaan,

$$\hat{\boldsymbol{\theta}}_{dt}^{\text{EBLUP}} = \mathbf{x}_{dt}^\top \hat{\boldsymbol{\beta}} + \hat{u}_{1d} + \hat{u}_{2dt}, \quad (19)$$

dengan $\hat{\mathbf{u}}_1 = \hat{\sigma}_1^2 \boldsymbol{\Omega}_1 \mathbf{Z}_1^\top \hat{\mathbf{V}}^{-1}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$ dan $\hat{\mathbf{u}}_2 = \hat{\sigma}_2^2 \boldsymbol{\Omega}_2^\oplus \hat{\mathbf{V}}^{-1}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$ ($\boldsymbol{\Omega}_2^\oplus$: blok-diagonal per domain; untuk model ‘‘S’’, $\boldsymbol{\Omega}_2 = \mathbf{I}_T$).

4.3 Pendugaan parameter dan MSE

Parameter varians diduga dengan *Fisher-scoring* gaya-REML atas $(\sigma_1^2, \rho_1, \sigma_2^2, \rho_2)$. MSE diestimasi dengan *parametric bootstrap* (PB-MSE, `compute_mse` = TRUE): populasi bootstrap dibangkitkan dari model terpasang dengan $\mathbf{u}_1^* \sim N(\mathbf{0}, \hat{\sigma}_1^2 \boldsymbol{\Omega}_1(\hat{\rho}_1))$, $\mathbf{u}_{2d}^* \sim N(\mathbf{0}, \hat{\sigma}_2^2 \boldsymbol{\Omega}_2(\hat{\rho}_2))$, dan $\mathbf{e}^* \sim N(\mathbf{0}, \text{diag}(\psi_{dt}))$, lalu MSE dihitung dari B replikasi EBLUP. Versi ini mensyaratkan panel lengkap (tanpa NA pada respons).

4.4 Pseudocode

Algoritma 3 `eblup_stfh`: EBLUP spasio-temporal + PB-MSE

Require: Panel seimbang $y_{dt}, \mathbf{x}_{dt}, \psi_{dt}$ (D area $\times T$ waktu, diurut per area); $\mathbf{W}$; `model` $\in \{\text{S}, \text{ST}\}$; `compute_mse`; B ; `n_threads`

Ensure: $\hat{\boldsymbol{\theta}}_{dt}^{\text{EBLUP}}$, mse (bila diminta), $(\hat{\sigma}_1^2, \hat{\rho}_1, \hat{\sigma}_2^2, \hat{\rho}_2)$

- 1: Susun $\mathbf{y}, \mathbf{X}$; bangun $\boldsymbol{\Omega}_1(\rho_1)$ (spasial SAR) dan $\boldsymbol{\Omega}_2(\rho_2)$ (AR(1) temporal, model ST) atau $\mathbf{I}_T$ (model S)
 - 2: Bentuk $\mathbf{V}$ ($DT \times DT$) per blok domain dengan identitas Woodbury
 - 3: *Fisher-scoring* gaya-REML atas $(\sigma_1^2, \rho_1, \sigma_2^2, \rho_2)$ hingga $|\Delta| \leq \text{precision}$ atau `maxiter`
 - 4: $\hat{\boldsymbol{\beta}} \leftarrow \text{GLS}$; $\hat{\mathbf{u}}_1 \leftarrow \hat{\sigma}_1^2 \boldsymbol{\Omega}_1 \mathbf{Z}_1^\top \hat{\mathbf{V}}^{-1}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$; $\hat{\mathbf{u}}_2 \leftarrow \hat{\sigma}_2^2 \boldsymbol{\Omega}_2^\oplus \hat{\mathbf{V}}^{-1}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$
 - 5: $\hat{\boldsymbol{\theta}}_{dt} \leftarrow \mathbf{x}_{dt}^\top \hat{\boldsymbol{\beta}} + \hat{u}_{1d} + \hat{u}_{2dt}$
 - 6: **if** `compute_mse` = TRUE **then**
 - 7: **for** $b = 1, \dots, B$ **do** ▷ paralel OpenMP
 - 8: $\mathbf{u}_1^{*(b)} \sim N(\mathbf{0}, \hat{\sigma}_1^2 \boldsymbol{\Omega}_1(\hat{\rho}_1))$; $\mathbf{u}_{2d}^{*(b)} \sim N(\mathbf{0}, \hat{\sigma}_2^2 \boldsymbol{\Omega}_2(\hat{\rho}_2))$ independen per domain; $\mathbf{e}^{*(b)} \sim N(\mathbf{0}, \text{diag}(\psi_{dt}))$
 - 9: $\mathbf{y}^{*(b)} \leftarrow \mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{u}_1^{*(b)} + \mathbf{u}_2^{*(b)} + \mathbf{e}^{*(b)}$; $\boldsymbol{\theta}^{*(b)} \leftarrow \mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{u}_1^{*(b)} + \mathbf{u}_2^{*(b)}$
 - 10: Pasang ulang EBLUP $\rightarrow \hat{\boldsymbol{\theta}}^{*(b)}$
 - 11: Akumulasi $(\hat{\boldsymbol{\theta}}_{dt}^{*(b)} - \boldsymbol{\theta}_{dt}^{*(b)})^2$
 - 12: **end for**
 - 13: $\text{mse}_{dt} \leftarrow B^{-1} \sum_b (\hat{\boldsymbol{\theta}}_{dt}^{*(b)} - \boldsymbol{\theta}_{dt}^{*(b)})^2$
 - 14: **end if**
 - 15: **return** $\hat{\boldsymbol{\theta}}, \text{mse}$ (opsional), parameter varians
-

5 Model Battese–Harter–Fuller: `eblup_bhf`

5.1 Spesifikasi model

Model berbasis unit [2] untuk unit j dalam area d :

$$y_{dj} = \mathbf{x}_{dj}^\top \boldsymbol{\beta} + u_d + e_{dj}, \quad u_d \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2), \quad e_{dj} \stackrel{\text{iid}}{\sim} N(0, \sigma_e^2), \quad (20)$$

dengan $d = 1, \dots, D$, $j = 1, \dots, n_d$. Berbeda dari model berbasis area, model ini memakai data unit hasil survei (n_d unit per area) dan informasi peubah bantu pada level populasi $(\bar{\mathbf{X}}_d, N_d)$.

5.2 Pendugaan dan EBLUP

Komponen varians (σ_u^2, σ_e^2) dan β diduga dengan model linear campuran via **lme4** (REML baku, atau ML). Prediktor EBLUP bagi rata-rata area $\bar{Y}_d$ adalah

$$\hat{Y}_d^{\text{EBLUP}} = f_d \bar{y}_{ds} + (\bar{\mathbf{X}}_d - f_d \bar{\mathbf{x}}_{ds})^\top \hat{\beta} + (1 - f_d) \hat{u}_d, \quad (21)$$

dengan $f_d = n_d/N_d$ fraksi penarikan contoh, $\bar{y}_{ds}$ dan $\bar{\mathbf{x}}_{ds}$ rata-rata contoh, $\bar{\mathbf{X}}_d$ rata-rata populasi, dan $\hat{u}_d$ BLUP pengaruh acak area. Area tanpa unit contoh diprediksi secara sintetis: $\hat{Y}_d = \bar{\mathbf{X}}_d^\top \hat{\beta}$.

5.3 MSE bootstrap

Dengan `compute_mse = TRUE`, MSE diestimasi secara *parametric bootstrap*: populasi unit artifisial dibangkitkan dari (20) dengan parameter terpasang, contoh bootstrap diambil, EBLUP dihitung ulang, dan $\text{MSE} = \text{rata-rata kuadrat galat terhadap nilai populasi bootstrap selama } B \text{ replikasi}$.

5.4 Pseudocode

Algoritma 4 `eblop_bhf`: EBLUP Battese–Harter–Fuller berbasis unit

Require: `unit_data` ($y_{dj}, \mathbf{x}_{dj}$); `Xpop` (rata-rata populasi $\bar{\mathbf{X}}_d$); `domain_var`; `popsizes_var` (N_d); `method` $\in \{\text{REML}, \text{ML}\}$; `compute_mse`; B

Ensure: $\hat{Y}_d^{\text{EBLUP}}$, `mse` (bila diminta)

```

1: Pasang model linear campuran (20) via lme4  $\rightarrow \hat{\sigma}_u^2, \hat{\sigma}_e^2, \hat{\beta}$ 
2: for  $d = 1, \dots, D$  do
3:    $f_d \leftarrow n_d/N_d$  ▷ fraksi penarikan contoh
4:    $\hat{u}_d \leftarrow$  BLUP pengaruh acak area
5:   if  $n_d > 0$  then
6:      $\hat{Y}_d \leftarrow f_d \bar{y}_{ds} + (\bar{\mathbf{X}}_d - f_d \bar{\mathbf{x}}_{ds})^\top \hat{\beta} + (1 - f_d) \hat{u}_d$  ▷ (21)
7:   else
8:      $\hat{Y}_d \leftarrow \bar{\mathbf{X}}_d^\top \hat{\beta}$  ▷ sintetis
9:   end if
10: end for
11: if compute_mse = TRUE then
12:   for  $b = 1, \dots, B$  do ▷ paralel OpenMP
13:     Bangkitkan populasi unit artifisial  $y_{dj}^{*(b)} = \mathbf{x}_{dj}^\top \hat{\beta} + u_d^{*(b)} + e_{dj}^{*(b)}$  memakai parameter terpasang
14:     Ambil contoh bootstrap; pasang ulang (20)  $\rightarrow \hat{Y}_d^{*(b)}$ 
15:     Akumulasi  $(\hat{Y}_d^{*(b)} - \bar{Y}_d^{*(b)})^2$ 
16:   end for
17:    $\text{mse}_d \leftarrow B^{-1} \sum_b (\hat{Y}_d^{*(b)} - \bar{Y}_d^{*(b)})^2$ 
18: end if
19: return  $\hat{\mathbf{Y}}$ , mse (opsional)
```

6 Model Bayes Hierarkis Area-Level: `hb_area`

6.1 Kerangka umum

`hb_area` memodelkan respons area y_d melalui GLMM hierarkis

$$y_d \mid \mu_d \sim \mathcal{F}(\mu_d, \phi), \quad g(\mu_d) = \eta_d = \mathbf{x}_d^\top \beta + u_d + v_d + \gamma_t + \delta_{dt}, \quad (22)$$

dengan $g(\cdot)$ fungsi hubung, u_d pengaruh acak area tak terstruktur, v_d pengaruh acak spasial, γ_t pengaruh acak temporal, dan δ_{dt} interaksi spasio-temporal. Inferensi dilakukan dengan *Integrated Nested Laplace Approximations* (INLA) [12] memakai strategi `laplace` penuh; alternatifnya, GLMM binomial/Poisson dapat dipasang secara frekuentis dengan aproksimasi Laplace via `lme4`.

6.2 Keluarga sebaran

Table 2: Keluarga sebaran pada `hb_area` beserta fungsi hubung baku.

family	Sebaran	Hubung baku
<code>gaussian</code>	Normal (model Fay–Herriot; ψ_d diketahui bila <code>vardir</code> diisi)	identitas
<code>binomial</code>	Binomial(n_d, p_d); perlu <code>trials</code> = n_d	logit
<code>poisson</code>	Poisson(μ_d); mendukung <code>exposure</code> E_d	log
<code>nbinomial</code>	Binomial negatif (untuk <i>overdispersion</i>)	log
<code>beta</code>	Beta(μ_d, ϕ_d) untuk proporsi (0, 1)	logit
<code>gamma</code>	Gamma untuk respons positif menceng	log

Untuk `family` = "`beta`", presisi ϕ_d dihitung dari inversi varians distribusi beta,

$$\phi_d = \frac{y_d(1 - y_d)}{\psi_d} - 1, \quad (23)$$

(disebut dalam dokumentasi paket sebagai formula Janicki, 2020) dan disuntikkan melalui argumen `scale` pada INLA; bila `trials` diisi, presisi diskalakan sebesar $n_d - 1$.

6.3 Efek acak spasial

"none": hanya $u_d \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2)$.

"bym": Besag–York–Mollié klasik [4], $u_d + v_d$ dengan v_d ICAR dan u_d iid.

"bym2": BYM2 terskala [18],

$$\eta_d^{(\text{spasial})} = \sigma \left(\sqrt{1 - \phi} v_d + \sqrt{\phi} s_d^* \right), \quad (24)$$

dengan s_d^* efek terstruktur yang diskalakan sehingga varians marginalnya ≈ 1 ; $\phi \in [0, 1]$ proporsi varians yang bersifat spasial.

"besag": ICAR murni (intrinsik), $v_d \mid \mathbf{v}_{-d} \sim N(\bar{v}_{\delta d}, \tau^{-1}/m_d)$.

"generic1": model autoregresif Leroux [7], $\mathbf{v} \sim N(\mathbf{0}, \tau^{-1}[(1 - \lambda)\mathbf{I} + \lambda\mathbf{R}]^{-1})$.

"slm": model *spatial lag* SAR pada medan laten (`f(..., model="slm")` pada INLA), $\mathbf{v} = \rho\mathbf{W}\mathbf{v} + \boldsymbol{\varepsilon}$.

Prior baku memakai *penalized complexity* (PC): PC(1, 0,01) untuk presisi dan PC(0,5; 0,5) untuk ϕ pada BYM2.

6.4 Efek temporal dan interaksi spasio-temporal

Efek temporal γ_t : "`rw1`" (*random walk* orde-1), "`rw2`" (orde-2), "`ar1`" (autoregresif orde-1), atau "`iid`". Interaksi δ_{dt} mengikuti klasifikasi Knorr-Held [6]: tipe I (tak terstruktur $\times$ tak terstruktur), II (tak terstruktur $\times$ terstruktur), III (terstruktur $\times$ tak terstruktur), IV (terstruktur $\times$ terstruktur); serta varian "`domain-specific`" (dinamika temporal per domain, seperti model spasio-temporal `tipsae` [19]) dan "`separable`" (medan spasial dinamis AR(1)/RW, analog model Marhuenda dkk.).

6.5 Pseudocode

Algoritma 5 hb_area: GLMM hierarkis area-level via INLA

Require: formula, data; family (6 pilihan); spatial, temporal, st_interaction; **W**; vardir / trials / exposure sesuai keluarga sebaran

Ensure: Ringkasan posterior per area(-waktu): mean, SD, kuantil, interval kredibel

- 1: Periksa paket INLA tersedia; bila method = "laplace", pasang GLMM frekuentis via lme4 dan selesai
 - 2: Petakan family → sebaran INLA + fungsi hubung baku (Tabel 2)
 - 3: Bangun formula INLA: $y \sim x + f(\text{domain}, \text{model}=\langle \text{spatial} \rangle) + f(\text{time}, \text{model}=\langle \text{temporal} \rangle)$
 - 4: $+ f(\text{domain.time}, \text{model}=\langle \text{st_interaction} \rangle)$ sesuai Tabel efek acak; untuk "bym2" aktifkan scale.model = TRUE
 - 5: Tetapkan prior PC: presisi $\sim \text{PC}(1, 0, 01)$, $\phi_{\text{bym2}} \sim \text{PC}(0, 5; 0, 5)$
 - 6: **if** family = "beta" **then**
 - 7: Hitung presisi $\phi_d = y_d(1 - y_d)/\psi_d - 1$; teruskan via scale
 - 8: **end if**
 - 9: fit $\leftarrow \text{INLA::inla}(\text{formula}, \text{family}, \text{data}, \text{control.inla} = \text{list}(\text{strategy} = \langle \text{strategy} \rangle),$
 - 10: control.compute = list(dic, waic, cpo, pit))
 - 11: Ekstrak marginal posterior $\theta_d | \mathbf{y} \rightarrow$ mean, SD, kuantil 2,5%/97,5% (interval kredibel)
 - 12: Hitung diagnostik: PIT, CPO, DIC, WAIC
 - 13: **return** tabel ringkasan posterior + diagnostik model
-

7 Kalibrasi *Benchmarking*: benchmark_sae

Benchmarking mengkalibrasi penduga area $\hat{\theta}_d$ agar agregatnya konsisten dengan target tepercaya pada tingkat agregasi yang lebih tinggi (misalnya total provinsi/nasional) [17]:

$$\sum_{d \in g} w_d \hat{\theta}_d^{\text{BM}} = T_g, \quad (25)$$

dengan w_d bobot (misalnya ukuran populasi N_d) dan T_g target kalibrasi grup g . Empat metode diimplementasikan:

"ratio": penyesuaian proporsional $\hat{\theta}_d^{\text{BM}} = \hat{\theta}_d \cdot T_g / \sum_{j \in g} w_j \hat{\theta}_j$ [8]; mempertahankan non-negativitas.

"difference": penyesuaian aditif seragam $\hat{\theta}_d^{\text{BM}} = \hat{\theta}_d + (T_g - \sum_j w_j \hat{\theta}_j) / \sum_j w_j$ [17].

"optimal": meminimumkan rugi kuadrat berbobot-MSE $\sum_d (\hat{\theta}_d^{\text{BM}} - \hat{\theta}_d)^2 / \text{mse}_d$ dengan kendala (25), menghasilkan

$$\hat{\theta}_d^{\text{BM}} = \hat{\theta}_d + \frac{w_d \text{mse}_d}{\sum_j w_j^2 \text{mse}_j} \left(T_g - \sum_{j \in g} w_j \hat{\theta}_j \right) \quad (26)$$

[13]; area dengan MSE besar menyerap penyesuaian lebih besar.

"logit": pergeseran aditif pada skala logit untuk indikator terbatas $\theta_d \in (0, 1)$ [15].

Tersedia pula kalibrasi hierarkis dua tahap (kabupaten/kota → provinsi → nasional) yang menjamin konsistensi matematis di semua jenjang administrasi sekaligus [17, 16].

7.1 Pseudocode

Algoritma 6 `benchmark_sae`: kalibrasi benchmarking

Require: Objek `fastsae` ($\hat{\theta}_d$, mse_d); target T_g ; bobot w_d ; grup g ; **method** $\in \{\text{ratio}, \text{difference}, \text{optimal}, \text{logit}\}$; **type** $\in \{\text{mean}, \text{total}\}$

Ensure: $\hat{\theta}_d^{\text{BM}}$ memenuhi $\sum_{d \in g} w_d \hat{\theta}_d^{\text{BM}} = T_g$

```

1:  $S \leftarrow \sum_{d \in g} w_d \hat{\theta}_d$ ;  $\Delta \leftarrow T_g - S$ 
2: if method = "ratio" then
3:    $\hat{\theta}_d^{\text{BM}} \leftarrow \hat{\theta}_d \cdot T_g / S$ 
4: else if method = "difference" then
5:    $\hat{\theta}_d^{\text{BM}} \leftarrow \hat{\theta}_d + \Delta / \sum_{d \in g} w_d$ 
6: else if method = "optimal" then
7:    $\hat{\theta}_d^{\text{BM}} \leftarrow \hat{\theta}_d + \frac{w_d \text{mse}_d}{\sum_j w_j^2 \text{mse}_j} \Delta$ 
8: else if method = "logit" then
9:    $\hat{\theta}_d^{\text{BM}} \leftarrow \text{logit}^{-1}(\text{logit}(\hat{\theta}_d) + c)$ , dengan  $c$  dipecahkan agar (25) terpenuhi
10: end if
11: Bila kalibrasi hierarkis dua tahap: terapkan Algoritma 6 pada jenjang bawah dahulu, lalu
    kalibrasi agregatnya ke target jenjang atas
12: return  $\hat{\theta}^{\text{BM}}$ 

```

8 Metode Estimasi MSE dalam Paket

Table 3: Metode estimasi MSE yang tersedia per fungsi.

Fungsi	Metode MSE	Rujukan
<code>eblup_fh</code>	Analitik Prasad–Rao (+ koreksi ML)	[3, 5]
<code>eblup_sfh</code>	Analitik $g_1 + g_2 + 2g_3 - g_4$; PB; NPB	[9, 11]
<code>eblup_stfh</code>	<i>Parametric bootstrap</i>	[14]
<code>eblup_bhf</code>	<i>Parametric bootstrap</i>	[2]
<code>hb_area</code>	Posterior INLA (interval kredibel)	[12]

9 Penggunaan Kode `fastsae`

Bagian ini memberi contoh alur kerja tipikal memakai paket `fastsae` di R, berdasarkan himpunan data bawaan paket (`mys`: 42 kabupaten/kota, `mys_panel`: panel 2016–2026, `mys_proxmat`: matriks ketetanggaan). Instalasi dari GitHub:

```
# install.packages("remotes")
remotes::install_github("ridsonap/fastvae")
```

9.1 Model berbasis area

```
library(fastsae)
data(mys); data(mys_proxmat); data(mys_panel)

# 1. Fay-Herriot baku (REML)
fit_fh <- eblup_fh(y ~ x1 + x2, vardir = "vardir", data = mys)
```

```
# 2. Fay-Herriot spasial (SAR(1) pada pengaruh acak)
fit_sfh <- eblup_sfh(y ~ x1 + x2, vardir = "vardir", data = mys,
                    W = mys_proxmat, mse_method = "analytical")

# 3. Fay-Herriot spasio-temporal, model "ST"
fit_stfh <- eblup_stfh(y ~ x1 + x2, vardir = "vardir", data = mys_panel,
                      domain = "area", time = "year",
                      W = mys_proxmat, model = "ST", compute_mse = TRUE)
```

9.2 Model berbasis unit

```
# 4. Battese-Harter-Fuller (butuh data unit + rata-rata populasi Xpop)
fit_bhf <- eblup_bhf(y ~ x1 + x2, unit_data = susenas_unit,
                    Xpop = pop_means, domain_var = "kab",
                    popsize_var = "N", compute_mse = TRUE)
```

9.3 Model Bayes hierarkis (INLA)

```
# 5. HB area-level; INLA hanya tersedia bila terpasang
if (requireNamespace("INLA", quietly = TRUE)) {
  fit_hb <- hb_area(y ~ x1 + x2, data = mys, vardir = "vardir",
                   family = "gaussian", spatial = "bym2",
                   W = mys_proxmat)
}
```

9.4 Kalibrasi, diagnostik, dan visualisasi

```
# 6. Benchmarking ke target provinsi/nasional
bm <- benchmark_sae(fit_fh, target = 6.5, method = "ratio")

# 7. Diagnostik model dan plot otomatis
dg <- diagnose(fit_fh)
print(dg)
autoplot(dg)          # ggplot2: residual, RSE, peta keandalan

# 8. Bandingkan beberapa model
cmp <- compare_sae(fh = fit_fh, sfh = fit_sfh)

# 9. Ekspor hasil ke Excel/CSV
export_sae(fit_fh, file = "hasil_sae.xlsx", benchmark = bm)
```

Semua fungsi pemodelan mengembalikan objek kelas **fastsae** (list berisi penduga, MSE, parameter, dan ringkasan model) yang dapat dicetak dengan **print()** dan diringkas dengan **summary()**.

A Riwayat Perbaikan Implementasi

Berdasarkan pembacaan kode sumber v0.1.0, ditemukan empat isu implementasi (yang tidak mengubah formulasi model pada bagian-bagian sebelumnya, tetapi memengaruhi keluaran perangkat lunak). Keempatnya telah diperbaiki pada *branch inla-v2* (komit 55af78ab):

1. `src/eb lup_sfh_core.cpp`: variabel `u_all` dideklarasikan ulang sehingga menutupi (*shadowing*) versi yang telah diisi; kolom `random_effect` untuk area tak tersampel tidak terinisialisasi. **Perbaikan:** deklarasi bayangan dihapus sehingga prediksi kriging area tak tersampel terisi dengan benar.
2. `src/eb lup_stfh_pbmse.cpp`: pada bootstrap model “S”, satu vektor pengaruh acak temporal u_{2t} dibangkitkan sekali per replikasi lalu dipakai ulang untuk *seluruh* domain, sehingga menciptakan korelasi silang-domain artifisial. **Perbaikan:** u_{2dt} kini dibangkitkan independen per domain dan waktu, sesuai spesifikasi model “S”.
3. `R/compare_sae.R`: penggabungan panel hanya berdasarkan `domain` sehingga berpotensi menghasilkan perkalian kartesius antar waktu. **Perbaikan:** penggabungan dilakukan berdasarkan `domain dan time`.
4. `src/eb lup_fh.cpp`: penanda konvergensi ($k < \text{maxiter}$) melaporkan tidak konvergen bila algoritma tepat berhenti pada iterasi maksimum (*off-by-one*). **Perbaikan:** penanda kini memakai `diff <= precision`.

Keempat perbaikan telah diverifikasi dengan skrip pengujian khusus (6/6 lolos) serta suite `testthat` bawaan paket (0 gagal).

References

- [1] Fay, R. E. dan Herriot, R. A. (1979). Estimates of income for small places: An application of James–Stein procedures to census data. *Journal of the American Statistical Association*, 74(366), 269–277.
- [2] Battese, G. E., Harter, R. M., dan Fuller, W. A. (1988). An error-components model for prediction of county crop areas using survey and satellite data. *Journal of the American Statistical Association*, 83(401), 28–36.
- [3] Prasad, N. G. N. dan Rao, J. N. K. (1990). The estimation of the mean squared error of small-area estimators. *Journal of the American Statistical Association*, 85(409), 163–171.
- [4] Besag, J., York, J., dan Mollié, A. (1991). Bayesian image restoration, with two applications in spatial statistics. *Annals of the Institute of Statistical Mathematics*, 43, 1–20.
- [5] Datta, G. S. dan Lahiri, P. (2000). A unified measure of uncertainty of estimated best linear unbiased predictors in small area estimation problems. *Statistica Sinica*, 10(2), 613–627.
- [6] Knorr-Held, L. (2000). Bayesian modelling of inseparable space-time variation in disease risk. *Statistics in Medicine*, 19, 2555–2567.
- [7] Leroux, B. G., Lei, X., dan Breslow, N. (2000). Estimation of disease rates in small areas: A new mixed model for spatial dependence. Dalam M. E. Halloran dan D. Berry (ed.), *Statistical Models in Epidemiology, the Environment, and Clinical Trials*, 179–191. Springer.
- [8] You, Y. dan Rao, J. N. K. (2002). Small area estimation using matched sampling and linking models. *The Canadian Journal of Statistics*, 30(1), 3–19.
- [9] Singh, B. B., Shukla, G. K., dan Kundu, D. (2005). Spatio-temporal models in small area estimation. *Survey Methodology*, 31(2), 183–195.
- [10] Pratesi, M. dan Salvati, N. (2008). Small area estimation: the EBLUP estimator based on spatially correlated random area effects. *Statistical Methods & Applications*, 17, 113–141.
- [11] González-Manteiga, W., Lombardía, M. J., Molina, I., Morales, D., dan Santamaría, L. (2008). Bootstrap mean squared error of a small-area EBLUP. *Journal of Statistical Computation and Simulation*, 78(5), 443–462.

- [12] Rue, H., Martino, S., dan Chopin, N. (2009). Approximate Bayesian inference for latent Gaussian models by using integrated nested Laplace approximations. *Journal of the Royal Statistical Society: Series B*, 71(2), 319–392.
- [13] Datta, G. S., Ghosh, M., Steorts, R. C., dan Maples, J. J. (2011). Bayesian benchmarking with applications to small area estimation. *TEST*, 20, 574–588.
- [14] Marhuenda, Y., Molina, I., dan Morales, D. (2013). Small area estimation with spatio-temporal Fay–Herriot models. *Computational Statistics & Data Analysis*, 58, 308–325.
- [15] Berg, E. J. dan Fuller, W. A. (2014). Small area prediction of proportions with applications to the Canadian Labour Force Survey. *Journal of Survey Statistics and Methodology*, 2(2), 227–256.
- [16] Steorts, R. C. dan Ghosh, M. (2014). Bayesian benchmarking of the Fay–Herriot model using random deletion. *Calcutta Statistical Association Bulletin*, 65, 257–274.
- [17] Rao, J. N. K. dan Molina, I. (2015). *Small Area Estimation* (edisi ke-2). John Wiley & Sons.
- [18] Riebler, A., Sørbye, S. H., Simpson, D., dan Rue, H. (2016). An intuitive Bayesian spatial model for disease mapping that accounts for scaling. *Statistical Methods in Medical Research*, 25(4), 1145–1165.
- [19] De Nicolò, S. dan Gardini, A. (2024). The R package `tipsae`: Tools for mapping proportions and indicators on the unit interval. *Journal of Statistical Software*, 108(1), 1–36.